

**ANALISIS KOMPARATIF PENDEKATAN SPASIAL DAN
SPASIOTEMPORAL UNTUK KLASIFIKASI VIDEO DEEPPAKE
MENGUNAKAN VISION TRANSFORMER DAN VIDEOMAE**

TUGAS AKHIR

Rustian Afencius Marbun

122140155



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	v
DAFTAR GAMBAR	vi
DAFTAR KODE	viii
DAFTAR RUMUS	ix
BABI PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	6
1.6.1 Bab I Pendahuluan	6
1.6.2 Bab II Tinjauan Pustaka	6
1.6.3 Bab III Metode Penelitian	6
1.6.4 Bab IV Hasil dan Pembahasan	6
1.6.5 Bab V Kesimpulan dan Saran	6
BAB II TINJAUAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.2 Dasar Teori	12
2.2.1 Deepfake dan Manipulasi Media Visual	12
2.2.1.1 Deepfake	13
2.2.1.2 Konsep dan Generasi Deepfake	13
2.2.1.3 Karakteristik Dataset In-the-Wild	14

2.2.2	Deep Learning	15
2.2.3	Computer Vision	15
2.2.4	Transformer	16
2.2.5	Vision Transformer (ViT)	18
2.2.6	VideoMAE	19
2.2.7	Strided Temporal Sampling	22
2.2.8	Evaluasi Model	24
2.2.8.1	Confusion Matrix	24
2.2.8.2	Accuracy	25
2.2.8.3	Precision, Recall, dan F1-Score	25
2.2.8.4	Area Under Curve – Receiver Operating Characteristic (AUC-ROC)	26
BAB III METODE PENELITIAN		28
3.1	Alur Penelitian	28
3.2	Penjabaran Langkah Penelitian	28
3.2.1	Identifikasi Masalah	28
3.2.2	Studi Literatur	29
3.2.3	Pengumpulan Data	30
3.2.4	Preprocessing Data	32
3.2.4.1	Ekstraksi Dataset	33
3.2.4.2	Pembentukan Klip 46 Frame	35
3.2.4.3	Strided Temporal Sampling	38
3.2.4.4	Data Splitting	39
3.2.4.5	Augmentasi Data	40
3.2.4.6	Normalisasi Frame	40
3.2.5	Rancangan Model	41
3.2.5.1	Rancangan Model Spasial Berbasis Vision Transformer (ViT)	42

3.2.5.2	Rancangan Model Spasiotemporal Berbasis VideoMAE	44
3.2.5.3	Rancangan Eksperimen	47
3.2.6	Evaluasi Model	50
3.2.7	Hasil dan Pembahasan	51
3.3	Alat dan Bahan Tugas Akhir	52
3.3.1	Alat	52
3.3.2	Dataset	52
3.4	Ilustrasi Perhitungan Metode	52
3.4.1	Ilustrasi Perhitungan Metrik Evaluasi	52
BAB IV	HASIL DAN PEMBAHASAN	56
4.1	Pengumpulan Data	56
4.2	Hasil <i>Pre-processing</i> Data	57
4.2.1	Hasil Pembentukan Klip 46 <i>Frame</i>	57
4.2.2	Hasil Pembagian <i>Dataset</i>	59
4.2.3	Augmentasi Data	61
4.2.4	Normalisasi Data	63
4.3	Hasil Rancangan Model	64
4.3.1	Model Spasial	65
4.3.2	Model Spasiotemporal	66
4.3.3	Konfigurasi <i>Hyperparameter</i>	67
4.4	Hasil Eksperimen	68
4.4.1	Hasil Eksperimen <i>Baseline</i>	69
4.4.2	Hasil Konfigurasi Pelatihan	73
4.4.2.1	Pengaruh <i>Epoch</i> Maksimum	73
4.4.2.2	Pengaruh <i>Learning Rate</i>	76
4.4.2.3	Pengaruh <i>Loss Function</i>	79
4.4.2.4	Pengaruh Augmentasi Data	82

4.4.2.5	Pengaruh <i>Dropout</i>	83
4.4.2.6	Pengaruh <i>Scheduler</i>	84
4.4.3	Hasil Konfigurasi Input Spasial dan Temporal	86
4.4.3.1	Eksperimen Penurunan Resolusi	87
4.4.3.2	Eksperimen <i>Stride</i> Lebih Rapat	88
4.4.3.3	Eksperimen <i>Frame</i> Lebih Sedikit	89
4.4.3.4	Eksperimen <i>Frame</i> Lebih Banyak	91
4.4.4	Evaluasi Lintas- <i>Dataset</i>	92
BAB V	KESIMPULAN DAN SARAN	96
5.1	Kesimpulan	96
5.2	Saran	96
DAFTAR PUSTAKA		97

DAFTAR TABEL

Tabel 2.1	Literasi Penelitian Terdahulu	10
Tabel 2.2	<i>Confusion Matrix</i>	25
Tabel 3.1	Statistik panjang sekuens berdasarkan subset dan kelas	31
Tabel 3.2	Rancangan eksperimen <i>baseline</i>	48
Tabel 3.3	Konfigurasi pelatihan yang diuji	48
Tabel 3.4	Konfigurasi input spasial dan temporal	49
Tabel 3.5	Rancangan evaluasi lintas- <i>dataset</i>	49
Tabel 3.6	Contoh <i>confusion matrix</i> hasil evaluasi	53
Tabel 4.1	Distribusi Kelas <i>Dataset WildDeepfake</i>	56
Tabel 4.2	Distribusi Kelas Hasil Pembentukan Klip 46 <i>Frame</i>	59
Tabel 4.3	Hasil Pembagian <i>Dataset</i> Berdasarkan Kelas	61
Tabel 4.4	Hyperparameter Model Baseline	68
Tabel 4.5	Hasil Eksperimen <i>Baseline</i>	69
Tabel 4.6	Konfigurasi Pelatihan yang Diuji	74
Tabel 4.7	Pengaruh <i>Epoch</i> Maksimum terhadap Performa Model	74
Tabel 4.8	Pengaruh <i>Learning Rate</i> terhadap Performa Model	76
Tabel 4.9	Pengaruh <i>Loss Function</i> terhadap Performa Model	79
Tabel 4.10	Pengaruh Augmentasi Data terhadap Performa Model	82
Tabel 4.11	Pengaruh <i>Dropout</i> terhadap Performa Model	83
Tabel 4.12	Pengaruh <i>Scheduler</i> terhadap Performa Model	85
Tabel 4.13	Konfigurasi Input Spasial dan Temporal	86
Tabel 4.14	Hasil Eksperimen Penurunan Resolusi	87
Tabel 4.15	Hasil Eksperimen <i>Stride</i> Lebih Rapat	88
Tabel 4.16	Hasil Eksperimen <i>Frame</i> Lebih Sedikit	90
Tabel 4.17	Hasil Eksperimen <i>Frame</i> Lebih Banyak	91
Tabel 4.18	Hasil Evaluasi Lintas- <i>Dataset</i> pada <i>Dataset Celeb-DF v2</i> ..	93

DAFTAR GAMBAR

Gambar 2.1	Arsitektur Transformer	17
Gambar 2.2	Arsitektur Vision Transformer (ViT)	19
Gambar 2.3	Arsitektur VideoMAE dengan asymmetric encoder-decoder dan tube masking	20
Gambar 3.1	Alur Penelitian	28
Gambar 3.2	Contoh sampel citra wajah kelas <i>real</i> dan <i>fake</i> pada dataset WildDeepfake	30
Gambar 3.3	Struktur folder dataset WildDeepfake sebelum ekstraksi ..	34
Gambar 3.4	Struktur folder dataset WildDeepfake setelah ekstraksi ..	35
Gambar 3.5	Ilustrasi pembentukan klip 46 <i>frame</i> berpusat di tengah pada sekuens 50 <i>frame</i>	37
Gambar 3.6	Ilustrasi pembentukan klip 46 <i>frame</i> berpusat di tengah pada sekuens 150 <i>frame</i>	37
Gambar 3.7	Struktur folder dataset WildDeepfake setelah proses pembentukan klip 46 <i>frame</i>	38
Gambar 3.8	Ilustrasi <i>strided temporal sampling</i> ($T = 16, \tau = 3$)	39
Gambar 3.9	Arsitektur model spasial berbasis Vision Transformer (ViT)	43
Gambar 3.10	Arsitektur model spasiotemporal berbasis VideoMAE untuk klasifikasi <i>deepfake</i>	46
Gambar 4.1	Contoh Sampel Citra Wajah Kelas <i>Real</i> dan <i>Fake</i> pada Dataset WildDeepfake	56
Gambar 4.2	Contoh Hasil Augmentasi Data Menggunakan Albumentations: (a) citra asli, (b) horizontal flip, (c) random crop, (d) random scale, (e) color jitter, (f) Gaussian blur, dan (g) Gaussian noise	63

Gambar 4.3	Kurva <i>training loss</i> dan <i>validation loss</i> pada eksperimen <i>baseline</i>	70
Gambar 4.4	Kurva <i>training accuracy</i> dan <i>validation accuracy</i> pada eksperimen <i>baseline</i>	71
Gambar 4.5	<i>Confusion matrix</i> pada eksperimen <i>baseline</i>	71
Gambar 4.6	Kurva <i>training loss</i> dan <i>validation loss</i> pada eksperimen <i>epoch</i> maksimum 40: (a) Model spasial dan (b) Model spasiotemporal.	75
Gambar 4.7	Kurva <i>training loss</i> dan <i>validation loss</i> pada eksperimen <i>learning rate</i> $5e-4$: (a) model spasial dan (b) model spasiotemporal.	77
Gambar 4.8	<i>Confusion matrix</i> model spasial pada <i>Cross Entropy Loss</i> dan <i>Focal Loss</i>	80
Gambar 4.9	<i>Confusion matrix</i> model spasiotemporal pada <i>Cross Entropy Loss</i> dan <i>Focal Loss</i>	81

DAFTAR KODE

Kode 4.1 Pembentukan Klip 46 <i>Frame</i>	57
Kode 4.2 Pembagian <i>Dataset Train</i> , Validasi, dan <i>Test</i>	60
Kode 4.3 Augmentasi Data Menggunakan <i>Albumentations</i>	62
Kode 4.4 Normalisasi Data	64
Kode 4.5 Implementasi Model Spasial	65
Kode 4.6 Implementasi Model Spasiotemporal	67

DAFTAR RUMUS

Rumus 2.1	Mekanisme <i>self-attention</i> pada Transformer	17
Rumus 2.2	Rumus indeks <i>frame</i> pada <i>strided temporal sampling</i>	22
Rumus 2.3	Rumus panjang klip minimum berdasarkan indeks <i>frame</i> .	23
Rumus 2.4	Rumus panjang klip minimum bentuk sederhana	23
Rumus 2.5	Rumus jumlah klip turunan dari satu sekuens	23
Rumus 2.6	Rumus sisa <i>frame</i> yang tidak membentuk klip penuh	23
Rumus 2.7	Rumus pembuangan <i>frame</i> sisa secara simetris	24
Rumus 2.8	Rumus <i>accuracy</i> pada klasifikasi biner	25
Rumus 2.9	Rumus <i>precision</i> pada klasifikasi biner	26
Rumus 2.10	Rumus <i>recall</i> pada klasifikasi biner	26
Rumus 2.11	Rumus <i>F1-score</i> pada klasifikasi biner	26
Rumus 2.12	Rumus <i>true positive rate</i> (TPR)	27
Rumus 2.13	Rumus <i>false positive rate</i> (FPR)	27

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Kemajuan teknologi informasi dan komunikasi telah mengubah cara masyarakat memproduksi, mendistribusikan, dan mengonsumsi informasi digital. Dalam konteks tersebut, media visual seperti citra dan video menempati posisi penting karena kerap dipersepsikan sebagai representasi yang dekat dengan realitas. Namun, perkembangan kecerdasan buatan generatif juga meningkatkan risiko manipulasi informasi visual dalam skala besar. *Global Risks Report 2026* yang diterbitkan oleh *World Economic Forum* menunjukkan bahwa misinformasi dan disinformasi merupakan ancaman yang konsisten lintas periode proyeksi, yaitu menempati peringkat kelima pada tahun 2026, peringkat kedua dalam proyeksi dua tahun hingga 2028, dan peringkat keempat dalam proyeksi sepuluh tahun hingga 2036 [1]. Temuan tersebut menunjukkan bahwa gangguan terhadap integritas informasi bukan hanya menjadi persoalan saat ini, tetapi juga diperkirakan tetap signifikan dalam jangka menengah dan panjang. Salah satu bentuk manipulasi visual yang paling menonjol dalam konteks ini adalah *deepfake*, yaitu media sintetis berbasis *deep learning* yang mampu menghasilkan konten wajah dan video yang sangat realistis, sehingga berpotensi digunakan untuk penipuan, manipulasi opini, dan penyalahgunaan identitas digital [2], [3].

Ancaman *deepfake* tidak lagi terbatas pada ranah hiburan atau eksperimen teknis, tetapi telah berkembang menjadi persoalan keamanan informasi dan kepercayaan digital. Tolosana dkk. menjelaskan bahwa kemajuan teknik manipulasi wajah, khususnya yang ditopang *deep learning* dan GAN, telah menghasilkan konten palsu yang sangat meyakinkan serta menimbulkan tantangan serius bagi sistem deteksi [2]. Sejalan dengan itu, Khaund menunjukkan bahwa media sintetis modern dapat melemahkan keandalan

mekanisme autentikasi yang bergantung pada biometrik dan verifikasi dokumen, sehingga *deepfake* menjadi ancaman yang relevan bagi ekosistem identitas digital [4]. Kondisi ini menegaskan perlunya pengembangan sistem deteksi otomatis yang tidak hanya akurat pada lingkungan terkontrol, tetapi juga tangguh ketika dihadapkan pada variasi kualitas media di dunia nyata [4].

Dalam perkembangannya, pendekatan deteksi *deepfake* dapat dibedakan menjadi pendekatan spasial dan pendekatan spasiotemporal. Pendekatan spasial, yang secara operasional bekerja pada tingkat *frame* tunggal, berfokus pada ekstraksi artefak visual statis seperti ketidakwajaran tekstur, batas wajah, dan inkonsistensi detail lokal [2], [5]. Pendekatan ini relatif efisien dan telah menunjukkan performa yang baik pada banyak dataset terkontrol. Akan tetapi, semakin realistisnya generator *deepfake* membuat artefak visual statis menjadi semakin halus, sehingga detektor yang hanya bergantung pada bukti spasial berisiko mengalami penurunan kemampuan generalisasi [2], [5]. Dengan kata lain, peningkatan kualitas generasi media sintetis menuntut strategi deteksi yang tidak hanya mengandalkan petunjuk visual pada satu bingkai secara terpisah.

Sebagai alternatif, pendekatan spasiotemporal memanfaatkan hubungan antarbingkai untuk mendeteksi inkonsistensi gerakan atau koherensi temporal yang tidak alami pada video *deepfake* [6]. Gu dkk. menunjukkan bahwa deteksi video *deepfake* pada praktiknya berkembang dalam dua jalur besar, yaitu solusi berbasis *frame* dan solusi berbasis video, serta menekankan pentingnya pemodelan *spatial-temporal inconsistency* dalam video hasil manipulasi [7]. Demikian pula, Haliassos dkk. menunjukkan bahwa representasi gerakan mulut yang bersifat spasiotemporal dapat meningkatkan kemampuan generalisasi dan ketahanan terhadap berbagai distorsi umum [8]. Meskipun demikian, keunggulan pendekatan spasiotemporal tidak selalu bersifat mutlak, karena isyarat temporal juga dapat terdegradasi oleh kompresi, *post-processing*, dan kualitas video yang rendah, yang lazim dijumpai pada distribusi konten daring [8].

Tantangan tersebut menjadi semakin penting ketika sistem deteksi diuji

pada skenario dunia nyata (*in-the-wild*). Zi dkk. memperkenalkan WildDeepfake sebagai dataset dunia nyata yang terdiri atas 7.314 sekuens wajah yang diekstraksi dari 707 video *deepfake* yang dikumpulkan sepenuhnya dari internet [9]. Mereka juga menunjukkan bahwa WildDeepfake merupakan dataset yang lebih menantang dibandingkan dataset yang lebih terkontrol, karena performa sejumlah detektor dasar dapat menurun secara drastis pada dataset ini [9]. Temuan tersebut menunjukkan bahwa evaluasi pada data yang terkontrol belum cukup untuk merepresentasikan kondisi operasional sebenarnya. Oleh karena itu, pertanyaan mengenai pendekatan mana yang lebih tangguh, apakah pendekatan spasial atau pendekatan spasiotemporal, masih relevan untuk diuji secara empiris pada data *deepfake* dunia nyata [7], [8], [9], [10].

Berdasarkan uraian tersebut, penelitian ini berfokus pada analisis komparatif klasifikasi video *deepfake* dengan pendekatan spasial dan spasiotemporal menggunakan dua model dari keluarga Transformer, yaitu Vision Transformer (ViT) dan VideoMAE. ViT merepresentasikan pendekatan Transformer untuk citra dengan memproses urutan *image patches* secara langsung [11], sedangkan VideoMAE merupakan *video transformer* yang dirancang untuk mempelajari representasi video secara efisien [12]. Dengan membandingkan kedua pendekatan tersebut pada dataset WildDeepfake, penelitian ini bertujuan untuk mengevaluasi secara objektif kontribusi relatif informasi spasial dan temporal terhadap ketahanan klasifikasi video *deepfake* pada kondisi dunia nyata. Hasil penelitian diharapkan dapat memberikan dasar empiris yang lebih kuat mengenai pendekatan yang lebih sesuai untuk pengembangan sistem deteksi *deepfake* yang *robust* dan relevan secara praktis.

1.2 Rumusan Masalah

1. Bagaimana merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset

WildDeepfake?

2. Bagaimana mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*?
3. Pendekatan manakah di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE yang paling efektif untuk klasifikasi video *deepfake* pada dataset WildDeepfake?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan penelitian ini adalah sebagai berikut.

1. Merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake.
2. Mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*.
3. Menentukan pendekatan yang paling efektif di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE untuk klasifikasi video *deepfake* pada dataset WildDeepfake.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut.

1. Dataset yang digunakan dalam penelitian ini hanya dataset WildDeepfake sebagai sumber data pelatihan, validasi, dan pengujian.
2. Penelitian ini dibatasi pada klasifikasi biner untuk membedakan video ke

dalam kelas *real* dan *fake*.

3. Data yang digunakan berupa *face sequence* yang telah melalui proses *preprocessing* awal pada dataset sumber, sehingga penelitian ini tidak mencakup tahap deteksi wajah, ekstraksi fitur wajah, maupun *face alignment* dari video mentah.
4. Model yang digunakan dibatasi pada arsitektur Vision Transformer (ViT) untuk pendekatan spasial dan VideoMAE untuk pendekatan spasiotemporal, dengan memanfaatkan (*pretrained weights*) untuk proses *fine-tuning*.
5. Evaluasi kinerja model dibatasi pada metrik *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*.
6. Penelitian ini tidak mencakup perancangan atau pengembangan aplikasi maupun antarmuka pengguna, serta tidak membahas implementasi sistem dalam skenario *real-time*, integrasi dengan data audio atau teks, dan pengujian pada dataset eksternal selain WildDeepfake.

1.5 Manfaat Penelitian

Manfaat penelitian ini adalah sebagai berikut.

1. Menghasilkan implementasi dan evaluasi komparatif model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake.
2. Memberikan kontribusi ilmiah berupa analisis efektivitas relatif informasi spasial dan temporal dalam klasifikasi video *deepfake* pada kondisi dunia nyata (*in-the-wild*).
3. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan sistem klasifikasi atau deteksi *deepfake* yang lebih *robust*, khususnya pada data video dengan kualitas visual yang beragam dan terkompresi.

1.6 Sistematika Penulisan

Sistematika penulisan yang diterapkan dalam menyusun penelitian ini adalah sebagai berikut.

1.6.1 Bab I Pendahuluan

Pada Bab I, penulis menjelaskan latar belakang permasalahan, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, dan sistematika penulisan.

1.6.2 Bab II Tinjauan Pustaka

Pada Bab II, penulis memberikan penjabaran tentang penelitian sebelumnya yang terkait dengan penelitian ini. Penulis juga memaparkan dasar teori yang berkaitan dengan penelitian yang dilakukan.

1.6.3 Bab III Metode Penelitian

Pada Bab III, penulis menjelaskan mengenai metodologi yang akan digunakan pada penelitian ini. Metodologi yang digunakan dapat dijelaskan dengan diagram alir yang dilanjutkan dengan penjelasan setiap tahapnya dan juga menjelaskan tentang perangkat apa yang digunakan oleh penulis untuk penelitian.

1.6.4 Bab IV Hasil dan Pembahasan

Pada Bab IV, penulis menjelaskan hasil dari penelitian yang didapatkan, dimulai dengan pengumpulan data, pengolahan data, hasil penelitian, dan pembahasan penelitian.

1.6.5 Bab V Kesimpulan dan Saran

Pada Bab V, penulis memberikan kesimpulan dari hasil penelitian yang didapatkan pada Bab IV, serta saran yang dapat dilakukan untuk penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Tinjauan pustaka ini memaparkan penelitian terdahulu yang memiliki relevansi topik dan menjadi landasan utama penyusunan tugas akhir. Adapun penelitian yang dijadikan acuan diuraikan sebagai berikut.

Zi dkk. pada tahun 2021 mempermasalahkan keterbatasan dataset *deepfake* yang umumnya disusun dalam kondisi terkontrol, sehingga kurang merepresentasikan variasi konten dunia nyata yang beredar di internet [9]. Untuk mengatasi hal tersebut, mereka memperkenalkan dataset WildDeepfake yang terdiri atas 7.314 *face sequence* yang diekstraksi dari 707 video *deepfake* yang dikumpulkan sepenuhnya dari internet [9]. Kontribusi utama penelitian ini terletak pada penyediaan dataset *in-the-wild* yang lebih menantang dibandingkan dataset terkontrol, serta evaluasi sejumlah detektor dasar yang menunjukkan penurunan performa yang cukup besar pada dataset tersebut [9]. Bagi penelitian ini, paper tersebut menjadi landasan utama dalam pemilihan WildDeepfake sebagai sumber data, karena menunjukkan bahwa evaluasi model pada data terkontrol saja belum cukup untuk menggambarkan ketahanan model pada kondisi operasional yang sesungguhnya.

Khormali dan Yuan pada tahun 2022 mengangkat masalah bahwa sebagian besar metode deteksi *deepfake* masih bergantung pada arsitektur CNN, yang dinilai kurang optimal dalam menangkap hubungan global antarbagi citra [13]. Mereka mengusulkan DFDT, yaitu kerangka *end-to-end* berbasis Vision Transformer yang terdiri atas komponen *patch extraction and embedding*, *multi-stream transformer block*, *attention-based patch selection*, dan *multi-scale classifier* [13]. Hasil pengujian menunjukkan bahwa DFDT mencapai akurasi 99,41% pada FaceForensics++, 99,31% pada Celeb-DF (V2), dan 81,35% pada

WildDeepfake [13]. Penelitian ini relevan karena secara langsung mendukung penggunaan ViT pada pendekatan spasial untuk klasifikasi *deepfake*. Selain itu, keberhasilan DFDT pada WildDeepfake menunjukkan bahwa Transformer berbasis citra tetap memiliki potensi yang baik pada data dunia nyata, sehingga layak dijadikan pembanding konseptual bagi pendekatan spasial yang digunakan dalam penelitian ini.

Zhuang dkk. pada tahun 2022 membahas permasalahan bahwa pembelajaran inkonsistensi pemalsuan wajah umumnya memerlukan anotasi lokasi manipulasi tingkat piksel, padahal anotasi itu sulit diperoleh dan mahal dibuat [14]. Untuk menjawab masalah tersebut, mereka mengusulkan UIA-ViT, yaitu metode berbasis ViT yang memanfaatkan *self-attention* untuk mempelajari inkonsistensi intra-*frame* hanya dengan label tingkat video, melalui dua komponen utama berupa *Unsupervised Patch Consistency Learning* (UPCL) dan *Progressive Consistency Weighted Assemble* (PCWA) [14]. Kontribusi penelitian ini menunjukkan bahwa ViT tidak hanya efektif sebagai pengganti CNN, tetapi juga memiliki keunggulan metodologis dalam memodelkan relasi antarpetak citra yang relevan untuk mendeteksi inkonsistensi manipulasi [14]. Bagi penelitian ini, UIA-ViT memperkuat justifikasi bahwa pendekatan spasial berbasis ViT masuk akal untuk diterapkan pada klasifikasi video *deepfake*, karena informasi visual statis pada tingkat *frame* masih dapat dieksploitasi secara efektif melalui mekanisme perhatian global.

Kingra dkk. tahun 2024 menyoroti bahwa banyak metode sebelumnya belum mampu memanfaatkan informasi spasial dan temporal secara terpadu dalam satu kerangka Transformer *end-to-end* [15]. Untuk itu, mereka mengusulkan SFormer yang menggunakan Swin Transformer untuk analisis spasial, diikuti *transformer block* untuk analisis temporal, dan *MLP block* untuk prediksi akhir [15]. Hasil eksperimen menunjukkan bahwa SFormer memperoleh akurasi 100% pada FF++, 97,81% pada DFD, 99,1% pada Celeb-DF, dan 93,67% pada DFDC, serta menunjukkan kemampuan generalisasi yang baik

pada eksperimen lintas-dataset [15]. Penelitian ini relevan karena mendukung argumen bahwa pendekatan spasiotemporal berbasis Transformer merupakan arah yang kuat untuk deteksi *deepfake* video. Dalam konteks penelitian ini, SFormer menjadi pembanding penting pada jalur spasiotemporal karena menunjukkan bahwa pemodelan hubungan antar-*frame* dapat meningkatkan kemampuan model dalam menangkap jejak manipulasi yang tidak selalu tampak pada *frame* tunggal.

Hu dkk. pada tahun 2024 membahas tantangan bahwa video *deepfake* modern sering memiliki jejak manipulasi yang tersebar secara acak dan berubah antar-*frame*, sehingga sulit dideteksi hanya dengan fitur lokal yang tetap [16]. Mereka mengusulkan metode Delocate untuk deteksi dan lokalisasi *deepfake*, serta melakukan studi *ablation* yang secara langsung membandingkan MAE dan VideoMAE pada tugas deteksi *deepfake* [16]. Dalam *ablation study* tersebut, baseline VideoMAE memperoleh skor AUC 77,4 pada CDF, 89,3 pada DFO, dan 71,8 pada DFDC, sementara Delocate menunjukkan peningkatan lebih lanjut setelah dilakukan modifikasi terhadap strategi pemodelan [16]. Walaupun VideoMAE pada penelitian ini tidak digunakan sebagai metode utama oleh Hu dkk., keberadaan VideoMAE sebagai baseline yang dievaluasi secara langsung pada domain *deepfake* tetap penting, karena menunjukkan bahwa representasi video berbasis Transformer sudah mulai digunakan dan relevan untuk tugas deteksi *deepfake* video. Dengan demikian, paper ini dapat dijadikan justifikasi tambahan bagi pemilihan VideoMAE sebagai model pada pendekatan spasiotemporal dalam penelitian ini.

Berdasarkan lima penelitian tersebut, dapat disimpulkan bahwa terdapat tiga landasan utama yang mendukung penelitian ini. Pertama, WildDeepfake terbukti merupakan dataset yang lebih menantang dan lebih representatif untuk evaluasi pada kondisi dunia nyata [9]. Kedua, pendekatan spasial berbasis ViT telah menunjukkan potensi yang baik dalam mendeteksi artefak visual statis pada *deepfake* [13], [14]. Ketiga, pendekatan spasiotemporal berbasis

Transformer, termasuk model video seperti VideoMAE, menunjukkan potensi untuk menangkap bukti manipulasi yang tersebar pada dimensi spasial dan temporal [15], [16]. Meskipun demikian, masih terdapat celah penelitian berupa belum banyaknya studi yang secara langsung membandingkan pendekatan spasial berbasis ViT dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake dalam satu rancangan eksperimen yang setara. Oleh karena itu, penelitian ini diarahkan untuk mengisi celah tersebut melalui analisis komparatif kedua pendekatan pada skenario *deepfake in-the-wild*.

Tabel 2.1 Literasi Penelitian Terdahulu

No.	Judul	Masalah	Metode	Hasil
1.	WildDeepfake: A Challenging Real-World Dataset for Deepfake Detection (Zi dkk., 2024)	Dataset <i>deepfake</i> terkontrol kurang mewakili kondisi dunia nyata.	Memperkenalkan dataset WildDeepfake dan menguji beberapa baseline deteksi.	WildDeepfake lebih menantang daripada dataset terkontrol dan layak digunakan untuk evaluasi <i>in-the-wild</i> .
2.	DFDT: An End-to-End DeepFake Detection Framework Using Vision Transformer (Khormali dkk., 2022)	CNN kurang optimal menangkap relasi global citra.	Mengusulkan deteksi <i>deepfake</i> berbasis Vision Transformer.	Mencapai akurasi tinggi pada beberapa dataset, termasuk WildDeepfake, dan mendukung penggunaan ViT.

No.	Judul	Masalah	Metode	Hasil
3.	UIA-ViT: Unsupervised Inconsistency- Aware Method based on Vision Transformer for Face Forgery Detection (Zhuang dkk., 2022)	Deteksi inkonsistensi manipulasi biasanya memerlukan anotasi piksel.	Menggunakan ViT untuk mempelajari inkonsistensi <i>intra-frame</i> tanpa anotasi piksel.	Menunjukkan generalisasi yang baik dan memperkuat efektivitas ViT untuk deteksi manipulasi wajah.
4.	SFormer: An End-to- End Spatio- Temporal Transformer Architecture for Deepfake Detection (Kingra dkk., 2024)	Diperlukan model yang memanfaatkan informasi spasial dan temporal secara terpadu.	Menggunakan Swin Transformer dan <i>transformer</i> <i>temporal</i> untuk deteksi video <i>deepfake</i> .	Memberikan akurasi tinggi pada beberapa dataset dan mendukung pendekatan spasiotemporal berbasis Transformer.

No.	Judul	Masalah	Metode	Hasil
5.	Delocate: Detection and Localization for Deepfake Videos with Randomly-Located Tampered Traces (Huddk., 2024)	Jejak manipulasi video <i>deepfake</i> tersebar acak dan berubah antar- <i>frame</i> .	Mengusulkan model deteksi-lokalisasi dan membandingkan baseline MAE dan VideoMAE.	Menunjukkan peningkatan deteksi lintas-domain dan mendukung relevansi VideoMAE pada deteksi <i>deepfake</i> video.

2.2 Dasar Teori

2.2.1 Deepfake dan Manipulasi Media Visual

Perkembangan manipulasi media visual mengalami perubahan yang sangat signifikan seiring kemajuan *deep learning*, khususnya pada model generatif yang mampu mensintesis wajah dan video dengan tingkat realisme yang tinggi. Dalam konteks ini, *deepfake* dipahami sebagai salah satu bentuk media sintetis yang dihasilkan atau dimanipulasi menggunakan model berbasis jaringan saraf dalam, sehingga konten visual yang dihasilkan tampak autentik meskipun tidak sepenuhnya merepresentasikan kondisi yang sebenarnya [3]. Realisme *deepfake* semakin meningkat setelah berkembangnya arsitektur generator modern yang mampu menghasilkan wajah sintetis beresolusi tinggi dengan detail tekstur, pencahayaan, dan struktur wajah yang semakin alami [17]. Kondisi tersebut menyebabkan manipulasi media visual tidak lagi terbatas pada penyuntingan konvensional, tetapi telah berkembang menjadi rekayasa identitas, ekspresi, dan gerak wajah yang sulit dibedakan dari media asli [3], [17].

2.2.1.1 Deepfake

Deepfake adalah media sintetis atau media yang dimanipulasi menggunakan teknik *deep learning* untuk menghasilkan konten visual atau audiovisual yang menyerupai data asli secara sangat meyakinkan [3]. Dalam praktiknya, *deepfake* tidak hanya mencakup pertukaran wajah (*face swapping*), tetapi juga sintesis wajah penuh, manipulasi ekspresi wajah, rekayasa gerak bibir, dan perubahan identitas visual pada video [3]. Karakteristik utama *deepfake* terletak pada kemampuannya mempertahankan kesan visual yang realistis bagi pengamat manusia, sehingga media hasil manipulasi tampak sah secara visual walaupun tidak autentik secara semantik [3]. Oleh karena itu, *deepfake* menjadi salah satu bentuk manipulasi media visual yang paling menantang dalam bidang forensik digital, karena kualitas hasil generasinya terus meningkat seiring perkembangan model generatif modern [3], [17].

2.2.1.2 Konsep dan Generasi Deepfake

Konsep generasi *deepfake* sangat erat kaitannya dengan perkembangan model generatif, terutama *Generative Adversarial Networks* (GAN). GAN merupakan kerangka pembelajaran generatif yang melibatkan dua jaringan, yaitu *generator* yang bertugas menghasilkan sampel sintetis dan *discriminator* yang bertugas membedakan sampel sintetis dari data asli [18]. Melalui proses pelatihan yang bersifat *adversarial*, *generator* secara bertahap belajar menghasilkan data yang semakin menyerupai distribusi data nyata [18]. Kerangka ini menjadi fondasi penting bagi generasi awal *deepfake* karena memungkinkan pembentukan wajah sintetis dan manipulasi visual berbasis data dengan kualitas yang terus meningkat. Perkembangan berikutnya menghasilkan arsitektur yang lebih kuat, salah satunya *style-based generator architecture* pada StyleGAN, yang memungkinkan kontrol yang lebih baik terhadap atribut visual tingkat tinggi seperti identitas, pose, dan struktur wajah, sekaligus mempertahankan detail lokal yang halus [17]. Dengan demikian, realisme

deepfake modern tidak hanya ditentukan oleh kemampuan menghasilkan wajah yang tampak alami, tetapi juga oleh kemampuan model dalam menjaga konsistensi detail visual sehingga artefak manipulasi menjadi semakin sulit dikenali [17], [18].

2.2.1.3 Karakteristik Dataset In-the-Wild

Karakteristik dataset *in-the-wild* berbeda secara mendasar dari dataset yang dibangun dalam kondisi terkontrol. Pada data terkontrol, video umumnya memiliki kualitas yang lebih seragam, resolusi yang relatif stabil, pencahayaan yang lebih terkendali, dan tingkat kompresi yang tidak terlalu beragam. Sebaliknya, dataset *in-the-wild* merepresentasikan kondisi distribusi dunia nyata yang jauh lebih kompleks, karena memuat variasi kompresi, resolusi, pencahayaan, pose, ekspresi, latar belakang, sudut pengambilan gambar, serta kualitas video yang tidak seragam [9], [19]. Perbedaan tersebut menyebabkan jejak manipulasi pada video *deepfake* menjadi lebih sulit dikenali dibandingkan pada dataset terkontrol. Pergeseran menuju dataset yang lebih realistis juga terlihat pada Celeb-DF, yang dirancang sebagai dataset *DeepFake* yang lebih menantang dengan kualitas visual yang lebih tinggi daripada dataset generasi awal [19]. Pada konteks yang lebih luas, WildDeepfake merepresentasikan karakteristik *in-the-wild* secara lebih kuat karena disusun dari video yang benar-benar dikumpulkan dari internet dan menunjukkan bahwa performa detektor dasar dapat menurun cukup drastis ketika diuji pada kondisi dunia nyata [9]. Oleh karena itu, karakteristik utama dataset *in-the-wild* dalam penelitian ini dipahami sebagai keberagaman kondisi visual dan degradasi nyata yang membuat proses klasifikasi *deepfake* menjadi lebih menantang daripada pada data yang dibangun dalam lingkungan terkontrol [9], [19].

2.2.2 Deep Learning

Deep learning adalah cabang dari *machine learning* yang menggunakan jaringan saraf tiruan berlapis banyak untuk mempelajari representasi data secara bertingkat, mulai dari pola berlevel rendah hingga representasi berlevel tinggi yang lebih abstrak [20]. Pendekatan ini memungkinkan proses ekstraksi fitur dilakukan secara otomatis dari data, sehingga mengurangi ketergantungan pada perancangan fitur manual yang umum digunakan pada metode pembelajaran tradisional [20]. Dalam perkembangannya, *deep learning* telah menunjukkan peningkatan kinerja yang signifikan pada berbagai tugas, seperti pengenalan ucapan, pengenalan objek visual, deteksi objek, dan analisis data berskala besar [20]. Pada konteks penelitian ini, *deep learning* menjadi landasan utama dalam pembangunan model klasifikasi video *deepfake*, karena pendekatan ini memungkinkan model mempelajari pola visual yang kompleks dari citra wajah dan klip video secara langsung dari data [20], [21].

2.2.3 Computer Vision

Computer vision adalah bidang dalam kecerdasan buatan yang berfokus pada bagaimana sistem komputer memperoleh, merepresentasikan, dan memahami informasi dari citra maupun video [21]. Perkembangan *deep learning* telah mendorong kemajuan pesat pada bidang ini, terutama pada tugas klasifikasi citra, deteksi objek, segmentasi, dan analisis visual lainnya, karena model dapat mempelajari fitur visual secara lebih efektif dibandingkan pendekatan konvensional [21]. Dalam penelitian ini, *computer vision* menjadi kerangka aplikasi yang mendasari proses analisis *face sequence* dan klip video untuk membedakan konten *real* dan *fake* berdasarkan karakteristik visual yang dipelajari model [21]. Dengan demikian, *computer vision* tidak hanya berperan sebagai domain penerapan, tetapi juga sebagai dasar konseptual dalam memahami bagaimana informasi visual pada video *deepfake* dapat diolah menjadi keputusan klasifikasi [21].

2.2.4 Transformer

Transformer merupakan arsitektur jaringan saraf yang diperkenalkan untuk memodelkan hubungan antar elemen masukan melalui mekanisme *attention* tanpa bergantung pada proses rekuren maupun konvolusi [22]. Berbeda dengan *Recurrent Neural Network* (RNN) dan *Long Short-Term Memory* (LSTM) yang memproses data secara berurutan, Transformer memungkinkan setiap elemen masukan berinteraksi secara langsung dengan elemen lainnya dalam satu urutan, sehingga konteks global dapat dipelajari secara lebih efektif [22]. Karakteristik ini membuat Transformer menjadi salah satu fondasi utama dalam perkembangan *deep learning* modern dan kemudian diadaptasi ke berbagai domain, tidak hanya pada *Natural Language Processing* (NLP), tetapi juga pada *computer vision* [22].

Secara umum, arsitektur Transformer terdiri atas blok *encoder* dan *decoder* yang dibangun dari komponen utama berupa *multi-head attention*, *feed-forward network*, *residual connection*, dan *layer normalization* [22]. Pada penelitian ini, konsep Transformer menjadi dasar penting karena baik *Vision Transformer* (ViT) maupun VideoMAE sama-sama memanfaatkan mekanisme perhatian untuk membangun representasi visual dari citra dan video [11], [12], [22]. Dengan demikian, pemahaman terhadap Transformer diperlukan untuk menjelaskan bagaimana hubungan global antarbagian masukan visual dapat dipelajari secara langsung tanpa ketergantungan pada struktur rekuren maupun operasi konvolusi tradisional.

Mekanisme inti pada Transformer adalah *self-attention*, yaitu proses yang memungkinkan setiap elemen masukan memberikan perhatian terhadap elemen lainnya dalam urutan yang sama [22]. Pada mekanisme ini, setiap elemen masukan diproyeksikan ke dalam tiga representasi, yaitu *Query* (Q), *Key* (K), dan *Value* (V). Hubungan antar elemen dihitung melalui perkalian antara Q dan K untuk memperoleh skor kesamaan, kemudian dinormalisasi dengan fungsi


2.2.5 Vision Transformer (ViT)

Vision Transformer (ViT) merupakan adaptasi arsitektur Transformer untuk tugas klasifikasi citra dengan memproses citra sebagai urutan *image patch* [11]. Berbeda dengan *Convolutional Neural Network* (CNN) yang menekankan ekstraksi fitur lokal melalui operasi konvolusi, ViT membagi citra menjadi sejumlah *patch* dua dimensi, kemudian memperlakukan setiap *patch* sebagai token masukan yang serupa dengan token pada pemrosesan bahasa alami [11]. Pendekatan ini memungkinkan model memanfaatkan *self-attention* untuk mempelajari hubungan global antarbagian citra secara langsung [11]. Dalam konteks penelitian ini, ViT menjadi dasar pada pendekatan spasial karena setiap *frame* video *deepfake* diproses sebagai citra tunggal untuk mengekstraksi artefak visual statis.

Pada tahap awal pemrosesan, citra masukan berukuran $H \times W \times C$ dibagi menjadi sejumlah *patch* berukuran $P \times P$ [11]. Banyaknya *patch* yang dihasilkan dinyatakan sebagai $N = \frac{HW}{P^2}$, sehingga citra tidak lagi diproses sebagai matriks piksel utuh, melainkan sebagai urutan token visual [11]. Setiap *patch* kemudian diratakan menjadi vektor satu dimensi dan diproyeksikan secara linier ke dalam ruang *embedding* untuk membentuk *patch embedding* [11]. Setelah itu, sebuah *class token* ditambahkan pada awal urutan token sebagai representasi global untuk keperluan klasifikasi, sedangkan *positional embedding* ditambahkan untuk mempertahankan informasi posisi spasial tiap *patch* [11]. Dengan rancangan tersebut, citra dapat diproses oleh rangkaian Transformer *encoder* dengan prinsip yang serupa dengan pengolahan token pada NLP.

Urutan token hasil *embedding* selanjutnya diproses oleh Transformer *encoder* yang tersusun atas blok *multi-head self-attention* dan *multi-layer perceptron* (MLP), disertai *layer normalization* dan *residual connection* [11]. Melalui mekanisme ini, ViT mampu membangun representasi visual yang tidak hanya menangkap detail lokal, tetapi juga keterkaitan global antararea citra

[11]. Karakteristik tersebut menjadikan ViT relevan untuk klasifikasi *deepfake*, karena manipulasi wajah pada *deepfake* sering menghasilkan artefak visual yang tersebar pada berbagai bagian wajah dan tidak selalu terbatas pada pola lokal tertentu. Oleh karena itu, ViT memiliki dasar teoritis yang kuat untuk digunakan sebagai model pada pendekatan spasial dalam penelitian ini[23]. Arsitektur *Vision Transformer* ditunjukkan pada Gambar 2.2.




Gambar 2.2 Arsitektur Vision Transformer (ViT)

2.2.6 VideoMAE

VideoMAE merupakan model *video transformer* berbasis *masked autoencoder* yang dirancang untuk mempelajari representasi video secara efisien melalui *self-supervised pre-training* [12]. Secara konseptual, VideoMAE mengadaptasi prinsip Transformer ke domain video dengan memproses masukan sebagai urutan token visual spasiotemporal, bukan sebagai urutan kata seperti pada *Natural Language Processing* [22]. Rancangan ini juga berkaitan erat dengan perkembangan *Vision Transformer* (ViT), karena *backbone* yang digunakan pada VideoMAE dibangun di atas prinsip *Transformer encoder* yang memproses token visual melalui mekanisme *self-attention* [11], [12]. Dengan demikian, VideoMAE dapat dipahami sebagai perluasan Transformer berbasis citra ke domain video untuk mempelajari hubungan spasial dan temporal secara

bersamaan [11], [12], [22].

Pada arsitektur aslinya, VideoMAE menggunakan rancangan *asymmetric encoder-decoder* [12]. Klip video terlebih dahulu diubah menjadi token spasiotemporal melalui pembagian masukan ke dalam kubus video kecil, kemudian hanya token yang tidak dimask diproses oleh *encoder*, sedangkan *decoder* yang lebih ringan digunakan untuk merekonstruksi token yang disembunyikan [12]. Rancangan ini membuat proses *pre-training* menjadi lebih efisien karena beban komputasi utama difokuskan pada *encoder* yang hanya menerima sebagian token masukan [12]. Selain itu, pendekatan tersebut juga sejalan dengan karakteristik data video yang memiliki redundansi temporal tinggi, sehingga informasi penting masih dapat dipelajari meskipun sebagian besar token masukan disembunyikan [12].



Gambar 2.3 Arsitektur VideoMAE dengan asymmetric encoder-decoder dan tube masking
Sumber: diadaptasi dari Tong dkk. (2022)

Salah satu karakteristik utama VideoMAE adalah penggunaan *tube masking* dengan rasio *masking* yang sangat tinggi, yaitu sekitar 90% hingga 95% [12]. Strategi ini digunakan karena video memiliki korelasi temporal antarbingkai yang kuat, sehingga *masking* biasa berisiko membuat tugas rekonstruksi menjadi terlalu mudah akibat adanya informasi yang berulang pada bingkai tetangga [12]. Dengan *tube masking*, pola *masking* dipertahankan sepanjang dimensi waktu sehingga model terdorong untuk mempelajari representasi spasiotemporal tingkat tinggi, bukan hanya mencocokkan korespondensi lokal antar-*frame* [12]. Pada tahap pembentukan token, VideoMAE tidak membagi masukan sebagai *patch* dua dimensi seperti pada ViT

untuk citra, tetapi sebagai kubus spasiotemporal melalui mekanisme *joint space-time cube embedding*, lalu memodelkan hubungan antar token menggunakan *joint space-time attention* [12]. Rancangan tersebut memungkinkan model menangkap informasi visual statis sekaligus dinamika temporal dalam satu kerangka representasi [12].

Pemodelan ini relevan untuk analisis video *deepfake*, karena bukti manipulasi tidak selalu muncul sebagai artefak spasial pada satu *frame*, tetapi juga dapat muncul sebagai inkonsistensi gerakan atau ketidakwajaran temporal antar-*frame* [7], [15]. Penelitian pada deteksi *deepfake* video juga menunjukkan bahwa pendekatan spasiotemporal berbasis Transformer memiliki potensi yang baik dalam memanfaatkan informasi temporal secara lebih komprehensif [15]. Selain itu, keberadaan VideoMAE sebagai salah satu *baseline* dalam penelitian *deepfake* video menunjukkan bahwa model ini sudah dianggap relevan untuk tugas deteksi dan klasifikasi video manipulasi [16]. Dengan demikian, penggunaan VideoMAE dalam penelitian ini memiliki dasar teoritis yang kuat, baik dari sisi arsitektur model video maupun dari sisi relevansinya pada domain *deepfake* [12], [16], [24].

Pada rancangan asli VideoMAE, *encoder* dan *decoder* digunakan bersama pada tahap *self-supervised pre-training* untuk merekonstruksi token video yang dimask [12]. Namun, pada penelitian ini tidak seluruh mekanisme tersebut digunakan kembali secara utuh. Penelitian ini hanya memanfaatkan *encoder* VideoMAE sebagai *backbone* representasi video, kemudian bagian tersebut di-*fine-tuning* untuk tugas klasifikasi biner *real* dan *fake*. Dengan kata lain, *decoder* rekonstruksi bukan bagian yang digunakan pada tahap klasifikasi dalam penelitian ini, melainkan hanya merupakan komponen pada rancangan asli VideoMAE saat proses *pre-training* [12]. Pendekatan ini sesuai dengan praktik pemanfaatan model hasil *pre-training* pada tugas *downstream*, yaitu menggunakan representasi yang telah dipelajari oleh *encoder* untuk membangun model klasifikasi yang lebih spesifik terhadap domain target [12], [16].

2.2.7 Strided Temporal Sampling

Strided temporal sampling merupakan teknik pemilihan *frame* video secara berkala dengan interval tertentu pada dimensi waktu, sehingga hanya sebagian *frame* yang digunakan sebagai representasi dari satu klip video. Tujuan utama teknik ini adalah mengurangi redundansi temporal pada video, karena *frame-frame* yang berdekatan umumnya memiliki kemiripan visual yang tinggi, sementara informasi gerakan yang relevan masih dapat dipertahankan melalui pemilihan *frame* yang tersebar secara teratur. Dalam konteks pemodelan video, pendekatan ini membantu menekan panjang sekuens masukan dan biaya komputasi, tanpa menghilangkan informasi temporal secara keseluruhan [12], [25], [26].

Pada rancangan VideoMAE, *strided temporal sampling* digunakan sebagai strategi *temporal downsampling* untuk mengatasi redundansi antar-*frame* berurutan [12]. Melalui strategi ini, satu klip video terlebih dahulu diambil dari video asli, kemudian dikompresi menjadi jumlah *frame* yang lebih sedikit melalui proses *temporal sampling* dengan *stride* tertentu [12]. Pendekatan ini membuat model tidak perlu memproses seluruh *frame* dalam satu sekuens secara langsung, tetapi tetap dapat mempelajari pola perubahan visual yang penting pada dimensi waktu [12]. Dengan demikian, *strided temporal sampling* berperan sebagai langkah awal yang penting untuk membentuk representasi video yang lebih ringkas dan efisien sebelum diproses oleh model spasiotemporal [12].

Secara umum, apabila indeks *frame* awal dinyatakan sebagai s , jumlah *frame* keluaran dinyatakan sebagai T , dan nilai *stride* dinyatakan sebagai τ , maka indeks *frame* ke- k yang dipilih pada proses sampling dapat dirumuskan sebagai berikut.

$$i_k = s + (k - 1)\tau, \quad k = 1, 2, \dots, T \quad (\text{Rumus 2.2})$$

Berdasarkan definisi tersebut, panjang klip minimum yang diperlukan

untuk menghasilkan T frame dengan *stride* τ dirumuskan sebagai berikut.

$$L = i_T - i_1 + 1 \quad (\text{Rumus 2.3})$$

Karena $i_1 = s$ dan $i_T = s + (T - 1)\tau$, maka bentuk sederhananya menjadi berikut.

$$L = (T - 1)\tau + 1 \quad (\text{Rumus 2.4})$$

Rumus tersebut menunjukkan bahwa panjang klip minimum ditentukan oleh jumlah *frame* keluaran dan interval sampling yang digunakan. Dengan demikian, semakin besar nilai *stride*, semakin panjang klip awal yang dibutuhkan untuk membentuk representasi temporal dengan jumlah *frame* keluaran yang sama.

Dalam penelitian ini, satu sekuens wajah dapat menghasilkan lebih dari satu klip turunan dengan panjang tetap. Jika panjang satu sekuens dinyatakan sebagai N frame dan panjang satu klip dinyatakan sebagai L , maka jumlah klip turunan yang dapat dibentuk dirumuskan sebagai berikut.

$$C = \left\lfloor \frac{N}{L} \right\rfloor \quad (\text{Rumus 2.5})$$

Rumus tersebut merupakan pembagian bulat ke bawah, sehingga hanya klip penuh yang digunakan. Adapun sisa *frame* yang tidak cukup untuk membentuk satu klip penuh dirumuskan sebagai berikut.

$$R = N - C \cdot L \quad (\text{Rumus 2.6})$$

Agar pembentukan klip tetap berpusat di tengah sekuens, sisa *frame* tersebut dibuang secara seimbang pada sisi kiri dan kanan. Besar *frame* yang dibuang pada masing-masing sisi dirumuskan sebagai berikut.

$$d_{\text{kiri}} = \left\lfloor \frac{R}{2} \right\rfloor, \quad d_{\text{kanan}} = \left\lceil \frac{R}{2} \right\rceil \quad (\text{Rumus 2.7})$$

Melalui formulasi tersebut, *strided temporal sampling* tidak hanya dipahami sebagai teknik pemilihan *frame* secara berkala, tetapi juga sebagai dasar matematis untuk menentukan panjang klip, jumlah klip turunan, serta mekanisme pembuangan *frame* sisa secara simetris. Pada penelitian ini, formulasi tersebut digunakan sebagai landasan teoretis dalam tahap *preprocessing* pada Bab III.

2.2.8 Evaluasi Model

Evaluasi model merupakan tahap yang bertujuan untuk menilai sejauh mana model mampu melakukan klasifikasi video *deepfake* secara tepat pada data uji. Pada penelitian ini, evaluasi dilakukan untuk mengukur kemampuan model dalam membedakan video ke dalam dua kelas, yaitu *real* dan *fake*, sesuai dengan rumusan masalah dan batasan penelitian yang telah ditetapkan. Oleh karena itu, evaluasi tidak hanya dilakukan dengan satu metrik, tetapi menggunakan beberapa ukuran yang saling melengkapi, yaitu *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan *Area Under Curve – Receiver Operating Characteristic* (AUC-ROC).

2.2.8.1 Confusion Matrix

Confusion matrix merupakan representasi tabel yang digunakan untuk membandingkan label sebenarnya (*ground truth*) dengan hasil prediksi model [27]. Pada klasifikasi biner, *confusion matrix* terdiri atas empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Dalam konteks penelitian ini, kelas positif didefinisikan sebagai kelas *fake*. Dengan demikian, *True Positive* merepresentasikan jumlah video *deepfake* yang berhasil diprediksi benar sebagai *fake*, *True Negative* merepresentasikan jumlah video *real* yang diprediksi benar sebagai *real*, *False Positive* merepresentasikan jumlah video *real* yang salah diprediksi sebagai *fake*, sedangkan *False Negative* merepresentasikan jumlah video *deepfake* yang

salah diprediksi sebagai *real* [27], [28]. Informasi ini penting karena tidak hanya menunjukkan jumlah prediksi yang benar, tetapi juga memperlihatkan pola kesalahan model pada masing-masing kelas. Struktur *confusion matrix* ditunjukkan pada Tabel 2.2.

Tabel 2.2 *Confusion Matrix*

Actual \ Predicted	Positive	Negative
<i>Positive</i>	TP	FN
<i>Negative</i>	FP	TN

Keterangan:

- TP (*True Positive*): jumlah prediksi positif yang benar.
- TN (*True Negative*): jumlah prediksi negatif yang benar.
- FP (*False Positive*): jumlah prediksi positif yang salah.
- FN (*False Negative*): jumlah prediksi negatif yang salah.

2.2.8.2 Accuracy

Accuracy merupakan metrik evaluasi yang mengukur proporsi prediksi benar terhadap seluruh sampel yang diuji [27]. Metrik ini memberikan gambaran umum tentang seberapa baik model melakukan klasifikasi secara keseluruhan. Namun, *accuracy* saja tidak selalu cukup untuk menggambarkan performa model secara lengkap, terutama ketika kesalahan pada salah satu kelas memiliki konsekuensi yang lebih penting untuk dianalisis [27], [28]. Secara matematis, *accuracy* dirumuskan sebagai berikut.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (\text{Rumus 2.8})$$

2.2.8.3 Precision, Recall, dan F1-Score

Precision merupakan metrik yang mengukur tingkat ketepatan prediksi pada kelas positif, yaitu seberapa banyak sampel yang diprediksi sebagai kelas positif benar-benar termasuk ke dalam kelas tersebut [27], [28]. Pada penelitian

ini, *precision* menunjukkan seberapa tepat model ketika memprediksi sebuah video sebagai *fake*. Secara matematis, *precision* dapat dirumuskan sebagai berikut.

$$Precision = \frac{TP}{TP + FP} \quad (\text{Rumus 2.9})$$

Recall merupakan metrik yang mengukur kemampuan model dalam menangkap seluruh sampel positif yang sebenarnya ada [27], [28]. Dalam penelitian ini, *recall* menunjukkan seberapa banyak video *deepfake* yang berhasil dideteksi dengan benar oleh model. Secara matematis, *recall* dirumuskan sebagai berikut.

$$Recall = \frac{TP}{TP + FN} \quad (\text{Rumus 2.10})$$

Sementara itu, *F1-score* merupakan rata-rata harmonik dari *precision* dan *recall*, sehingga digunakan untuk memberikan ukuran yang lebih seimbang antara ketepatan prediksi positif dan sensitivitas model terhadap kelas positif [27], [28]. Metrik ini penting ketika evaluasi tidak cukup hanya melihat satu sisi performa saja, melainkan memerlukan keseimbangan antara kemampuan mendeteksi video *deepfake* dan kemampuan menghindari prediksi positif yang salah. Secara matematis, *F1-score* dirumuskan sebagai berikut.

$$F1\text{-score} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (\text{Rumus 2.11})$$

2.2.8.4 Area Under Curve – Receiver Operating Characteristic (AUC-ROC)

Receiver Operating Characteristic (ROC) merupakan kurva yang digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas positif dan kelas negatif pada berbagai nilai ambang keputusan (*threshold*) [28], [29]. Kurva ROC dibentuk dari hubungan antara *True Positive Rate* (TPR) dan

False Positive Rate (FPR). *True Positive Rate* menunjukkan proporsi sampel positif yang berhasil dideteksi dengan benar, sedangkan *False Positive Rate* menunjukkan proporsi sampel negatif yang salah diprediksi sebagai positif [29].

Secara matematis, *True Positive Rate* dirumuskan sebagai berikut.

$$TPR = \frac{TP}{TP + FN} \quad (\text{Rumus 2.12})$$

Adapun *False Positive Rate* dirumuskan sebagai berikut.

$$FPR = \frac{FP}{FP + TN} \quad (\text{Rumus 2.13})$$


Sementara itu, *Area Under Curve* (AUC) merupakan luas area di bawah kurva ROC yang digunakan untuk merepresentasikan kemampuan diskriminatif model secara keseluruhan [29]. Nilai AUC berada pada rentang 0 sampai 1, di mana nilai yang semakin mendekati 1 menunjukkan bahwa model memiliki kemampuan yang semakin baik dalam membedakan video *real* dan *fake* [29]. Dalam penelitian ini, AUC-ROC digunakan untuk melengkapi metrik berbasis *confusion matrix*, sehingga evaluasi model tidak hanya bergantung pada satu nilai ambang keputusan, tetapi juga mempertimbangkan performa model pada berbagai kemungkinan *threshold* [28], [29].

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Alur penelitian dalam tugas akhir ini divisualisasikan melalui sebuah diagram alir yang menjelaskan setiap tahapan proses penelitian, mulai dari identifikasi masalah hingga tahap akhir penyelesaian. Ilustrasi keseluruhan proses tersebut dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Berdasarkan alur penelitian yang ditampilkan pada Gambar 3.1, subbab berikut akan menjabarkan secara rinci setiap langkah yang dilakukan dalam penelitian ini.

3.2.1 Identifikasi Masalah

Tahap identifikasi masalah dalam penelitian ini berfokus pada kerentanan sistem deteksi *deepfake* pada skenario dunia nyata (*in-the-wild*). Pendekatan deteksi konvensional yang berbasis analisis spasial pada tingkat *frame* diketahui dapat mengalami penurunan kinerja seiring meningkatnya kualitas visual

manipulasi *deepfake* [5], [30]. Sebagai alternatif, pendekatan spasiotemporal pada tingkat video secara teoretis mampu mengatasi keterbatasan tersebut melalui pemodelan hubungan antar-*frame* dan pendeteksian anomali gerakan [7]. Namun, pendekatan ini juga menghadapi tantangan, karena jejak artefak temporal sering kali mengalami degradasi akibat kompresi tinggi, distorsi resolusi, dan kualitas video yang tidak konsisten pada data dunia nyata [9], [31]. Kondisi tersebut menunjukkan bahwa penambahan informasi temporal belum tentu menghasilkan sistem deteksi yang lebih tangguh dibandingkan pendekatan spasial murni [8]. Berdasarkan permasalahan tersebut, penelitian ini merancang eksperimen komparatif secara objektif antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE menggunakan dataset WildDeepfake.


3.2.2 Studi Literatur

Tahap kedua dalam penelitian ini adalah studi literatur, yaitu kajian terhadap berbagai sumber ilmiah yang relevan dengan topik penelitian. Studi literatur ini bertujuan untuk memahami konsep dasar, pendekatan, dan temuan penelitian terdahulu yang berkaitan dengan deteksi *deepfake*, khususnya pada pendekatan spasial dan spasiotemporal, serta tantangan klasifikasi video pada kondisi dunia nyata.

Pada tahap ini, dilakukan penelaahan terhadap penelitian-penelitian yang membahas efektivitas ekstraksi artefak visual statis pada tingkat *frame* [2], [5], pentingnya analisis inkonsistensi temporal antar-*frame* pada tingkat video [7], serta pengaruh kompresi dan variasi kualitas visual pada dataset WildDeepfake [9]. Hasil studi literatur tersebut digunakan sebagai landasan konseptual untuk mengidentifikasi celah penelitian dan menyusun rancangan eksperimen komparatif antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE.

3.2.3 Pengumpulan Data

Tahap pengumpulan data dalam penelitian ini dilakukan menggunakan *dataset* publik *WildDeepfake*. *Dataset* ini diperkenalkan oleh Zi dkk. [9] sebagai *dataset deepfake* yang merepresentasikan kondisi dunia nyata atau *in-the-wild*, sehingga dinilai sesuai untuk mengevaluasi ketahanan model klasifikasi dibandingkan *dataset* yang disusun dalam lingkungan yang lebih terkontrol. *WildDeepfake* memiliki keragaman yang tinggi, mencakup variasi jumlah subjek dalam satu adegan, latar belakang, pose wajah, ekspresi, pencahayaan, serta variasi kompresi, resolusi, dan format video. Karakteristik tersebut menjadikan *WildDeepfake* relevan untuk penelitian ini, karena tujuan utama penelitian adalah membandingkan pendekatan spasial dan spatiotemporal pada skenario *deepfake* dunia nyata yang menantang [9].



Gambar 3.2 Contoh sampel citra wajah kelas *real* dan *fake* pada dataset *WildDeepfake*
Sumber: *WildDeepfake* (Zi dkk., 2024)

Secara keseluruhan, *WildDeepfake* terdiri atas 707 video yang diproses menjadi 7.314 sekuens wajah dengan total 1.180.099 citra wajah. Dari jumlah tersebut, terdapat 3.805 sekuens wajah kelas *real* dan 3.509 sekuens wajah kelas *fake*. Selain itu, *dataset* ini telah dibagi menjadi 6.508 sekuens data latih dan 806 sekuens data uji. Pembagian tersebut dilakukan berdasarkan kemiripan antarsekuens agar data latih dan data uji memiliki perbedaan yang memadai, sehingga evaluasi model dapat dilakukan secara lebih objektif [9]. Dengan demikian, penelitian ini menggunakan unit data pada tingkat *face sequence*, bukan video mentah secara langsung. Pada tahap *preprocessing* berikutnya,

setiap *face sequence* kemudian diolah lebih lanjut menjadi klip turunan sebagai unit data eksperimen.

Berdasarkan hasil pencatatan jumlah *frame* pada setiap sekuens, *dataset* yang digunakan dalam penelitian ini menunjukkan variasi panjang sekuens yang cukup tinggi. Secara keseluruhan, panjang sekuens berada pada rentang 51 hingga 29.008 *frame*, dengan rata-rata 161,35 *frame* dan median 105 *frame*. Temuan ini menunjukkan bahwa *WildDeepfake* tidak hanya beragam dari sisi kualitas visual, tetapi juga tidak seragam dari sisi panjang temporal setiap sekuens. Variasi tersebut penting untuk dicatat karena menunjukkan bahwa data yang digunakan merepresentasikan kondisi distribusi dunia nyata yang heterogen.

Jika ditinjau berdasarkan subset dan kelas, terdapat perbedaan karakteristik panjang sekuens antara kelas *real* dan *fake*. Pada data latih, kelas *fake* memiliki rata-rata panjang sekuens 204,12 *frame*, sedangkan kelas *real* memiliki rata-rata 112,02 *frame*. Pada data uji, kelas *fake* memiliki rata-rata 260,98 *frame*, sedangkan kelas *real* memiliki rata-rata 148,13 *frame*. Secara umum, sekuens pada kelas *fake* cenderung lebih panjang dibandingkan kelas *real*, baik pada data latih maupun data uji. Ringkasan statistik tersebut disajikan pada Tabel 3.1.

Tabel 3.1 Statistik panjang sekuens berdasarkan subset dan kelas

Split	Kelas	Jumlah sekuens	Total <i>frame</i>	Rata-rata <i>frame</i>	Median	Minimum	Maksimum
train	<i>real</i>	3.409	381.876	112,02	85	51	3.572
train	<i>fake</i>	3.099	632.561	204,12	125	51	29.008
test	<i>real</i>	396	58.659	148,13	86	51	3.655
test	<i>fake</i>	410	107.003	260,98	144	52	3.418

Selain *WildDeepfake*, penelitian ini juga menggunakan *dataset Celeb-DF v2* sebagai *dataset* evaluasi eksternal [19]. *Dataset* ini tidak digunakan dalam proses pelatihan, validasi, maupun pemilihan model. *Celeb-DF v2* hanya digunakan pada tahap evaluasi lintas-*dataset* secara *zero-shot* untuk mengukur kemampuan generalisasi model ketika dihadapkan pada distribusi data yang

berbeda dari *dataset* sumber. Dengan demikian, seluruh proses *fine-tuning* model tetap dilakukan menggunakan *WildDeepfake*, sedangkan *Celeb-DF v2* digunakan untuk menguji ketahanan model terhadap pergeseran domain data.

3.2.4 Preprocessing Data

Tahap preprocessing data pada penelitian ini dilakukan untuk menyiapkan dataset *WildDeepfake* agar sesuai dengan kebutuhan eksperimen klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE. Sebelum dipublikasikan, *WildDeepfake* telah melalui serangkaian preprocessing awal oleh Zi dkk. [9]. Proses tersebut meliputi pengumpulan video *deepfake* dari berbagai situs video, penyaringan video yang tidak memenuhi kriteria, deteksi area wajah menggunakan MTCNN, ekstraksi fitur wajah menggunakan MobileNetV2, serta *face alignment* menggunakan *facial landmark* dari dlib. Pada tahap anotasi, setiap sekuens wajah diberi label *real*, *fake*, atau *unknown* oleh tiga anotator, kemudian sekuens dengan label tidak konsisten atau masuk kategori *unknown* dibuang dari dataset akhir [9]. Dengan demikian, dataset *WildDeepfake* yang digunakan dalam penelitian ini merupakan hasil pengolahan dan anotasi yang telah dilakukan secara sistematis, sehingga siap digunakan sebagai sumber data pada tahap preprocessing penelitian ini.

Berdasarkan kondisi tersebut, penelitian ini tidak lagi mencakup tahap deteksi wajah, ekstraksi fitur wajah, maupun *face alignment* dari video mentah. Selain itu, citra wajah pada dataset sumber telah tersedia dalam ukuran 224×224 piksel, sehingga penelitian ini juga tidak melakukan proses *resize* tambahan. Oleh karena itu, preprocessing pada penelitian ini difokuskan pada penyiapan struktur data dan pembentukan masukan model, yang meliputi ekstraksi dataset, pembentukan klip 46 frame, *strided temporal sampling*, *data splitting*, augmentasi data, dan normalisasi *frame* hasil sampling. Rangkaian tahapan tersebut disusun agar kedua pendekatan menggunakan evidensi visual

dasar yang sepadan, sehingga perbandingan kinerja model dapat dilakukan secara lebih adil dan terarah.

3.2.4.1 Ekstraksi Dataset

Tahap awal preprocessing pada penelitian ini dilakukan melalui proses ekstraksi dataset WildDeepfake dan penataan ulang struktur direktori hasil ekstraksi. Dataset yang digunakan tersimpan dalam direktori utama *deepfake_in_the_wild* yang terbagi ke dalam empat subset, yaitu *real_train*, *real_test*, *fake_train*, dan *fake_test*. Pada masing-masing subset tersebut terdapat sejumlah berkas terkompresi dengan format *.tar.gz*, seperti *0.tar.gz*, *1.tar.gz*, *2.tar.gz*, dan seterusnya.

Sebelum proses ekstraksi dilakukan, setiap berkas *.tar.gz* telah memuat struktur data internal yang terdiri atas folder kelas dan sejumlah folder sekuens wajah. Sebagai contoh, pada subset *real_train*, berkas *0.tar.gz* memuat folder *real* yang berisi folder-folder seperti *0*, *1*, *2*, dan seterusnya. Setiap folder tersebut merepresentasikan satu *face sequence*, sedangkan citra-citra di dalamnya, seperti *0.png*, *1.png*, *2.png*, dan seterusnya, merupakan kumpulan *frame* wajah hasil ekstraksi dari video. Nama berkas citra menunjukkan urutan *frame* pada video asli, sehingga informasi temporal tetap dapat dipertahankan untuk kebutuhan pemrosesan lebih lanjut. Struktur folder dataset WildDeepfake sebelum proses ekstraksi ditunjukkan pada Gambar 3.3.

```

deepfake_in_the_wild/
|-- real_train/
|   |-- 0.tar.gz
|   |   |-- real/
|   |   |   |-- 0/
|   |   |   |   |-- 0.png
|   |   |   |   |-- 1.png
|   |   |   |   |-- 2.png
|   |   |   |   |-- ...
|   |   |   |-- 1/
|   |   |   |-- 2/
|   |   |   |-- ...
|   |-- 1.tar.gz
|   |-- 2.tar.gz
|   |-- ...
|-- real_test/
|   |-- 0.tar.gz
|   |-- ...
|-- fake_train/
|   |-- 0.tar.gz
|   |-- ...
|-- fake_test/
|   |-- 0.tar.gz
|   |-- ...

```

Gambar 3.3 Struktur folder dataset WildDeepfake sebelum ekstraksi

Pada penelitian ini, seluruh berkas *.tar.gz* diekstraksi terlebih dahulu sesuai subset asalnya. Setelah proses ekstraksi selesai, struktur data disusun ulang agar lebih sistematis dan mudah digunakan pada tahap berikutnya. Folder hasil ekstraksi dari setiap arsip, misalnya *0*, *1*, *2*, dan seterusnya, ditempatkan langsung di bawah subset masing-masing, seperti *real_train*, *real_test*, *fake_train*, dan *fake_test*. Di dalam setiap folder hasil ekstraksi tersebut tersimpan kembali folder-folder sekuens wajah yang berisi kumpulan citra *frame*. Dengan demikian, satu folder hasil ekstraksi merepresentasikan satu kelompok data dari satu arsip, sedangkan folder-folder di dalamnya tetap mempertahankan unit sekuens sebagaimana pada dataset sumber. Struktur folder dataset WildDeepfake setelah proses ekstraksi ditunjukkan pada Gambar 3.4.


```

deepfake_in_the_wild/
|-- real train/
|   |-- 0/
|   |   |-- 0/
|   |   |   |-- 0.png
|   |   |   |-- 1.png
|   |   |   |-- 2.png
|   |   |   |-- ...
|   |   |-- 1/
|   |   |-- 2/
|   |   |-- ...
|   |-- 1/
|   |-- 2/
|   |-- ...
|-- real test/
|   |-- 0/
|   |-- ...
|-- fake train/
|   |-- 0/
|   |-- ...
|-- fake test/
|   |-- 0/
|   |-- ...

```

Gambar 3.4 Struktur folder dataset WildDeepfake setelah ekstraksi

Penyusunan ulang struktur data ini dilakukan untuk memudahkan proses pembacaan data pada tahap berikutnya. Dengan struktur yang telah disusun ulang tersebut, proses *data loading* dan pelacakan identitas sekuens dapat dilakukan secara lebih teratur dan konsisten. Melalui tahapan ini, dataset berada dalam bentuk yang lebih siap untuk digunakan pada proses *data splitting* dan pembentukan klip pada tahap berikutnya.

3.2.4.2 Pembentukan Klip 46 Frame

Setelah proses ekstraksi dataset selesai, tahap berikutnya adalah membentuk klip berdurasi tetap dari setiap *face sequence* pada dataset WildDeepfake. Pada penelitian ini, setiap sekuens diproses menjadi satu atau lebih klip turunan yang masing-masing terdiri atas 46 *frame*. Tahap ini dilakukan sebelum *data splitting* dan *strided temporal sampling*, karena unit data yang digunakan pada tahapan berikutnya bukan lagi sekuens asal, melainkan klip turunan hasil segmentasi sekuens.

Penetapan panjang klip didasarkan pada konfigurasi masukan model spasiotemporal yang menggunakan 16 *frame*. Pada penelitian ini, jumlah *frame* keluaran dinyatakan sebagai $T = 16$ dan nilai *stride* dinyatakan sebagai $\tau = 3$.

Dengan menggunakan Rumus 2.4, diperoleh panjang klip minimum $L = 46$. Dengan demikian, setiap klip turunan pada penelitian ini dibentuk sepanjang 46 *frame*. Pemilihan *stride* 3 dilakukan karena panjang minimum sekuens pada dataset penelitian adalah 51 *frame*, sehingga konfigurasi ini masih dapat diterapkan secara konsisten pada seluruh data. Sebaliknya, apabila digunakan *stride* 4, dengan menggunakan Rumus 2.4 akan diperoleh kebutuhan panjang klip sebesar 61 *frame*, sehingga tidak lagi sesuai dengan panjang minimum sekuens pada dataset.


Setelah panjang klip ditetapkan, jumlah klip turunan dari setiap sekuens ditentukan berdasarkan panjang sekuens asal. Jika panjang satu sekuens dinyatakan sebagai N dan panjang klip dinyatakan sebagai L , maka jumlah klip turunan dihitung dengan menggunakan Rumus 2.5. Adapun sisa *frame* yang tidak cukup untuk membentuk satu klip penuh dihitung menggunakan Rumus 2.6, sedangkan pembuangan *frame* sisa secara simetris pada sisi kiri dan kanan sekuens dilakukan dengan menggunakan Rumus 2.7. Dengan strategi tersebut, bagian tengah sekuens diprioritaskan sebagai area pembentukan klip, sedangkan *frame* berlebih di awal dan akhir sekuens tidak digunakan.

Sebagai contoh, pada sekuens dengan $N = 50$ *frame* dan $L = 46$, dengan menggunakan Rumus 2.5 diperoleh jumlah klip turunan $C = 1$. Selanjutnya, dengan menggunakan Rumus 2.6 diperoleh sisa *frame* $R = 4$. Karena sisa *frame* dibuang secara seimbang menggunakan Rumus 2.7, maka dua *frame* dibuang di awal dan dua *frame* dibuang di akhir. Dengan demikian, klip yang digunakan adalah *frame* ke-3 hingga *frame* ke-48. Ilustrasi proses ini ditunjukkan pada Gambar 3.5.



Gambar 3.5 Ilustrasi pembentukan klip 46 frame berpusat di tengah pada sekuens 50 frame

Pada sekuens yang lebih panjang, satu sekuens dapat menghasilkan lebih dari satu klip turunan. Sebagai contoh, pada sekuens dengan $N = 150$ frame dan $L = 46$, dengan menggunakan Rumus 2.5 diperoleh jumlah klip turunan $C = 3$. Selanjutnya, dengan menggunakan Rumus 2.6 diperoleh sisa frame $R = 12$. Karena sisa frame dibuang secara seimbang menggunakan Rumus 2.7, maka enam frame dibuang di awal dan enam frame dibuang di akhir. Rentang frame yang digunakan menjadi frame ke-7 hingga frame ke-144, yang kemudian dibagi menjadi tiga klip turunan, yaitu frame 7–52, frame 53–98, dan frame 99–144. Ilustrasi proses ini ditunjukkan pada Gambar 3.6.



Gambar 3.6 Ilustrasi pembentukan klip 46 frame berpusat di tengah pada sekuens 150 frame

Setiap klip turunan selanjutnya disimpan sebagai folder independen dengan format penamaan *ID sekuens_ID klip*, misalnya *0_0*, *0_1*, *0_2*, dan seterusnya. Indeks pertama menunjukkan identitas sekuens asal, sedangkan indeks kedua menunjukkan urutan klip yang dihasilkan dari sekuens tersebut. Namun, folder klip turunan tetap ditempatkan di dalam folder grup hasil ekstraksi sesuai arsip asalnya. Sebagai contoh, struktur *deepfake_in_the_wild/real_train/0/0_0/* menunjukkan bahwa *0* merupakan folder grup hasil ekstraksi arsip pada subset *real_train*, sedangkan *0_0* merupakan klip turunan pertama yang berasal dari sekuens *0* pada grup tersebut.

Struktur folder setelah pembentukan klip dapat diilustrasikan sebagai berikut.

```

deepfake_in_the_wild/
|-- real_train/
|   |-- 0/
|   |   |-- 0_0/
|   |   |   |-- 7.png
|   |   |   |-- 8.png
|   |   |   |-- 9.png
|   |   |   '--- ...
|   |   |-- 0_1/
|   |   |   |-- 53.png
|   |   |   |-- 54.png
|   |   |   |-- 55.png
|   |   |   '--- ...
|   |   '--- ...
|   |-- 1/
|   |   '--- ...
|   '--- ...
|-- real_test/
|   |-- 0/
|   |   |-- 0_0/
|   |   '--- ...
|   '--- ...
|-- fake_train/
|   |-- 0/
|   |   |-- 0_0/
|   |   '--- ...
|   '--- ...
'--- fake_test/
    |-- 0/
    |   |-- 0_0/
    |   '--- ...
    '--- ...

```


Gambar 3.7 Struktur folder dataset WildDeepfake setelah proses pembentukan klip 46 *frame*

Pada struktur tersebut, nama file *frame* tetap mempertahankan indeks aslinya agar keterlacakan posisi temporal terhadap sekuens asal tetap terjaga. Dengan demikian, setelah tahap ini selesai, unit data penelitian tidak lagi berupa sekuens asal, tetapi berupa klip turunan 46 *frame* yang telah disusun secara seragam dan siap digunakan pada tahap berikutnya.

3.2.4.3 Strided Temporal Sampling

Setelah klip turunan 46 *frame* berhasil dibentuk, tahap berikutnya adalah *strided temporal sampling* untuk menghasilkan masukan akhir model. Pada tahap ini, setiap klip 46 *frame* dipadatkan menjadi 16 *frame* dengan *stride* 3.

Sebagai ilustrasi, apabila satu klip turunan terdiri atas *frame* ke-1 hingga *frame* ke-46, maka dengan menggunakan Rumus 2.2 diperoleh *frame* terpilih ke-1, 4, 7, 10, 13, 16, 19, 22, 25, 28, 31, 34, 37, 40, 43, dan 46. Contoh ini menunjukkan bahwa *strided temporal sampling* tidak mengambil *frame* secara berurutan, melainkan memilih *frame* dengan interval tetap. Dengan strategi tersebut, informasi temporal masih tetap tercakup, tetapi jumlah *frame* yang diproses menjadi lebih sedikit dan lebih efisien.



Gambar 3.8 Ilustrasi *strided temporal sampling* ($T = 16$, $\tau = 3$)

Perbedaan antara pengambilan *frame* berurutan dan *strided temporal sampling* ditunjukkan pada Gambar 3.8. Dalam penelitian ini, hasil *strided temporal sampling* dijadikan sebagai evidensi visual dasar bersama untuk kedua jalur eksperimen, yaitu pendekatan spasial dan pendekatan spatiotemporal. Dengan demikian, kedua pendekatan tidak dibangun dari kumpulan citra yang berbeda, melainkan dari *frame-frame* hasil sampling yang sama.

3.2.4.4 Data Splitting

Pada penelitian ini, pemisahan data mengikuti pembagian resmi yang telah tersedia pada dataset WildDeepfake, yaitu subset *real_train*, *fake_train*, *real_test*, dan *fake_test*. Dengan demikian, seluruh klip yang berasal dari direktori *real_test* dan *fake_test* digunakan sebagai data pengujian akhir, sedangkan klip

yang berasal dari direktori *real_train* dan *fake_train* digunakan sebagai sumber data untuk proses pelatihan dan validasi [9].

Selanjutnya, subset data latih dipecah kembali menjadi data latih dan data validasi dengan perbandingan 80:20. Rasio ini dipilih karena memberikan proporsi data latih yang cukup besar, tetapi tetap menyediakan data validasi yang memadai untuk memantau performa model selama pelatihan [32], [33].

3.2.4.5 Augmentasi Data

Untuk meningkatkan keragaman data pelatihan dan mengurangi risiko *overfitting*, augmentasi hanya diterapkan pada data latih, sedangkan data validasi dan data uji tidak diberikan augmentasi agar evaluasi model tetap objektif. Dalam penelitian ini, augmentasi dilakukan setelah tahap *data splitting* dan *strided temporal sampling*, sehingga transformasi hanya diterapkan pada klip hasil sampling yang berasal dari subset pelatihan.

Transformasi yang diterapkan meliputi *horizontal flip* untuk menambah keragaman orientasi wajah, penyesuaian kecerahan dan kontras (*color jitter*) untuk mensimulasikan variasi pencahayaan pada video dunia nyata, penambahan *Gaussian noise* untuk meniru derau akibat proses perekaman dan kompresi, serta *random resized crop* agar model dapat mempelajari pola visual pada area wajah yang sedikit berbeda tanpa menghilangkan konteks utama. Seluruh transformasi diterapkan secara konsisten pada semua *frame* dalam satu klip dengan parameter yang sama, sehingga struktur visual wajah dan koherensi temporal antar-*frame* tetap terjaga. Dengan demikian, augmentasi yang digunakan dapat meningkatkan keragaman data tanpa mengubah karakteristik visual penting yang menjadi dasar klasifikasi video *deepfake*.

3.2.4.6 Normalisasi Frame

Normalisasi dilakukan agar distribusi nilai piksel menjadi lebih terstandarisasi dan sesuai dengan karakteristik model *pretrained* yang digunakan.

Tahap ini penting untuk menjaga stabilitas proses pelatihan serta membantu model dalam mempelajari pola visual secara lebih efektif.

Pada pendekatan spasial, setiap *frame* hasil *strided temporal sampling* diperlakukan sebagai citra tunggal yang akan diberikan ke model Vision Transformer (ViT). Sebelum digunakan, nilai piksel pada setiap *frame* terlebih dahulu diubah ke rentang $[0, 1]$, kemudian dinormalisasi menggunakan parameter $mean = [0.5, 0.5, 0.5]$ dan $standard deviation = [0.5, 0.5, 0.5]$. Parameter ini mengikuti konfigurasi preprocessing bawaan dari model *ViT-Base*¹ pada pustaka *timm* yang digunakan dalam penelitian ini.

Sementara itu, pada pendekatan spasiotemporal, kumpulan *frame* hasil *strided temporal sampling* dipertahankan sebagai satu klip yang akan digunakan oleh model VideoMAE. Setiap *frame* dalam klip juga dinormalisasi dengan terlebih dahulu mengubah nilai piksel ke rentang $[0, 1]$, kemudian menerapkan parameter $mean = [0.5, 0.5, 0.5]$ dan $standard deviation = [0.5, 0.5, 0.5]$. Parameter ini mengikuti konfigurasi VideoMAEImageProcessor² pada implementasi yang digunakan dalam penelitian ini.

3.2.5 Rancangan Model

Pada tahap ini, rancangan model disusun untuk membandingkan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada tugas klasifikasi video *deepfake*. Kedua model menggunakan *frame-frame* hasil *strided temporal sampling* yang sama sebagai evidensi visual dasar, sehingga perbedaan performa yang diperoleh lebih merefleksikan perbedaan kemampuan model dalam memanfaatkan informasi spasial dan temporal. Pada pendekatan spasial, masukan diproses pada tingkat *frame* dan hasilnya diagregasi pada tingkat klip, sedangkan pada pendekatan spasiotemporal, masukan diproses langsung pada tingkat klip.

¹https://huggingface.co/timm/vit_base_patch16_224_augreg2_in21k_ft_in1k


²https://github.com/huggingface/transformers/blob/v5.5.0/src/transformers/models/videmae/image_processing_videmae.py

Rancangan ini memungkinkan evaluasi komparatif yang lebih objektif terhadap kedua pendekatan pada data *deepfake in-the-wild*.

3.2.5.1 Rancangan Model Spasial Berbasis Vision Transformer (ViT)

Model Vision Transformer (ViT) yang diperkenalkan oleh Dosovitskiy dkk. pada tahun 2021 merupakan arsitektur berbasis Transformer untuk tugas klasifikasi citra yang memproses citra sebagai urutan *image patch* [11]. Berbeda dengan pendekatan konvolusional yang menekankan operasi lokal, ViT memanfaatkan mekanisme *self-attention* untuk memodelkan hubungan global antarbagian citra, sehingga mampu menangkap keterkaitan visual yang tersebar pada berbagai area masukan [11]. Dalam penelitian ini, ViT-Base digunakan sebagai model pada pendekatan spasial untuk melakukan klasifikasi video *deepfake* berdasarkan informasi visual statis pada tingkat *frame*. Model tersebut diinisialisasi menggunakan bobot hasil pelatihan pada ImageNet-21K, kemudian disesuaikan lebih lanjut untuk tugas klasifikasi biner *real* dan *fake*.

Masukan model berupa *frame* hasil *strided temporal sampling* berukuran 224×224 piksel. Pada jalur spasial, setiap *frame* diproses sebagai citra tunggal. Sesuai dengan rancangan ViT, citra masukan terlebih dahulu dibagi menjadi *patch* berukuran 16×16 piksel. Dengan konfigurasi tersebut, satu citra 224×224 menghasilkan $14 \times 14 = 196$ *patch*. Setiap *patch* kemudian diratakan dan diproyeksikan secara linear untuk membentuk representasi vektor yang disebut *patch embedding* [11]. Setelah proses tersebut, sebuah *class token* ditambahkan pada awal urutan token, sedangkan *position embedding* disisipkan untuk mempertahankan informasi posisi spasial setiap *patch* dalam citra [11]. Dengan demikian, jumlah token yang diproses oleh model untuk setiap *frame* adalah 197 token, yaitu 196 token *patch* dan 1 *class token*. Ilustrasi arsitektur model spasial berbasis ViT yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.9.



Gambar 3.9 Arsitektur model spasial berbasis Vision Transformer (ViT)

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. Pada konfigurasi ViT-Base, encoder terdiri atas 12 blok Transformer dengan dimensi embedding sebesar 768 dan 12 *attention head* pada mekanisme *multi-head self-attention* [11]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection* [11]. Melalui susunan ini, model dapat mempelajari hubungan antar-*patch* secara menyeluruh, sehingga representasi visual yang dihasilkan tidak hanya menangkap detail lokal, tetapi juga struktur global wajah yang berpotensi mengalami manipulasi.

Dalam rancangan penelitian ini, setiap *frame* hasil *strided temporal sampling* diberikan ke *backbone* ViT untuk mengekstraksi fitur spasial. Representasi keluaran yang terkait dengan *class token* pada akhir encoder kemudian diteruskan ke lapisan klasifikasi biner untuk menghasilkan probabilitas kelas *real* dan *fake*. Dengan rancangan tersebut, unit prediksi dasar pada pendekatan spasial berada pada tingkat *frame*. Namun, karena unit data pada penelitian ini ditetapkan pada tingkat klip turunan, prediksi akhir tidak ditentukan dari satu *frame* secara individual. Untuk setiap klip yang terdiri atas 16 *frame*

hasil sampling, model terlebih dahulu menghasilkan probabilitas prediksi pada setiap *frame*, kemudian seluruh probabilitas tersebut diagregasi menggunakan rata-rata probabilitas untuk memperoleh satu keputusan akhir pada tingkat klip. Strategi ini dipilih agar pendekatan spasial tetap merepresentasikan analisis visual statis pada tingkat *frame*, tetapi hasil akhirnya tetap dapat dibandingkan secara langsung dengan pendekatan spasiotemporal yang juga menghasilkan prediksi pada tingkat klip.

Rancangan tersebut konsisten dengan tujuan eksperimen komparatif yang menggunakan evidensi visual dasar yang sama pada kedua jalur model. Pada pendekatan spasial, *frame-frame* hasil sampling diperlakukan sebagai masukan individual untuk menilai sejauh mana informasi visual statis masih efektif dalam membedakan wajah asli dan wajah hasil manipulasi pada klip *deepfake* dunia nyata [9], [34]. Meskipun demikian, pendekatan ini memiliki keterbatasan mendasar karena tidak memodelkan hubungan temporal antar-*frame* secara eksplisit. Akibatnya, model spasial diperkirakan lebih sensitif terhadap artefak visual statis, tetapi berpotensi kurang optimal dalam menangkap anomali manipulasi yang hanya tampak melalui dinamika gerakan atau inkonsistensi temporal antar-*frame*. Keterbatasan inilah yang kemudian menjadi dasar pembandingan terhadap pendekatan spasiotemporal berbasis VideoMAE pada subbab berikutnya.


3.2.5.2 Rancangan Model Spasiotemporal Berbasis VideoMAE

Model VideoMAE yang diperkenalkan oleh Tong dkk. pada tahun 2022 merupakan arsitektur berbasis Transformer untuk pemodelan video yang dirancang agar mampu mempelajari representasi spasiotemporal secara efisien [12]. Berbeda dengan Transformer untuk citra tunggal, VideoMAE memproses video sebagai urutan token spasiotemporal yang dibentuk dari klip video, sehingga model dapat menangkap informasi visual statis sekaligus hubungan temporal antar-*frame* [12]. Dalam penelitian ini, VideoMAE digunakan sebagai

model pada pendekatan spasiotemporal untuk melakukan klasifikasi video *deepfake* berdasarkan representasi visual pada tingkat klip. Model tersebut diinisialisasi menggunakan bobot hasil pelatihan pada Something-Something V2, kemudian disesuaikan lebih lanjut untuk tugas klasifikasi biner *real* dan *fake*.

Masukan model berupa satu klip video hasil *strided temporal sampling* yang terdiri atas 16 *frame* RGB berukuran 224×224 piksel. Keenam belas *frame* tersebut diperoleh dari satu klip turunan sepanjang 46 *frame* melalui proses *strided temporal sampling* dengan *stride* 3 pada tahap *preprocessing* sebelumnya. Konfigurasi ini dipilih agar konsisten dengan tahapan *preprocessing* yang telah dijelaskan, sekaligus menjaga kesetaraan evidensi visual dengan pendekatan spasial. Dengan demikian, kedua jalur eksperimen dibangun dari *frame-frame* hasil sampling yang sama, sehingga perbedaan performa yang diperoleh lebih merefleksikan perbedaan kemampuan model dalam memanfaatkan informasi spasial dan temporal, bukan disebabkan oleh perbedaan data masukan.

Berbeda dari Vision Transformer untuk citra tunggal yang membagi input menjadi *patch* dua dimensi, VideoMAE membagi klip video menjadi kubus spasiotemporal melalui mekanisme *joint space-time cube embedding* [12]. Pada rancangan ini, setiap kubus memiliki ukuran $2 \times 16 \times 16$, yaitu mencakup dua *frame* pada dimensi waktu dan area 16×16 piksel pada dimensi spasial [12]. Dengan masukan berukuran $16 \times 224 \times 224$, proses tersebut menghasilkan token video sebanyak $(16/2) \times (224/16) \times (224/16) = 8 \times 14 \times 14 = 1568$ token. Setiap kubus kemudian diratakan dan diproyeksikan secara linear ke ruang embedding untuk membentuk representasi token video. Setelah itu, *positional embedding* ditambahkan untuk mempertahankan informasi posisi spasial dan urutan temporal token sebelum diproses lebih lanjut oleh model. Ilustrasi arsitektur model spasiotemporal berbasis VideoMAE yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.10.



Gambar 3.10 Arsitektur model spasiotemporal berbasis VideoMAE untuk klasifikasi *deepfake*

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. *Encoder* VideoMAE terdiri atas 12 blok Transformer [12]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection* [12]. Karakteristik utama rancangan ini terletak pada penggunaan *joint space-time attention*, yaitu mekanisme *self-attention* yang memungkinkan seluruh token video saling berinteraksi secara langsung lintas posisi spasial dan lintas waktu secara simultan [12]. Melalui mekanisme tersebut, model tidak hanya menangkap detail visual pada setiap *frame*, tetapi juga mampu mempelajari keterkaitan perubahan visual antar-*frame* dalam satu klip secara menyeluruh.

Perlu dicatat bahwa pada rancangan asli VideoMAE, komponen seperti *tube masking* dengan rasio tinggi dan *decoder* digunakan pada tahap *self-supervised pre-training* untuk merekonstruksi bagian video yang dimask [12]. Namun, pada penelitian ini fokus utama bukan pada tahap tersebut, melainkan pada pemanfaatan representasi VideoMAE untuk tugas klasifikasi biner *downstream*. Oleh karena itu, alur model dalam penelitian ini difokuskan pada pembentukan token spasiotemporal, ekstraksi representasi video melalui Transformer encoder, dan klasifikasi akhir pada tingkat klip.

Pada tahap akhir, representasi keluaran dari lapisan terakhir encoder diringkas melalui *mean pooling* untuk memperoleh satu vektor fitur pada tingkat klip. Vektor tersebut kemudian diteruskan ke *classification head* untuk menghasilkan prediksi akhir secara langsung pada tingkat klip, yaitu kelas *real* atau *fake*. Dengan rancangan tersebut, pendekatan spasiotemporal pada penelitian ini beroperasi sepenuhnya pada tingkat klip, sehingga model diharapkan mampu menangkap bukti manipulasi yang tersebar baik pada dimensi spasial maupun temporal secara lebih komprehensif [7], [12]. Hasil dari model ini selanjutnya dibandingkan secara langsung dengan pendekatan spasial berbasis ViT yang juga menghasilkan keputusan akhir pada tingkat klip, sehingga kontribusi relatif informasi temporal terhadap ketahanan klasifikasi *deepfake* pada kondisi dunia nyata dapat dievaluasi secara lebih setara.

3.2.5.3 Rancangan Eksperimen

Rancangan eksperimen pada penelitian ini disusun untuk membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada tugas klasifikasi video *deepfake*. Seluruh eksperimen dilakukan pada tingkat klip agar hasil kedua pendekatan dapat dibandingkan secara setara. Pada pendekatan spasial, *frame* dalam satu klip diproses secara individual, kemudian hasil prediksi setiap *frame* diagregasi menjadi prediksi tingkat klip. Sementara itu, pada pendekatan spasiotemporal, seluruh *frame* dalam satu klip diproses secara langsung untuk menghasilkan prediksi tingkat klip.

Rancangan eksperimen dibagi menjadi empat kelompok, yaitu eksperimen *baseline*, konfigurasi pelatihan, konfigurasi input spasial dan temporal, serta evaluasi lintas-*dataset*. Eksperimen *baseline* digunakan sebagai acuan awal performa model sebelum dilakukan variasi konfigurasi. Pengujian konfigurasi pelatihan digunakan untuk menganalisis pengaruh perubahan parameter pelatihan terhadap performa model. Pengujian konfigurasi input spasial

dan temporal digunakan untuk mengevaluasi pengaruh perubahan resolusi, jumlah *frame*, dan *stride* terhadap kedua pendekatan. Adapun evaluasi lintas-*dataset* digunakan untuk mengukur kemampuan generalisasi model pada *dataset* eksternal secara *zero-shot*.

Eksperimen *baseline* menggunakan konfigurasi dasar dengan resolusi 224×224 piksel, jumlah *frame* masukan 16, dan *stride* 3. Konfigurasi ini diterapkan pada model spasial dan model spasiotemporal agar diperoleh titik awal perbandingan yang setara. Rancangan eksperimen *baseline* ditunjukkan pada Tabel 3.2.

Tabel 3.2 Rancangan eksperimen *baseline*

Kode	Model	Resolusi	Jumlah Frame (<i>T</i>)	Stride (τ)
BASE-SP	Spasial	224×224	16	3
BASE-ST	Spasiotemporal	224×224	16	3

Setelah eksperimen *baseline* dilakukan, penelitian dilanjutkan dengan pengujian konfigurasi pelatihan. Pada kelompok eksperimen ini, satu komponen konfigurasi pelatihan diubah pada setiap eksperimen, sedangkan komponen lainnya dipertahankan mengikuti konfigurasi dasar. Strategi ini digunakan agar pengaruh masing-masing komponen pelatihan dapat dianalisis secara lebih terarah. Rancangan konfigurasi pelatihan yang diuji ditunjukkan pada Tabel 3.3.

Tabel 3.3 Konfigurasi pelatihan yang diuji

Kode	Parameter yang Diuji
M1-SP / M1-ST	Epoch maksimum
M2-SP / M2-ST	<i>Learning rate</i>
M3-SP / M3-ST	<i>Loss function</i>
M4-SP / M4-ST	Augmentasi data
M5-SP / M5-ST	<i>Dropout</i>
M6-SP / M6-ST	<i>Scheduler</i>

Pengujian konfigurasi input spasial dan temporal dilakukan setelah pengujian konfigurasi pelatihan untuk mengevaluasi pengaruh konfigurasi input terhadap performa kedua pendekatan. Pada eksperimen ini, variasi difokuskan pada resolusi masukan, kepadatan sampling temporal, dan jumlah *frame* masukan. Konfigurasi BASE digunakan sebagai acuan dasar, sedangkan E2 sampai E5 digunakan untuk menganalisis perubahan karakteristik input pada *dataset WildDeepfake*. Rancangan konfigurasi input spasial dan temporal ditunjukkan pada Tabel 3.4.

Tabel 3.4 Konfigurasi input spasial dan temporal

Kode	Fokus Eksperimen	Resolusi	Jumlah <i>Frame</i> (T)	<i>Stride</i> (τ)
E2-SP / E2-ST	Penurunan resolusi	112×112	16	3
E3-SP / E3-ST	<i>Stride</i> lebih rapat	224×224	16	1
E4-SP / E4-ST	<i>Frame</i> lebih sedikit	224×224	8	3
E5-SP / E5-ST	<i>Frame</i> lebih banyak	224×224	24	1

Selain eksperimen pada *dataset WildDeepfake*, penelitian ini juga melakukan evaluasi lintas-*dataset* menggunakan *Celeb-DF v2*. Evaluasi ini dilakukan secara *zero-shot*, yaitu model tidak dilatih ulang dan tidak dilakukan *fine-tuning* pada *Celeb-DF v2*. Model yang digunakan pada tahap ini berasal dari *checkpoint* konfigurasi pelatihan terbaik, kemudian langsung diuji pada *dataset Celeb-DF v2* untuk mengukur kemampuan generalisasi terhadap distribusi data eksternal. Rancangan evaluasi lintas-*dataset* ditunjukkan pada Tabel 3.5.

Tabel 3.5 Rancangan evaluasi lintas-*dataset*

Kode	Model	<i>Dataset Uji</i>
E6-SP	Spasial	<i>Celeb-DF v2</i>
E6-ST	Spasiotemporal	<i>Celeb-DF v2</i>

Berdasarkan rancangan tersebut, setiap eksperimen diterapkan pada dua pendekatan model, yaitu SP untuk model spasial dan ST untuk model

spasiotemporal. Pemisahan eksperimen ke dalam *baseline*, konfigurasi pelatihan, konfigurasi input spasial dan temporal, serta evaluasi lintas-*dataset* dilakukan agar alur penelitian lebih sistematis. Eksperimen *baseline* memberikan titik acuan performa awal, pengujian konfigurasi pelatihan menjelaskan pengaruh perubahan parameter pelatihan, pengujian konfigurasi input spasial dan temporal menunjukkan pengaruh variasi input, sedangkan evaluasi lintas-*dataset* digunakan untuk menilai kemampuan generalisasi model pada *dataset* eksternal. Dengan demikian, rancangan eksperimen ini mendukung analisis komparatif antara pendekatan spasial dan spasiotemporal secara lebih terarah dan konsisten.

3.2.6 Evaluasi Model

Evaluasi model pada penelitian ini dilakukan untuk menilai kinerja dua pendekatan yang digunakan, yaitu model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE. Evaluasi dilakukan pada tingkat klip agar hasil kedua pendekatan dapat dibandingkan secara setara. Pada pendekatan spasial, model menghasilkan prediksi untuk setiap *frame* dalam satu klip, kemudian seluruh prediksi tersebut diagregasi menggunakan rata-rata untuk memperoleh satu keputusan akhir pada tingkat klip. Sementara itu, pada pendekatan spasiotemporal, model memproses satu klip secara langsung dan menghasilkan satu prediksi akhir pada tingkat klip.

Evaluasi utama dilakukan pada *dataset WildDeepfake*. Data validasi digunakan selama proses pelatihan untuk memantau perkembangan model, sedangkan data uji digunakan untuk memperoleh performa akhir pada setiap konfigurasi eksperimen. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*. *Accuracy* digunakan untuk mengukur proporsi prediksi benar secara keseluruhan. *Precision* digunakan untuk mengukur ketepatan prediksi pada kelas *fake*, sedangkan *recall* digunakan untuk mengukur kemampuan model mendeteksi seluruh klip *fake*. *F1-score* digunakan untuk menilai keseimbangan antara

precision dan *recall*, sedangkan AUC-ROC digunakan untuk mengukur kemampuan diskriminatif model pada berbagai nilai *threshold*.

Selain evaluasi internal pada *WildDeepfake*, penelitian ini juga melakukan evaluasi lintas-*dataset* menggunakan *Celeb-DF v2*. Evaluasi tersebut dilakukan secara *zero-shot*, yaitu model yang telah dilatih pada *WildDeepfake* langsung digunakan untuk menguji *Celeb-DF v2* tanpa pelatihan ulang dan tanpa *fine-tuning*. Evaluasi lintas-*dataset* ini bertujuan untuk mengukur kemampuan generalisasi model terhadap distribusi data eksternal yang berbeda dari *dataset* pelatihan.

Hasil evaluasi disajikan dalam bentuk tabel metrik, *confusion matrix*, kurva ROC, serta grafik *training loss* dan *validation loss* apabila diperlukan untuk mendukung analisis kestabilan pelatihan. Dengan susunan evaluasi tersebut, penelitian ini dapat membandingkan efektivitas pendekatan spasial dan spasiotemporal secara objektif, baik pada *dataset* utama maupun pada skenario generalisasi lintas-*dataset*.

3.2.7 Hasil dan Pembahasan

Tahap hasil dan pembahasan dilakukan untuk menganalisis secara komparatif kinerja model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE dalam klasifikasi *deepfake* pada tingkat klip. Analisis didasarkan pada perbandingan nilai *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC, serta didukung oleh *confusion matrix*, kurva ROC, dan grafik *training loss* serta *validation loss* untuk menilai performa klasifikasi, kemampuan diskriminatif, dan kestabilan pelatihan model [27], [29], [35]. Hasil yang diperoleh kemudian diinterpretasikan untuk menjelaskan efektivitas relatif pendekatan spasial dan spasiotemporal, termasuk kecenderungan kesalahan prediksi pada data *WildDeepfake* yang memiliki karakteristik kompresi tinggi, variasi pose, pencahayaan, dan kualitas visual yang tidak seragam [8], [9], [34].

3.3 Alat dan Bahan Tugas Akhir

Adapun alat dan bahan yang digunakan dalam penelitian ini dijelaskan sebagai berikut.

3.3.1 Alat

Alat yang digunakan dalam penelitian ini meliputi perangkat keras (*hardware*) dan perangkat lunak (*software*) yang mendukung proses pemodelan, pelatihan, serta evaluasi model. Berikut adalah alat yang digunakan.

1. Visual Studio Code
2. Kaggle Notebook
3. Library PyTorch
4. GPU NVIDIA Tesla T4 (*cloud-based service*)

3.3.2 Dataset

Dataset utama yang digunakan dalam penelitian ini adalah *WildDeepfake*, yang berperan sebagai sumber data pelatihan, validasi, dan pengujian utama untuk model spasial berbasis Vision Transformer (ViT) dan model spatiotemporal berbasis VideoMAE. Selain itu, penelitian ini menggunakan *Celeb-DF v2* sebagai *dataset* evaluasi eksternal untuk pengujian lintas-*dataset* secara *zero-shot*, sehingga *dataset* tersebut tidak digunakan dalam proses pelatihan maupun *fine-tuning* model. Penelitian ini juga memanfaatkan *pretrained weights* pada ViT dan VideoMAE sebagai inisialisasi awal sebelum proses *fine-tuning* pada *WildDeepfake*, agar model dapat memanfaatkan representasi visual dan spatiotemporal yang telah dipelajari sebelumnya.

3.4 Ilustrasi Perhitungan Metode

3.4.1 Ilustrasi Perhitungan Metrik Evaluasi

Sebagai ilustrasi, misalkan hasil prediksi model pada 100 klip uji menghasilkan *confusion matrix* seperti pada Tabel 3.6. Pada penelitian ini, kelas positif didefinisikan sebagai *fake*, sedangkan kelas negatif didefinisikan sebagai

real.

Tabel 3.6 Contoh *confusion matrix* hasil evaluasi

Actual \ Predicted	Fake	Real
Fake	36	8
Real	4	52

Berdasarkan Tabel 3.6, diperoleh nilai $TP = 36$, $FN = 8$, $FP = 4$, dan $TN = 52$. Dengan demikian, nilai *accuracy* dapat dihitung sebagai berikut.

$$\begin{aligned}
 Accuracy &= \frac{TP + TN}{TP + TN + FP + FN} \\
 &= \frac{36 + 52}{36 + 52 + 4 + 8} = \frac{88}{100} = 0,88 = 88\%
 \end{aligned}$$

Nilai *precision* dihitung sebagai berikut.

$$\begin{aligned}
 Precision &= \frac{TP}{TP + FP} \\
 &= \frac{36}{36 + 4} = \frac{36}{40} = 0,90 = 90\%
 \end{aligned}$$

Nilai *recall* dihitung sebagai berikut.

$$\begin{aligned}
 Recall &= \frac{TP}{TP + FN} \\
 &= \frac{36}{36 + 8} = \frac{36}{44} = 0,8182 = 81,82\%
 \end{aligned}$$

Selanjutnya, nilai *F1-score* dihitung sebagai berikut.

$$\begin{aligned}
 F1\text{-score} &= 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \\
 &= 2 \times \frac{0,90 \times 0,8182}{0,90 + 0,8182} \\
 &= 0,8571 = 85,71\%
 \end{aligned}$$

Untuk kebutuhan kurva ROC, terlebih dahulu dihitung *True Positive Rate* (TPR) dan *False Positive Rate* (FPR). Nilai TPR adalah:

$$\begin{aligned}
 TPR &= \frac{TP}{TP + FN} \\
 &= \frac{36}{36 + 8} = \frac{36}{44} = 0,8182
 \end{aligned}$$

Adapun nilai FPR adalah:

$$\begin{aligned}
 FPR &= \frac{FP}{FP + TN} \\
 &= \frac{4}{4 + 52} = \frac{4}{56} = 0,0714
 \end{aligned}$$

Dengan demikian, pada satu nilai *threshold* tertentu diperoleh satu titik ROC, yaitu $(FPR, TPR) = (0,0714, 0,8182)$. Jika secara sederhana kurva ROC dibentuk oleh tiga titik, yaitu $(0, 0)$, $(0,0714, 0,8182)$, dan $(1, 1)$, maka nilai AUC dapat dihampiri menggunakan aturan trapesium sebagai berikut.

$$\begin{aligned}
 AUC &= \frac{0 + 0,8182}{2} (0,0714 - 0) + \frac{0,8182 + 1}{2} (1 - 0,0714) \\
 &= 0,0292 + 0,8442 = 0,8734
 \end{aligned}$$

Berdasarkan hasil perhitungan tersebut, model pada ilustrasi ini memiliki *accuracy* 88%, *precision* 90%, *recall* 81,82%, *F1-score* 85,71%, dan AUC 0,8734. Nilai-nilai tersebut menunjukkan bahwa model memiliki kemampuan klasifikasi yang baik dalam membedakan klip *real* dan *fake*, meskipun masih terdapat kesalahan prediksi pada sebagian sampel positif dan negatif.

BAB IV

HASIL DAN PEMBAHASAN


4.1 Pengumpulan Data

Pada tahap ini dilakukan proses pengumpulan *dataset* yang digunakan dalam penelitian. *Dataset* yang digunakan adalah *WildDeepfake*, yaitu *dataset* publik untuk klasifikasi video *deepfake* yang terdiri atas dua kelas, yaitu *real* dan *fake*. *Dataset* ini digunakan sebagai sumber data utama dalam proses pelatihan, validasi, dan pengujian model.

Tabel 4.1 Distribusi Kelas *Dataset WildDeepfake*

No	Kelas	Jumlah Data
1	<i>Real</i>	3.805
2	<i>Fake</i>	3.509
Total		7.314

Berdasarkan Tabel 4.1, jumlah data pada kelas *real* lebih banyak dibandingkan kelas *fake*, tetapi selisih keduanya tidak terlalu besar. Data tersebut selanjutnya diproses pada tahap *pre-processing* untuk membentuk klip wajah yang digunakan sebagai masukan model. Contoh sampel citra wajah kelas *real* dan *fake* pada *dataset WildDeepfake* ditunjukkan pada Gambar 4.1.



Gambar 4.1 Contoh Sampel Citra Wajah Kelas *Real* dan *Fake* pada *Dataset WildDeepfake*

4.2 Hasil *Pre-processing* Data

Tahap *pre-processing* data dilakukan untuk menyiapkan *dataset WildDeepfake* agar dapat digunakan sebagai masukan model. Pada tahap ini, data yang sebelumnya berbentuk sekuens wajah diproses menjadi klip dengan panjang seragam, kemudian dibagi ke dalam subset *train*, validasi, dan *test*.

4.2.1 Hasil Pembentukan Klip 46 *Frame*

Pada tahap ini, setiap sekuens wajah pada *dataset WildDeepfake* diproses menjadi klip turunan dengan panjang tetap 46 *frame*. Pembentukan klip dilakukan agar seluruh data memiliki panjang temporal yang seragam sebelum digunakan pada proses *strided temporal sampling*. Dengan demikian, unit data yang digunakan pada tahap eksperimen bukan lagi sekuens wajah awal, melainkan klip wajah berdurasi tetap.

Potongan kode yang digunakan untuk membentuk klip 46 *frame* ditunjukkan pada Kode 4.1.

Kode 4.1 Pembentukan Klip 46 *Frame*

```

1  CLIP_LEN = 46
2
3  def compute_centered_clip_ranges(num_frames: int, clip_len: int =
4      46):
5      """
6      Menghasilkan rentang [start, end) untuk klip 46 frame.
7      Strategi:
8      - C = floor(N / L)
9      - R = N - C * L
10     - buang floor(R/2) frame di kiri
11     - buang ceil(R/2) frame di kanan
12     """
13     if num_frames < clip_len:
14         return []
15
16     num_clips = num_frames // clip_len
17     used_frames = num_clips * clip_len
18     remainder = num_frames - used_frames
19
20     discard_left = remainder // 2
21     start_idx = discard_left
22
23     ranges = []
24     for i in range(num_clips):
25         s = start_idx + i * clip_len
26         e = s + clip_len
27         ranges.append((s, e))
28
29     return ranges

```

```

29
30 def build_46f_clips_for_subset(
31     extracted_subset_dir: Path,
32     processed_subset_dir: Path,
33     clip_len: int = 46
34 ):
35     reset_dir(processed_subset_dir)
36
37     group_dirs = sorted(
38         [p for p in extracted_subset_dir.iterdir() if p.is_dir()],
39         key=lambda p: p.name
40     )
41
42     total_sequences = 0
43     total_clips = 0
44     skipped_sequences = 0
45
46     for group_dir in group_dirs:
47         group_id = group_dir.name
48         out_group_dir = processed_subset_dir / group_id
49         ensure_dir(out_group_dir)
50
51         seq_dirs = sorted(
52             [p for p in group_dir.iterdir() if p.is_dir()],
53             key=lambda p: p.name
54         )
55
56         for seq_dir in seq_dirs:
57             total_sequences += 1
58             seq_id = seq_dir.name
59
60             frame_files = list_image_files(seq_dir)
61             n = len(frame_files)
62
63             if n < clip_len:
64                 skipped_sequences += 1
65                 continue
66
67             clip_ranges = compute_centered_clip_ranges(n,
68                 clip_len=clip_len)
69
70             for clip_idx, (s, e) in enumerate(clip_ranges):
71                 clip_folder_name = f"{seq_id}_{clip_idx}"
72                 out_clip_dir = out_group_dir / clip_folder_name
73                 ensure_dir(out_clip_dir)
74
75                 selected_frames = frame_files[s:e]
76
77                 for frame_path in selected_frames:
78                     shutil.copy2(frame_path, out_clip_dir /
79                         frame_path.name)
80
81                 total_clips += 1
82
83     return {
84         "total_sequences": total_sequences,
85         "total_clips": total_clips,
86         "skipped_sequences": skipped_sequences,
87     }

```

Kode 4.1 menunjukkan bahwa setiap sekuens terlebih dahulu dihitung jumlah klip penuhnya berdasarkan panjang klip 46 *frame*. Apabila terdapat sisa *frame* yang tidak membentuk satu klip penuh, sisa tersebut dibuang dari sisi kiri dan kanan secara seimbang. Setelah itu, setiap rentang *frame* disalin ke folder

klip baru sehingga satu klip berisi tepat 46 *frame*.

Berdasarkan hasil pre-processing, diperoleh total 22.303 klip. Seluruh klip tersebut memiliki panjang 46 *frame*, sehingga tidak terdapat klip yang tidak valid. Distribusi kelas hasil pembentukan klip 46 *frame* ditunjukkan pada Tabel 4.2.

Tabel 4.2 Distribusi Kelas Hasil Pembentukan Klip 46 *Frame*

No	Kelas	Jumlah Data
1	<i>Real</i>	7.851
2	<i>Fake</i>	14.452
Total		22.303

Berdasarkan Tabel 4.2, jumlah klip kelas fake lebih banyak dibandingkan kelas real. Kelas fake terdiri atas 14.452 klip, sedangkan kelas real terdiri atas 7.851 klip. Hasil ini menunjukkan bahwa setelah sekuens wajah diproses menjadi klip turunan, distribusi data menjadi lebih didominasi oleh kelas fake.

4.2.2 Hasil Pembagian *Dataset*

Dataset WildDeepfake yang digunakan dalam penelitian ini sebelumnya telah memiliki pembagian awal berupa subset *train* dan *test*. Subset tersebut tersusun dalam empat direktori utama, yaitu *real_train*, *fake_train*, *real_test*, dan *fake_test*. Pada penelitian ini, subset *real_test* dan *fake_test* tetap digunakan sebagai data pengujian akhir. Sementara itu, data yang berasal dari subset *real_train* dan *fake_train* dibagi kembali menjadi data *train* dan data validasi.

Pembagian data validasi dilakukan dari subset *train* dengan rasio 80:20. Proses pembagian dilakukan pada level *group_id*, bukan pada level klip. Strategi ini digunakan agar klip turunan yang berasal dari sekuens atau sumber yang sama tidak terpisah ke subset yang berbeda. Dengan demikian, risiko kebocoran data antara data latih dan data validasi dapat dikurangi.

Potongan kode pembagian *dataset* ditunjukkan pada Kode 4.2.

Kode 4.2 Pembagian *Dataset Train*, Validasi, dan *Test*

```

1  SEED = 42
2  VAL_RATIO = 0.20
3
4  # Data train resmi berasal dari subset real_train dan fake_train.
5  train_records = []
6  train_records += build_manifest_for_subset("real_train",
7      subset_dirs["real_train"])
8  train_records += build_manifest_for_subset("fake_train",
9      subset_dirs["fake_train"])
10
11 # Data test resmi berasal dari subset real_test dan fake_test.
12 test_records = []
13 test_records += build_manifest_for_subset("real_test",
14     subset_dirs["real_test"])
15 test_records += build_manifest_for_subset("fake_test",
16     subset_dirs["fake_test"])
17
18 train_df = pd.DataFrame(train_records)
19 test_df = pd.DataFrame(test_records)
20
21 # Split dilakukan pada level GROUP, bukan level klip,
22 # agar klip turunan seperti 101_0, 101_1, dan 101_2
23 # tidak terpisah ke subset yang berbeda.
24 group_df = (
25     train_df[["group_id", "label", "label_name"]]
26     .drop_duplicates()
27     .reset_index(drop=True)
28 )
29
30 train_groups, val_groups = train_test_split(
31     group_df,
32     test_size=VAL_RATIO,
33     random_state=SEED,
34     shuffle=True,
35     stratify=group_df["label"],
36 )
37
38 train_group_ids = set(train_groups["group_id"])
39 val_group_ids = set(val_groups["group_id"])
40
41 train_split_df = (
42     train_df[train_df["group_id"].isin(train_group_ids)]
43     .copy()
44     .reset_index(drop=True)
45 )
46
47 val_split_df = (
48     train_df[train_df["group_id"].isin(val_group_ids)]
49     .copy()
50     .reset_index(drop=True)
51 )
52
53 test_df = test_df.reset_index(drop=True)
54
55 # Validasi anti-leakage antara train dan validasi.
56 overlap_groups = set(train_split_df["group_id"]) &
57     set(val_split_df["group_id"])
58
59 if overlap_groups:
60     raise ValueError(
61         f"Ditemukan kebocoran group antara train dan validasi: "
62         f"{list(overlap_groups)[:5]}"
63     )

```

Kode 4.2 menunjukkan bahwa data uji tidak dibagi ulang, melainkan

tetap mengikuti subset *test* resmi dari *dataset WildDeepfake*. Pembagian ulang hanya dilakukan pada subset *train* untuk membentuk data latih dan data validasi. Selain itu, penggunaan `stratify=group_dff["label"]` bertujuan agar proporsi kelas *real* dan *fake* pada hasil pembagian tetap terjaga.

Tabel 4.3 Hasil Pembagian *Dataset* Berdasarkan Kelas

No	Subset	Real	Fake	Total
1	<i>Train</i>	5.376	10.124	15.500
2	Validasi	1.382	2.189	3.571
3	<i>Test</i>	1.093	2.139	3.232
Total		7.851	14.452	22.303

Berdasarkan Tabel 4.3, subset *train* memiliki jumlah data terbesar, yaitu 15.500 klip. Subset validasi terdiri atas 3.571 klip, sedangkan subset *test* terdiri atas 3.232 klip. Pada seluruh subset, jumlah klip kelas *fake* lebih banyak dibandingkan kelas *real*. Distribusi ini kemudian digunakan secara konsisten pada proses pelatihan, validasi, dan pengujian model.

4.2.3 Augmentasi Data

Augmentasi data diterapkan untuk meningkatkan keragaman data pelatihan dan mengurangi risiko *overfitting*. Pada penelitian ini, augmentasi hanya diterapkan pada subset *train*, sedangkan subset validasi dan *test* tidak diberikan augmentasi. Hal ini dilakukan agar proses validasi dan pengujian tetap merepresentasikan performa model pada data yang tidak mengalami transformasi tambahan.

Implementasi augmentasi dilakukan menggunakan library *Albumentations*. Library ini digunakan karena mendukung berbagai transformasi citra, seperti transformasi geometri, perubahan warna, blur, dan noise. Pada penelitian ini, augmentasi diterapkan secara konsisten pada seluruh *frame* dalam satu klip. Dengan demikian, transformasi yang diberikan pada satu *frame* direplikasi pada *frame-frame* lain dalam klip yang sama agar koherensi visual antar-*frame* tetap

terjaga.

Potongan kode augmentasi data ditunjukkan pada Kode 4.3.

Kode 4.3 Augmentasi Data Menggunakan Albumentations

```


1  def _build_train_transform(self):
2      crop_h, crop_w = _sample_fakeformer_crop_size(
3          image_size=self.image_size,
4          crop_limit=AUG_CROP_LIMIT,
5      )
6
7      return A.ReplayCompose(
8          [
9              A.OneOf(
10                 [
11                     A.RandomCrop(
12                         height=crop_h,
13                         width=crop_w,
14                         p=AUG_CROP_PROB,
15                     ),
16                     A.RandomScale(
17                         scale_limit=AUG_SCALE_LIMIT,
18                         interpolation=cv2.INTER_LINEAR,
19                         p=AUG_SCALE_PROB,
20                     ),
21                 ],
22                 p=AUG_GEOMETRY_ONEOF_PROB,
23             ),
24             A.Resize(
25                 height=self.image_size,
26                 width=self.image_size,
27                 interpolation=cv2.INTER_CUBIC,
28                 p=1.0,
29             ),
30             A.HorizontalFlip(p=AUG_PROB_HFLIP),
31             A.ColorJitter(
32                 brightness=AUG_COLORJITTER_BRIGHTNESS,
33                 contrast=AUG_COLORJITTER_CONTRAST,
34                 saturation=AUG_COLORJITTER_SATURATION,
35                 hue=AUG_COLORJITTER_HUE,
36                 p=AUG_COLORJITTER_PROB,
37             ),
38             A.OneOf(
39                 [
40                     A.GaussianBlur(
41                         blur_limit=AUG_GAUSSIAN_BLUR_LIMIT,
42                         sigma_limit=0,
43                         p=AUG_GAUSSIAN_BLUR_PROB,
44                     ),
45                     _make_gauss_noise_transform(
46                         p=AUG_GAUSSNOISE_PROB,
47                     ),
48                 ],
49                 p=AUG_BLUR_OR_NOISE_ONEOF_PROB,
50             ),
51         ]
52     )

```

Kode 4.3 menunjukkan bahwa augmentasi yang digunakan terdiri atas beberapa jenis transformasi, yaitu random crop, random scale, horizontal flip, color jitter, Gaussian blur, dan Gaussian noise. Transformasi random crop dan random scale digunakan untuk memberikan variasi geometri pada area wajah.

Transformasi horizontal flip digunakan untuk menambah variasi orientasi wajah. Transformasi color jitter digunakan untuk mensimulasikan variasi pencahayaan dan warna. Sementara itu, Gaussian blur dan Gaussian noise digunakan untuk menambahkan variasi degradasi visual yang dapat muncul pada data video.

Contoh visualisasi hasil augmentasi ditunjukkan pada Gambar 4.2. Visualisasi tersebut menampilkan perbandingan antara citra asli dan beberapa hasil augmentasi yang diterapkan pada data latih.



Gambar 4.2 Contoh Hasil Augmentasi Data Menggunakan Albumentations: (a) citra asli, (b) horizontal flip, (c) random crop, (d) random scale, (e) color jitter, (f) Gaussian blur, dan (g) Gaussian noise

Berdasarkan Gambar 4.2, augmentasi yang diterapkan tidak mengubah label data, tetapi hanya memberikan variasi visual pada citra wajah. Dengan demikian, model diharapkan dapat mempelajari pola yang lebih robust terhadap perubahan posisi wajah, orientasi, pencahayaan, serta degradasi visual pada *frame*.

4.2.4 Normalisasi Data

Setelah proses augmentasi dilakukan, setiap *frame* dikonversi menjadi *tensor* dan dinormalisasi sebelum diberikan ke model. Normalisasi dilakukan untuk menyesuaikan distribusi nilai piksel dengan karakteristik model *pretrained*

yang digunakan. Pada penelitian ini, nilai piksel terlebih dahulu diubah ke rentang [0, 1], kemudian dinormalisasi menggunakan nilai mean dan standard deviation ImageNet.

Potongan kode normalisasi data ditunjukkan pada Kode 4.4.

Kode 4.4 Normalisasi Data

```

1  NORM_MEAN = (0.485, 0.456, 0.406)
2  NORM_STD = (0.229, 0.224, 0.225)
3
4  def _array_to_normalized_tensor(self, image_array: np.ndarray):
5      tensor = torch.from_numpy(image_array).permute(2, 0, 1).float()
6
7      if image_array.dtype == np.uint8:
8          tensor = tensor / 255.0
9      elif tensor.max() > 1.0:
10         tensor = tensor / 255.0
11
12     tensor = torch.clamp(tensor, 0.0, 1.0)
13
14     tensor = TF.normalize(
15         tensor,
16         mean=self.mean,
17         std=self.std,
18     )
19
20     return tensor

```

Kode 4.4 menunjukkan bahwa citra yang semula berada dalam format $H \times W \times C$ dikonversi menjadi format *tensor* $C \times H \times W$. Selanjutnya, nilai piksel dikonversi ke rentang [0, 1] dengan membagi nilai piksel 8-bit terhadap 255. Setelah itu, normalisasi dilakukan menggunakan nilai mean (0,485, 0,456, 0,406) dan standard deviation (0,229, 0,224, 0,225).

Normalisasi diterapkan pada seluruh subset data, yaitu *train*, validasi, dan *test*. Perbedaannya adalah subset *train* terlebih dahulu melalui proses augmentasi, sedangkan subset validasi dan *test* hanya melalui proses transformasi dasar, konversi *tensor*, dan normalisasi. Dengan demikian, seluruh data yang diberikan ke model memiliki format dan skala nilai yang konsisten pada tahap pelatihan, validasi, dan pengujian.

4.3 Hasil Rancangan Model

Tahap rancangan model dilakukan untuk mengimplementasikan dua pendekatan klasifikasi video *deepfake*, yaitu pendekatan spasial dan pendekatan

spasiotemporal. Kedua pendekatan menggunakan data masukan yang berasal dari hasil *strided temporal sampling* yang sama, sehingga perbandingan performa dapat dilakukan secara lebih setara. Perbedaan utama kedua model terletak pada cara model memproses *frame* dalam satu klip. Model spasial memproses *frame* secara individual, sedangkan model spasiotemporal memproses seluruh *frame* dalam satu klip secara langsung.

4.3.1 Model Spasial

Model spasial pada penelitian ini menggunakan arsitektur *Vision Transformer* (ViT). Model ini dirancang untuk memproses informasi visual pada tingkat *frame*. Oleh karena itu, meskipun data dari dataloader berbentuk klip, setiap *frame* dalam klip tetap diperlakukan sebagai citra individual sebelum diberikan ke model.

Pada implementasinya, satu *batch* data memiliki bentuk *tensor* $B \times T \times C \times H \times W$, dengan B sebagai ukuran *batch*, T sebagai jumlah *frame* dalam satu klip, C sebagai jumlah kanal warna, serta H dan W sebagai tinggi dan lebar citra. Karena ViT menerima input berupa citra, *tensor* klip tersebut terlebih dahulu diubah menjadi bentuk $B \times T \times C \times H \times W$ dengan menggabungkan dimensi *batch* dan temporal menjadi $B \times T$ sehingga seluruh *frame* dapat diproses sebagai kumpulan citra tunggal.

Setelah model menghasilkan *logit* untuk setiap *frame*, *logit* tersebut dikembalikan ke bentuk $B \times T \times 2$. Angka 2 menunjukkan jumlah kelas klasifikasi, yaitu *real* dan *fake*. Selanjutnya, *logit* dari seluruh *frame* dalam satu klip dirata-ratakan pada dimensi temporal untuk menghasilkan satu prediksi akhir pada tingkat klip. Potongan kode implementasi model spasial ditunjukkan pada Kode 4.5.

Kode 4.5 Implementasi Model Spasial

```

1 | b, t, c, h, w = clips.shape
2 |
3 | clips = clips.to(device, non_blocking=True)
4 | labels = labels.to(device, non_blocking=True)

```

```

5 frames = clips.reshape(b * t, c, h, w)
6
7
8 with torch.autocast(device_type=DEVICE.type, dtype=AMP_DTYPE,
9     enabled=USE_AMP):
10     frame_logits = model(frames)
11     clip_logits = frame_logits.view(b, t, 2).mean(dim=1)
12     loss = criterion(clip_logits, labels)

```

Kode 4.5 menunjukkan bahwa model spasial tidak memproses video secara langsung, melainkan memproses setiap *frame* sebagai citra individual. Proses *reshape* digunakan untuk menggabungkan dimensi *batch* dan dimensi temporal, sehingga input yang diterima ViT berbentuk kumpulan *frame*. Setelah *logit* setiap *frame* diperoleh, hasil tersebut diagregasi menggunakan rata-rata untuk memperoleh *logit* tingkat klip.

Melalui mekanisme ini, model spasial tetap mempertahankan karakteristik sebagai model berbasis citra, tetapi hasil akhirnya tetap berada pada tingkat klip. Hal ini diperlukan agar hasil evaluasi model spasial dapat dibandingkan secara langsung dengan model spasiotemporal. Dengan demikian, model spasial digunakan untuk mengukur sejauh mana informasi visual statis pada *frame* mampu membedakan klip *real* dan *fake*.

4.3.2 Model Spasiotemporal

Model spasiotemporal pada penelitian ini menggunakan arsitektur *VideoMAE*. Berbeda dengan model spasial, model ini dirancang untuk menerima masukan berupa klip video secara langsung. Oleh karena itu, hubungan antar-*frame* dalam satu klip tetap dipertahankan selama proses pemodelan.

Pada implementasinya, data dari dataloader memiliki bentuk *tensor* $B \times T \times C \times H \times W$. Bentuk tersebut tidak diubah menjadi kumpulan *frame* individual, melainkan langsung diberikan ke model *VideoMAE* melalui parameter *pixel.values*. Dengan rancangan ini, model dapat mempelajari informasi spasial pada setiap *frame* sekaligus hubungan temporal antar-*frame* dalam satu klip.

Model *VideoMAE* menghasilkan *logit* secara langsung pada tingkat klip.

Oleh karena itu, tidak diperlukan proses agregasi *logit* antar-*frame* seperti pada model spasial. Potongan kode implementasi model spasiotemporal ditunjukkan pada Kode 4.6.

Kode 4.6 Implementasi Model Spasiotemporal

```

1 clips = clips.to(device, non_blocking=True)
2 labels = labels.to(device, non_blocking=True)
3
4 optimizer.zero_grad(set_to_none=True)
5
6 with torch.autocast(device_type=device.type, dtype=AMP_DTYPE,
7     enabled=USE_AMP):
8     outputs = model(pixel_values=clips)
9     logits = outputs.logits
10    loss = criterion(logits, labels)

```

Kode 4.6 menunjukkan bahwa model spasiotemporal menerima input klip secara langsung dalam bentuk $B \times T \times C \times H \times W$. Variabel *clips* merepresentasikan *batch* klip hasil sampling yang telah melalui proses normalisasi. Selanjutnya, klip tersebut diberikan ke *VideoMAE* melalui `model(pixel_values=clips)`, kemudian model menghasilkan *logit* untuk dua kelas, yaitu *real* dan *fake*.

Dengan mekanisme tersebut, model spasiotemporal dapat memanfaatkan informasi visual pada setiap *frame* sekaligus pola perubahan antar-*frame* dalam satu klip. Pendekatan ini berbeda dari model spasial yang hanya memproses *frame* secara individual. Oleh karena itu, model spasiotemporal digunakan untuk mengevaluasi apakah pemodelan temporal dapat memberikan kontribusi terhadap peningkatan performa klasifikasi video *deepfake* pada *dataset WildDeepfake*.

4.3.3 Konfigurasi Hyperparameter

Konfigurasi *hyperparameter* digunakan untuk mengatur proses pelatihan model pada eksperimen *baseline*. *Hyperparameter* ini diterapkan untuk membangun konfigurasi awal sebelum dilakukan variasi eksperimen lebih lanjut. Penggunaan konfigurasi *baseline* bertujuan agar model spasial dan model spasiotemporal memiliki titik awal pelatihan yang konsisten dalam proses

evaluasi komparatif.

Tabel 4.4 Hyperparameter Model Baseline

No	Parameter	Nilai
1	<i>Learning rate</i>	5×10^{-5}
2	<i>Batch size</i>	32
3	Epoch maksimum	25
4	<i>Optimizer</i>	AdamW
5	<i>Weight decay</i>	1×10^{-4}
6	<i>Scheduler</i>	<i>Linear Decay to Zero</i>
7	<i>Loss function</i>	CrossEntropyLoss
8	<i>Dropout</i>	0

Berdasarkan Tabel 4.4, model *baseline* dilatih menggunakan *learning rate* sebesar 5×10^{-5} dengan *epoch* maksimum sebanyak 25 *epoch*. *Optimizer* yang digunakan adalah AdamW dengan *weight decay* sebesar 1×10^{-4} . Penggunaan *weight decay* bertujuan untuk memberikan regularisasi pada bobot model selama proses pelatihan. *Scheduler* yang digunakan adalah *Linear Decay to Zero*, yaitu penurunan *learning rate* secara bertahap hingga mendekati nol selama proses pelatihan.

Fungsi *loss* yang digunakan adalah CrossEntropyLoss karena penelitian ini merupakan tugas klasifikasi biner dengan dua kelas, yaitu *real* dan *fake*. Nilai *dropout* ditetapkan sebesar 0, sehingga tidak terdapat penambahan *dropout* khusus pada konfigurasi *baseline*. Dengan konfigurasi ini, model *baseline* digunakan sebagai acuan awal untuk mengevaluasi performa pendekatan spasial dan spatiotemporal sebelum dibandingkan dengan konfigurasi eksperimen lainnya.

4.4 Hasil Eksperimen

Pada sub bab ini, hasil eksperimen disajikan dalam lima subbab utama. Pertama, hasil eksperimen *baseline* digunakan sebagai acuan awal performa model. Kedua, hasil konfigurasi pelatihan digunakan untuk menganalisis

pengaruh perubahan parameter pelatihan terhadap performa model. Ketiga, hasil konfigurasi input spasial dan temporal digunakan untuk mengevaluasi pengaruh perubahan resolusi, jumlah *frame*, dan *stride* terhadap pendekatan spasial dan spasiotemporal. Keempat, evaluasi lintas-*dataset* digunakan untuk menguji kemampuan generalisasi model pada *dataset* eksternal secara *zero-shot*. Kelima, analisis perbandingan model digunakan untuk merangkum pola performa kedua pendekatan dan membahas pendekatan yang paling efektif dalam klasifikasi video *deepfake*.

4.4.1 Hasil Eksperimen *Baseline*


Eksperimen *baseline* dilakukan untuk memperoleh gambaran performa awal dari pendekatan spasial dan spasiotemporal sebelum dilakukan variasi konfigurasi pada tahap eksperimen berikutnya. Pada eksperimen ini, kedua model menggunakan konfigurasi dasar, yaitu resolusi input 224×224 piksel, jumlah *frame* masukan sebanyak 16 *frame*, dan nilai *stride* sebesar 3. Model spasial menggunakan *Vision Transformer* untuk memproses *frame* secara individual, sedangkan model spasiotemporal menggunakan *VideoMAE* untuk memproses klip video secara langsung.

Tabel 4.5 Hasil Eksperimen *Baseline*

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
BASE-ST	85,8%	83,9%	85,5%	84,5%	92,3%

Berdasarkan Tabel 4.5, model spasiotemporal BASE-ST memperoleh performa yang lebih tinggi dibandingkan model spasial BASE-SP pada seluruh metrik evaluasi. Pada metrik *accuracy*, model spasiotemporal mencapai nilai sebesar 85,8%, sedangkan model spasial mencapai 79,2%. Pada metrik *F1*, model spasiotemporal memperoleh nilai 84,5%, lebih tinggi dibandingkan model spasial sebesar 76,7%. Demikian pula pada metrik *AUC*, model spasiotemporal

memperoleh nilai 92,3%, sedangkan model spasial memperoleh 86,8%. Hasil ini menunjukkan bahwa pada konfigurasi *baseline*, pendekatan spatiotemporal memiliki kemampuan klasifikasi dan kemampuan diskriminasi kelas yang lebih baik dibandingkan pendekatan spasial.




Gambar 4.3 Kurva *training loss* dan *validation loss* pada eksperimen *baseline*.

Berdasarkan Gambar 4.3, kurva *training loss* pada model spasial dan spatiotemporal sama-sama menurun secara bertahap selama proses pelatihan. Pola ini menunjukkan bahwa kedua model mampu mempelajari pola dari data latih dengan baik. Sementara itu, *validation loss* pada kedua model masih menunjukkan fluktuasi pada beberapa *epoch*, tetapi tidak mengalami peningkatan secara terus-menerus. Hal ini mengindikasikan bahwa proses pelatihan masih berjalan stabil dan tidak menunjukkan gejala *overfitting* yang berat pada konfigurasi *baseline*.

Jika dibandingkan, model spatiotemporal menunjukkan nilai *validation loss* akhir yang lebih rendah dibandingkan model spasial. Kondisi ini menunjukkan bahwa model spatiotemporal memiliki kemampuan generalisasi yang lebih baik terhadap data validasi. Temuan tersebut sejalan dengan hasil evaluasi pada data uji, yaitu model spatiotemporal memperoleh performa yang lebih tinggi dibandingkan model spasial.


Berdasarkan Gambar 4.4, kurva *training accuracy* pada kedua model menunjukkan peningkatan secara bertahap dari awal hingga akhir pelatihan. *validation accuracy* juga memperlihatkan tren peningkatan dan cenderung



Gambar 4.4 Kurva *training accuracy* dan *validation accuracy* pada eksperimen *baseline*.

stabil pada *epoch* akhir. Hal ini menunjukkan bahwa kedua model mampu meningkatkan kemampuan klasifikasi selama proses pelatihan.

Namun, model spasiotemporal menghasilkan *validation accuracy* yang lebih tinggi dibandingkan model spasial. Dengan demikian, kurva *accuracy* memperkuat hasil pada Tabel 4.5 bahwa pendekatan spasiotemporal memiliki performa pembelajaran dan generalisasi yang lebih baik pada eksperimen *baseline*. Secara keseluruhan, pola kurva *loss* dan *accuracy* menunjukkan bahwa kedua model berhasil dilatih dengan stabil, tetapi model spasiotemporal memberikan hasil yang lebih unggul.



Gambar 4.5 *Confusion matrix* pada eksperimen *baseline*.

Berdasarkan *confusion matrix* pada Gambar 4.5, jumlah *false positive* dan *false negative* pada model spasial masih relatif tinggi. *False positive*

menunjukkan bahwa sebagian data *real* masih keliru diklasifikasikan sebagai *fake*. Kondisi ini mengindikasikan bahwa model spasial cenderung sensitif terhadap karakteristik visual tertentu yang dianggap menyerupai artefak manipulasi. Akibatnya, sebagian video *real* dengan variasi pencahayaan, pose, kompresi, atau kualitas visual tertentu dapat salah dikenali sebagai *fake*. Sementara itu, *false negative* menunjukkan bahwa sebagian data *fake* belum berhasil terdeteksi dan masih diklasifikasikan sebagai *real*. Hal ini memperlihatkan keterbatasan pendekatan spasial dalam menangkap klip *fake* yang artefak manipulasinya tidak cukup jelas pada tingkat *frame* individual.

Pada model spasiotemporal, jumlah *false positive* lebih rendah dibandingkan model spasial. Penurunan *false positive* ini menunjukkan bahwa *VideoMAE* lebih mampu membedakan variasi visual alami pada video *real* dari pola manipulasi pada video *fake*. Dengan kata lain, model spasiotemporal lebih jarang memberikan prediksi *fake* terhadap data yang sebenarnya *real*. Hal ini penting karena *false positive* yang tinggi dapat menyebabkan video asli keliru dianggap sebagai *deepfake*.

Selain itu, model spasiotemporal juga menghasilkan *false negative* yang lebih rendah dibandingkan model spasial, meskipun penurunannya tidak sebesar penurunan *false positive*. Hal ini menunjukkan bahwa pemanfaatan informasi temporal antar-*frame* membantu model dalam mendeteksi sebagian klip *fake* yang tidak cukup kuat apabila hanya dianalisis melalui informasi spasial pada *frame* tunggal. Namun, masih adanya *false negative* menunjukkan bahwa beberapa klip *fake* tetap sulit dikenali, terutama apabila pola manipulasinya halus atau tidak konsisten sepanjang *frame*.

Jika dibandingkan, peningkatan utama model spasiotemporal terlihat pada kemampuannya menekan *false positive* secara lebih besar dibandingkan model spasial. Artinya, keunggulan *VideoMAE* pada eksperimen *baseline* tidak hanya berasal dari peningkatan kemampuan mendeteksi kelas *fake*, tetapi juga dari peningkatan kemampuan mempertahankan data *real* agar tidak salah

diklasifikasikan sebagai *fake*. Pola ini sejalan dengan nilai *accuracy*, *F1*, dan *AUC* yang lebih tinggi pada model spasiotemporal.

Secara keseluruhan, hasil eksperimen *baseline* menunjukkan bahwa model spasiotemporal memberikan performa yang lebih baik dibandingkan model spasial. Keunggulan tersebut terlihat dari nilai metrik evaluasi yang lebih tinggi, pola kurva pelatihan yang lebih stabil, serta jumlah kesalahan klasifikasi yang lebih rendah pada *confusion matrix*. Oleh karena itu, hasil *baseline* ini digunakan sebagai acuan awal untuk menilai pengaruh perubahan konfigurasi pada tahap *ablation study*.

4.4.2 Hasil Konfigurasi Pelatihan

Pengujian konfigurasi pelatihan dilakukan untuk menganalisis pengaruh perubahan satu komponen pelatihan terhadap performa model spasial dan spasiotemporal. Pada setiap eksperimen, satu parameter diubah dari konfigurasi *baseline*, sedangkan parameter lainnya dipertahankan tetap. Dengan demikian, perubahan performa dapat dianalisis secara lebih terarah berdasarkan parameter yang diuji.

Setiap hasil konfigurasi pelatihan dibandingkan langsung dengan *baseline* BASE-SP dan BASE-ST. Model BASE-SP digunakan sebagai acuan pendekatan spasial, sedangkan BASE-ST digunakan sebagai acuan pendekatan spasiotemporal. Pembahasan disusun secara bertahap, dimulai dari pengaruh *epoch* maksimum, *learning rate*, *loss function*, augmentasi data, *dropout*, hingga *scheduler*. Pada setiap subbab, analisis difokuskan pada tujuan perubahan konfigurasi, alasan pemilihan nilai parameter, serta dampaknya terhadap metrik evaluasi model.

4.4.2.1 Pengaruh *Epoch* Maksimum

Eksperimen ini dilakukan untuk melihat apakah peningkatan jumlah *epoch* maksimum dapat meningkatkan performa model atau justru tidak memberikan

Tabel 4.6 Konfigurasi Pelatihan yang Diuji

Kode	Parameter	Nilai <i>Baseline</i>	Nilai Uji
M1	<i>Epoch</i>	25 <i>epoch</i>	40 <i>epoch</i>
M2	<i>Learning rate</i>	5e-5	5e-4
M3	<i>Loss function</i>	<i>Cross Entropy Loss</i>	<i>Focal Loss</i>
M4	Augmentasi data	Standar	Lebih berat
M5	<i>Dropout</i>	0	0,1
M6	<i>Scheduler</i>	<i>LinearDecayLR</i>	<i>CosineAnnealingLR</i>

perbaikan terhadap kemampuan generalisasi. Pada *baseline*, pelatihan dilakukan dengan *epoch* maksimum sebanyak **25 *epoch***. Pada eksperimen ini, *epoch* maksimum dinaikkan menjadi **40 *epoch***. Nilai tersebut dipilih untuk memberikan kesempatan pelatihan yang lebih panjang kepada model, tetapi tetap berada dalam batas komputasi yang wajar. Dengan demikian, eksperimen ini digunakan untuk mengamati apakah model spasial dan spatiotemporal masih memperoleh manfaat dari durasi pelatihan yang lebih panjang.


Tabel 4.7 Pengaruh *Epoch* Maksimum terhadap Performa Model

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M1-SP	78,0%	75,8%	77,5%	76,3%	85,1%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M1-ST	84,5%	82,5%	84,3%	83,2%	91,7%

Berdasarkan Tabel 4.7, peningkatan *epoch* maksimum dari 25 menjadi 40 tidak memberikan peningkatan performa pada kedua pendekatan. Pada model spasial, *accuracy* menurun dari 79,2% menjadi 78,0%, sedangkan *F1* menurun dari 76,7% menjadi 76,3%. Meskipun *recall* meningkat dari 76,7% menjadi 77,5%, peningkatan tersebut tidak diikuti oleh kenaikan *precision*, *accuracy*, maupun *AUC*. Hal ini menunjukkan bahwa tambahan *epoch* membuat model spasial sedikit lebih sensitif dalam mengenali kelas tertentu, tetapi tidak meningkatkan kualitas klasifikasi secara keseluruhan.

Pada model spatiotemporal, penambahan *epoch* juga menurunkan performa pada seluruh metrik utama. *accuracy* menurun dari 85,8% menjadi 84,5%, *F1* menurun dari 84,5% menjadi 83,2%, dan *AUC* menurun dari 92,3% menjadi 91,7%. Penurunan ini menunjukkan bahwa pelatihan lebih lama tidak memberikan keuntungan tambahan bagi VideoMAE pada konfigurasi ini.

Untuk mendukung hasil tersebut, Gambar 4.6 menampilkan kurva *training loss* dan *validation loss* pada konfigurasi 40 *epoch* untuk model spasial dan spatiotemporal.



Gambar 4.6 Kurva *training loss* dan *validation loss* pada eksperimen *epoch* maksimum 40: (a) Model spasial dan (b) Model spatiotemporal.

Secara umum, *training loss* pada kedua model terus menurun hingga akhir pelatihan, yang menunjukkan bahwa model semakin menyesuaikan diri terhadap data latih. Namun, *validation loss* tidak menunjukkan penurunan yang konsisten dan cenderung berfluktuasi pada *epoch-epoch* lanjutan. Pola ini menunjukkan bahwa penambahan *epoch* tidak lagi memberikan perbaikan pada data validasi.

Pada model spasial, fluktuasi *validation loss* mulai terlihat setelah pertengahan pelatihan dan cenderung bertahan hingga akhir *epoch*. Sementara itu, pada model spatiotemporal, *validation loss* juga menunjukkan pola yang tidak stabil, bahkan beberapa kali meningkat meskipun *training loss* terus menurun. Kondisi tersebut menunjukkan adanya kecenderungan model untuk terus menyesuaikan diri pada data latih tanpa diikuti peningkatan kemampuan generalisasi pada data validasi.

Dengan demikian, analisis kurva *loss* sejalan dengan hasil evaluasi pada

Tabel 4.7, yaitu bahwa penambahan *epoch* maksimum menjadi 40 belum memberikan manfaat pada kedua pendekatan. Sebaliknya, konfigurasi ini cenderung membuat proses pelatihan berlangsung lebih lama tanpa menghasilkan peningkatan performa pada data uji. Oleh karena itu, konfigurasi *baseline* 25 *epoch* dinilai sudah memadai dan lebih efisien dibandingkan konfigurasi 40 *epoch*.

4.4.2.2 Pengaruh *Learning Rate*


Setelah pengaruh *epoch* maksimum dianalisis, eksperimen berikutnya dilakukan untuk melihat sensitivitas model terhadap perubahan *learning rate*. Pada *baseline*, *learning rate* yang digunakan adalah 5e-5. Pada eksperimen ini, *learning rate* dinaikkan menjadi 5e-4. Nilai tersebut dipilih untuk menguji apakah pembaruan bobot yang lebih besar dapat mempercepat adaptasi model terhadap *dataset* atau justru menurunkan stabilitas proses *fine-tuning*.

Tabel 4.8 Pengaruh *Learning Rate* terhadap Performa Model

Kode	Acc	Prec	Rec	F1	AUC
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M2-SP	64,0%	58,9%	58,3%	58,5%	64,2%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M2-ST	60,4%	55,4%	55,2%	55,3%	57,4%

Untuk mendukung analisis terhadap penurunan performa tersebut, kurva *training loss* dan *validation loss* pada eksperimen *learning rate* 5e-4 ditunjukkan pada Gambar 4.7.

Berdasarkan Tabel 4.8, peningkatan *learning rate* menjadi 5e-4 menyebabkan penurunan performa yang signifikan pada kedua pendekatan. Penurunan tersebut terlihat pada seluruh metrik evaluasi, baik pada model spasial maupun spatiotemporal. Hal ini menunjukkan bahwa *learning rate* yang lebih besar tidak membuat proses *fine-tuning* menjadi lebih baik, tetapi justru mengganggu kestabilan pembelajaran model.



Gambar 4.7 Kurva *training loss* dan *validation loss* pada eksperimen *learning rate* $5e-4$: (a) model spasial dan (b) model spasiotemporal.

Pola pada Gambar 4.7 memperkuat temuan tersebut. Pada kedua model, *training loss* terus menurun selama proses pelatihan, tetapi *validation loss* tidak mengikuti pola penurunan yang sama. *Validation loss* justru cenderung berfluktuasi dan berada pada nilai yang relatif tinggi sepanjang pelatihan. Pola ini menunjukkan bahwa model masih mampu menyesuaikan diri terhadap data latih, tetapi penyesuaian tersebut tidak menghasilkan peningkatan kemampuan generalisasi pada data validasi. Dengan demikian, *learning rate* $5e-4$ membuat proses *fine-tuning* menjadi tidak stabil dan menyebabkan jarak antara performa pelatihan dan validasi semakin jelas.

Anomali yang paling menonjol terlihat pada model spasiotemporal M2-ST. Pada konfigurasi *baseline*, model spasiotemporal BASE-ST menghasilkan *accuracy* sebesar 85,8% dan *AUC* sebesar 92,3%. Namun, ketika *learning rate* dinaikkan menjadi $5e-4$, performa M2-ST turun menjadi *accuracy* 60,4% dan *AUC* 57,4%. Penurunan ini bahkan membuat performa M2-ST lebih rendah dibandingkan M2-SP. Dengan demikian, eksperimen ini menunjukkan bahwa model spasiotemporal lebih sensitif terhadap *learning rate* tinggi dibandingkan model spasial.

Secara teoretis, sensitivitas tersebut dapat dijelaskan dari kompleksitas representasi yang dipelajari oleh *VideoMAE*. Berbeda dari model spasial yang memproses *frame* secara individual, *VideoMAE* memodelkan hubungan spasial dan temporal secara bersamaan melalui representasi klip video. Mekanisme

ini membuat model harus mempertahankan koordinasi antara informasi visual pada setiap *frame* dan relasi temporal antar-*frame*. Akibatnya, lanskap optimasi pada model spasiotemporal cenderung lebih kompleks dibandingkan pendekatan spasial murni. Ketika *learning rate* terlalu besar, langkah pembaruan bobot menjadi terlalu agresif dan berisiko melewati area solusi yang stabil selama proses *fine-tuning*.

Penurunan tajam pada M2-ST juga dapat diinterpretasikan sebagai indikasi terganggunya representasi *pretrained* yang dimiliki *VideoMAE*. Model *VideoMAE* yang digunakan pada penelitian ini telah memiliki representasi awal dari proses *pre-training* pada *dataset* video. Representasi tersebut mencakup pola spasial dan temporal yang telah dipelajari sebelum model diadaptasikan ke tugas klasifikasi *deepfake*. *Learning rate* yang terlalu besar dapat mengubah bobot model secara agresif, terutama pada fitur temporal yang bersifat halus dan bergantung pada keteraturan hubungan antar-*frame*. Kondisi ini dapat dikaitkan dengan indikasi *catastrophic forgetting*, yaitu ketika representasi yang telah dipelajari sebelumnya mengalami degradasi akibat proses *fine-tuning* yang terlalu agresif.

Pada model spasial, penurunan performa juga terjadi, tetapi tidak sedrastis model spasiotemporal. Hal ini dapat terjadi karena *ViT* hanya memproses informasi visual statis pada tingkat *frame*, sehingga struktur representasi yang perlu disesuaikan selama *fine-tuning* relatif lebih sederhana dibandingkan *VideoMAE*. Dengan kata lain, pembaruan bobot yang besar tetap merugikan model spasial, tetapi dampaknya tidak sebesar pada model yang harus menjaga keterkaitan representasi ruang dan waktu secara simultan.

Jika dibandingkan dengan eksperimen *epoch* maksimum, perubahan *learning rate* memberikan dampak yang jauh lebih besar terhadap penurunan performa. Oleh karena itu, *learning rate* $5e-4$ dinilai terlalu besar untuk proses *fine-tuning* pada penelitian ini. Konfigurasi *baseline* dengan *learning rate* $5e-5$ tetap lebih sesuai karena menghasilkan proses optimasi yang lebih stabil

dan mampu mempertahankan representasi *pretrained* pada kedua pendekatan, khususnya pada model spasiotemporal yang lebih sensitif terhadap pembaruan bobot yang agresif.

4.4.2.3 Pengaruh *Loss Function*

Setelah pengaruh *learning rate* dianalisis, eksperimen berikutnya dilakukan untuk melihat pengaruh fungsi *loss* terhadap performa model. Pada *baseline*, fungsi *loss* yang digunakan adalah *Cross Entropy Loss*. Pada eksperimen ini, fungsi *loss* diubah menjadi *Focal Loss*. Pemilihan *Focal Loss* didasarkan pada karakteristiknya yang memberikan bobot lebih besar terhadap sampel yang sulit diklasifikasikan, sehingga fungsi *loss* ini dapat digunakan untuk mengevaluasi apakah model menjadi lebih baik dalam menangani kesalahan klasifikasi yang masih muncul pada konfigurasi *baseline*. Dalam konteks klasifikasi *deepfake*, pengujian ini penting karena kesalahan model tidak hanya dilihat dari jumlah prediksi benar secara umum, tetapi juga dari pola *false positive* dan *false negative* pada kelas *real* dan *fake*.


Tabel 4.9 Pengaruh *Loss Function* terhadap Performa Model

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M3-SP	81,8%	79,7%	81,3%	80,3%	88,1%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M3-ST	83,5%	81,8%	84,7%	82,5%	92,1%

Berdasarkan Tabel 4.9, penggunaan *Focal Loss* memberikan dampak yang berbeda pada model spasial dan spasiotemporal. Pada model spasial, *Focal Loss* meningkatkan seluruh metrik evaluasi dibandingkan *baseline*. Peningkatan ini menunjukkan bahwa perubahan fungsi *loss* membantu model spasial dalam menghasilkan keputusan klasifikasi yang lebih baik pada data uji. Dengan demikian, pendekatan spasial memperoleh manfaat yang cukup jelas dari penggunaan *Focal Loss*.


Sebaliknya, pada model spasiotemporal, penggunaan *Focal Loss* tidak memberikan peningkatan performa secara keseluruhan. *Accuracy*, *precision*, *recall*, *F1*, dan *AUC* cenderung lebih rendah dibandingkan *baseline Cross Entropy Loss*. Meskipun penurunannya tidak sebesar eksperimen *learning rate*, hasil ini menunjukkan bahwa *Focal Loss* tidak selalu memberikan manfaat yang sama pada model yang telah memanfaatkan informasi temporal. Dengan kata lain, pengaruh *Focal Loss* bergantung pada karakteristik model yang digunakan.

Untuk menganalisis perubahan pola kesalahan secara lebih rinci, *confusion matrix baseline* dan *Focal Loss* ditunjukkan pada Gambar 4.8 dan Gambar 4.9.



Gambar 4.8 *Confusion matrix* model spasial pada *Cross Entropy Loss* dan *Focal Loss*.

Berdasarkan Gambar 4.8, penggunaan *Focal Loss* pada model spasial mampu menurunkan *false positive* dibandingkan *Cross Entropy Loss*. Artinya, jumlah data *real* yang salah diprediksi sebagai *fake* menjadi lebih sedikit. Penurunan *false positive* ini menunjukkan bahwa *Focal Loss* membantu model spasial menjadi lebih hati-hati dalam memberikan prediksi *fake* terhadap data *real*. Namun, penurunan *false positive* tersebut disertai dengan peningkatan *false negative*, sehingga sebagian data *fake* menjadi lebih banyak yang tidak terdeteksi dibandingkan *baseline*. Meskipun demikian, secara keseluruhan perubahan ini tetap menghasilkan peningkatan metrik pada model spasial.



Gambar 4.9 *Confusion matrix* model spasiotemporal pada *Cross Entropy Loss* dan *Focal Loss*.

Pada model spasiotemporal, pola yang ditunjukkan pada Gambar 4.9 juga memperlihatkan penurunan *false positive* setelah menggunakan *Focal Loss*. Model menjadi lebih jarang mengklasifikasikan data *real* sebagai *fake*. Akan tetapi, peningkatan *false negative* pada model spasiotemporal lebih besar dibandingkan model spasial. Kondisi ini menunjukkan bahwa *Focal Loss* membuat model spasiotemporal menjadi lebih konservatif dalam memprediksi kelas *fake*, sehingga sebagian data *fake* justru diklasifikasikan sebagai *real*. Pola tersebut menjelaskan mengapa metrik evaluasi model spasiotemporal menurun dibandingkan *baseline*, meskipun *false positive* berhasil ditekan.

Secara keseluruhan, eksperimen ini menunjukkan bahwa *Focal Loss* efektif dalam mengurangi *false positive* pada kedua pendekatan, tetapi memiliki konsekuensi berupa peningkatan *false negative*. Pada model spasial, perubahan tersebut masih menghasilkan peningkatan performa secara keseluruhan. Namun, pada model spasiotemporal, peningkatan *false negative* membuat performa akhir lebih rendah dibandingkan *baseline*. Oleh karena itu, *Focal Loss* dapat meningkatkan ketepatan model dalam menghindari kesalahan prediksi *fake* pada data *real*, tetapi belum tentu optimal apabila tujuan utama adalah mempertahankan kemampuan deteksi terhadap seluruh data *fake*.

4.4.2.4 Pengaruh Augmentasi Data

Setelah pengaruh *loss function* dianalisis, eksperimen berikutnya dilakukan untuk melihat pengaruh augmentasi data terhadap performa model. Pada *baseline*, augmentasi diterapkan dengan konfigurasi standar yang terdiri atas transformasi geometri, perubahan warna, *blur*, dan *noise*. Pada eksperimen ini, konfigurasi augmentasi dibuat lebih berat untuk menguji apakah peningkatan variasi visual pada data latih dapat membantu model menjadi lebih *robust* terhadap karakteristik data *in-the-wild*. Pengujian ini relevan karena data video *deepfake* dunia nyata memiliki variasi visual yang beragam, seperti perubahan pose, pencahayaan, kualitas kompresi, *blur*, dan *noise*.

Tabel 4.10 Pengaruh Augmentasi Data terhadap Performa Model

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M4-SP	71,8%	69,7%	71,4%	70,1%	77,5%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M4-ST	81,4%	79,2%	79,3%	79,3%	87,9%

Berdasarkan Tabel 4.10, penggunaan augmentasi yang lebih berat menyebabkan penurunan performa pada kedua pendekatan. Pada model spasial, penurunan terlihat pada seluruh metrik evaluasi, terutama *accuracy*, *F1*, dan *AUC*. Hal ini menunjukkan bahwa augmentasi yang terlalu kuat tidak membantu model spasial dalam meningkatkan generalisasi, tetapi justru dapat mengubah karakteristik visual yang dibutuhkan untuk membedakan kelas *real* dan *fake*.

Penurunan juga terjadi pada model spatiotemporal, meskipun performanya tetap lebih tinggi dibandingkan model spasial pada konfigurasi augmentasi yang sama. Hasil ini menunjukkan bahwa *VideoMAE* masih lebih stabil dalam menghadapi variasi visual tambahan, tetapi augmentasi yang lebih berat tetap menurunkan kemampuan model dalam mengenali pola klasifikasi pada data uji. Dengan demikian, penambahan intensitas augmentasi tidak selalu menghasilkan

peningkatan performa, terutama apabila transformasi yang diberikan terlalu mengganggu informasi visual yang relevan.

Jika dibandingkan dengan *baseline*, konfigurasi augmentasi standar lebih sesuai untuk kedua pendekatan. Augmentasi tetap diperlukan untuk meningkatkan keragaman data latih, tetapi intensitasnya perlu dikendalikan agar tidak mengaburkan artefak visual atau pola temporal yang menjadi dasar klasifikasi *deepfake*. Secara keseluruhan, eksperimen ini menunjukkan bahwa augmentasi yang lebih berat tidak dipilih sebagai konfigurasi lanjutan karena menurunkan performa model spasial maupun spasiotemporal.

4.4.2.5 Pengaruh Dropout

Setelah pengaruh augmentasi data dianalisis, eksperimen berikutnya dilakukan untuk melihat pengaruh regularisasi dari sisi model melalui *dropout*. Pada *baseline*, nilai *dropout* yang digunakan adalah 0, sedangkan pada eksperimen ini nilai *dropout* dinaikkan menjadi 0,1. Nilai tersebut dipilih untuk menguji apakah regularisasi tambahan dapat membantu model mengurangi ketergantungan terhadap pola tertentu pada data latih. Pengujian ini relevan karena model berbasis *Transformer* memiliki kapasitas representasi yang besar, sehingga regularisasi dapat berperan dalam mengendalikan risiko *overfitting* selama proses *fine-tuning*.

Tabel 4.11 Pengaruh *Dropout* terhadap Performa Model

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M5-SP	79,4%	77,0%	77,9%	77,4%	87,1%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M5-ST	83,8%	82,0%	84,7%	82,8%	91,0%

Berdasarkan Tabel 4.11, penggunaan *dropout* 0,1 memberikan dampak yang berbeda pada model spasial dan spasiotemporal. Pada model spasial, *dropout* memberikan peningkatan kecil pada seluruh metrik evaluasi.

Peningkatan tersebut menunjukkan bahwa regularisasi tambahan dapat membantu model spasial menghasilkan keputusan klasifikasi yang sedikit lebih baik dibandingkan *baseline*. Hal ini mengindikasikan bahwa model spasial memperoleh manfaat dari pembatasan ketergantungan terhadap pola visual tertentu pada data latih.

Namun, pengaruh *dropout* pada model spasiotemporal menunjukkan pola yang berbeda. Pada model *VideoMAE*, penggunaan *dropout* 0,1 justru menurunkan performa dibandingkan *baseline*. Penurunan tersebut terlihat pada *accuracy*, *precision*, *recall*, *F1*, dan *AUC*. Hal ini menunjukkan bahwa regularisasi tambahan tidak selalu memberikan manfaat pada model spasiotemporal, khususnya ketika model sudah memiliki representasi *pretrained* yang kuat dan memproses informasi dalam bentuk klip video.

Jika dibandingkan dengan *baseline*, *dropout* 0,1 dapat memberikan perbaikan terbatas pada pendekatan spasial, tetapi tidak memberikan keuntungan pada pendekatan spasiotemporal. Dengan demikian, *dropout* tidak dipilih sebagai konfigurasi utama yang dilanjutkan, karena pengaruhnya tidak konsisten pada kedua pendekatan. Hasil ini juga menunjukkan bahwa regularisasi model perlu diterapkan secara hati-hati, sebab konfigurasi yang membantu model spasial belum tentu memberikan dampak yang sama pada model spasiotemporal.

4.4.2.6 Pengaruh *Scheduler*

Setelah pengaruh *dropout* dianalisis, eksperimen berikutnya dilakukan untuk melihat pengaruh *scheduler* terhadap performa model. Pada *baseline*, *scheduler* yang digunakan adalah *LinearDecayLR*, sedangkan pada eksperimen ini digunakan *CosineAnnealingLR*. Eksperimen ini dilakukan untuk menguji apakah pola penurunan *learning rate* yang berbeda dapat menghasilkan proses optimasi yang lebih baik. *Scheduler* menjadi komponen penting dalam *fine-tuning* karena tidak hanya menentukan nilai awal *learning rate*, tetapi juga mengatur perubahan *learning rate* selama pelatihan berlangsung.

Tabel 4.12 Pengaruh *Scheduler* terhadap Performa Model

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
BASE-SP	79,2%	76,8%	76,7%	76,7%	86,8%
M6-SP	82,5%	80,4%	80,7%	80,6%	88,7%
BASE-ST	85,8%	83,8%	85,5%	84,5%	92,3%
M6-ST	84,1%	82,1%	84,4%	82,9%	91,5%

Berdasarkan Tabel 4.12, penggunaan *CosineAnnealingLR* memberikan dampak yang berbeda pada model spasial dan spasiotemporal. Pada model spasial, *CosineAnnealingLR* menghasilkan peningkatan pada seluruh metrik evaluasi dibandingkan *baseline*. Peningkatan ini menunjukkan bahwa pola penurunan *learning rate* berbasis *cosine* lebih membantu proses optimasi model spasial dibandingkan *LinearDecayLR*.

Pada model spasiotemporal, penggunaan *CosineAnnealingLR* tidak menghasilkan peningkatan dibandingkan *baseline*. Nilai *accuracy*, *precision*, *recall*, *F1*, dan *AUC* lebih rendah daripada konfigurasi awal. Meskipun demikian, penurunan performa pada model spasiotemporal tidak sebesar penurunan yang terjadi pada beberapa variasi *ablation* lain, seperti *learning rate* yang lebih besar atau augmentasi yang lebih berat. Hal ini menunjukkan bahwa *CosineAnnealingLR* masih menghasilkan performa yang relatif kompetitif pada model spasiotemporal.

Jika dilihat secara komparatif, *CosineAnnealingLR* memberikan keuntungan yang lebih jelas pada pendekatan spasial, sementara pendekatan spasiotemporal tetap lebih baik pada *baseline LinearDecayLR*. Oleh karena itu, pemilihan konfigurasi *scheduler* tidak hanya didasarkan pada performa salah satu model, tetapi mempertimbangkan rata-rata *accuracy* dari kedua pendekatan. Berdasarkan kriteria tersebut, konfigurasi *CosineAnnealingLR* memberikan rata-rata *accuracy* yang lebih tinggi dibandingkan *baseline*, sehingga dipilih sebagai konfigurasi pelatihan untuk eksperimen utama.

Secara keseluruhan, hasil *ablation study* menunjukkan bahwa setiap perubahan konfigurasi memberikan pengaruh yang berbeda pada model spasial dan spatiotemporal. Beberapa konfigurasi hanya meningkatkan salah satu pendekatan, sedangkan konfigurasi lainnya menurunkan performa pada kedua pendekatan. Pada tahap ini, *scheduler* dipilih sebagai konfigurasi lanjutan karena memberikan hasil rata-rata yang paling baik untuk digunakan secara adil pada kedua model. Dengan demikian, eksperimen utama pada subbab berikutnya menggunakan konfigurasi *scheduler* hasil *ablation study* sebagai dasar pelatihan.

4.4.3 Hasil Konfigurasi Input Spasial dan Temporal

Pengujian konfigurasi input spasial dan temporal dilakukan untuk mengevaluasi pengaruh perubahan karakteristik masukan terhadap performa model spasial dan spatiotemporal. Berbeda dari pengujian konfigurasi pelatihan yang berfokus pada parameter optimasi dan regularisasi, bagian ini berfokus pada perubahan bentuk input yang diterima model, yaitu resolusi, jumlah *frame*, dan *stride*. Konfigurasi BASE telah digunakan dan dianalisis sebelumnya pada eksperimen *baseline* sebagai konfigurasi dasar, yaitu resolusi 224×224 , jumlah *frame* masukan 16, dan *stride* 3. Oleh karena itu, pada bagian ini BASE digunakan sebagai acuan konfigurasi, sedangkan eksperimen E2 sampai E5 digunakan untuk menganalisis pengaruh variasi input terhadap performa kedua pendekatan.

Tabel 4.13 Konfigurasi Input Spasial dan Temporal

Kode	Variasi Eksperimen	Resolusi	Frame	Stride
BASE-SP / BASE-ST	Konfigurasi dasar	224×224	16	3
E2-SP / E2-ST	Penurunan resolusi	112×112	16	3
E3-SP / E3-ST	Stride lebih rapat	224×224	16	1
E4-SP / E4-ST	Frame lebih sedikit	224×224	8	3
E5-SP / E5-ST	Frame lebih banyak	224×224	24	1

4.4.3.1 Eksperimen Penurunan Resolusi

Eksperimen penurunan resolusi dilakukan untuk mengevaluasi pengaruh berkurangnya informasi spasial terhadap performa model. Pada konfigurasi ini, resolusi masukan diturunkan menjadi 112×112 piksel. Pengujian ini penting karena data video dunia nyata tidak selalu berada dalam kualitas visual yang ideal. Video yang beredar di internet dapat mengalami penurunan resolusi, kompresi, *blur*, atau degradasi visual lain yang berpotensi mengurangi detail wajah. Oleh karena itu, eksperimen ini digunakan untuk melihat sejauh mana model spasial dan spatiotemporal tetap mampu melakukan klasifikasi ketika informasi visual pada *frame* menjadi lebih terbatas.

Tabel 4.14 Hasil Eksperimen Penurunan Resolusi

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
E2-SP	76,0%	73,8%	75,6%	74,3%	84,6%
E2-ST	78,4%	75,9%	76,7%	76,2%	84,9%

Berdasarkan Tabel 4.14, penurunan resolusi menghasilkan performa yang lebih terbatas pada kedua pendekatan. Pada model spasial, nilai metrik menunjukkan bahwa berkurangnya detail visual pada *frame* memengaruhi kemampuan model dalam membedakan kelas *real* dan *fake*. Hal ini dapat terjadi karena pendekatan spasial bergantung pada informasi visual statis dari setiap *frame*, sehingga detail kecil seperti tekstur wajah, batas area manipulasi, atau artefak visual halus menjadi lebih sulit ditangkap ketika resolusi masukan diturunkan.

Pada model spatiotemporal, performa yang diperoleh lebih tinggi dibandingkan model spasial pada konfigurasi resolusi rendah. Hasil ini menunjukkan bahwa meskipun informasi spasial pada setiap *frame* berkurang, model spatiotemporal masih dapat memanfaatkan hubungan antar-*frame* sebagai sumber informasi tambahan. Dengan demikian, *VideoMAE* relatif lebih mampu mempertahankan performa pada kondisi resolusi rendah dibandingkan model

spasial.

Secara umum, eksperimen ini menunjukkan bahwa resolusi masukan merupakan faktor penting dalam klasifikasi video *deepfake*. Penurunan resolusi dapat mengurangi detail visual yang dibutuhkan model untuk mengenali pola manipulasi, terutama pada artefak yang bersifat halus. Namun, pendekatan spasiotemporal menunjukkan ketahanan yang lebih baik pada konfigurasi ini karena tidak hanya bergantung pada informasi spasial per *frame*, tetapi juga memanfaatkan konteks temporal dalam satu klip.

4.4.3.2 Eksperimen *Stride* Lebih Rapat

Eksperimen *stride* lebih rapat dilakukan untuk mengevaluasi pengaruh kepadatan sampling temporal terhadap performa model. Pada konfigurasi ini, jumlah *frame* masukan tetap sebanyak 16 *frame*, tetapi nilai *stride* dibuat lebih rapat menjadi 1 dari yang sebelumnya 3. Dengan demikian, *frame* yang digunakan berasal dari posisi temporal yang lebih berdekatan. Pengujian ini dilakukan untuk melihat apakah penggunaan *frame* yang lebih rapat dapat membantu model menangkap perubahan visual yang lebih halus antar-*frame*, atau justru menghasilkan informasi yang lebih redundan karena jarak temporal antar-*frame* menjadi terlalu dekat.

Tabel 4.15 Hasil Eksperimen *Stride* Lebih Rapat

Kode	Acc	Prec	Rec	F1	AUC
E3-SP	81,0%	78,7%	79,6%	79,1%	88,0%
E3-ST	82,9%	80,9%	83,1%	81,6%	90,1%

Berdasarkan Tabel 4.15, konfigurasi *stride* lebih rapat menghasilkan performa yang cukup baik pada kedua pendekatan. Pada model spasial, hasil ini menunjukkan bahwa penggunaan *frame* yang lebih berdekatan tetap dapat memberikan evidensi visual yang berguna ketika prediksi *frame-level* diagregasi menjadi prediksi tingkat klip. Hal ini mengindikasikan bahwa *frame* yang rapat

masih memuat variasi visual yang cukup untuk membantu model membedakan kelas *real* dan *fake*.

Pada model spasiotemporal, performa yang diperoleh tetap lebih tinggi dibandingkan model spasial. Hal ini menunjukkan bahwa *VideoMAE* masih memperoleh manfaat dari hubungan antar-*frame*, meskipun *frame* yang digunakan memiliki jarak temporal yang lebih dekat. Akan tetapi, konfigurasi *stride* 1 juga membuat cakupan temporal menjadi lebih sempit karena *frame* yang dipilih berada pada rentang waktu yang lebih pendek. Kondisi ini dapat membatasi kemampuan model dalam menangkap perubahan temporal yang lebih luas pada satu klip.

Secara umum, eksperimen ini menunjukkan bahwa penggunaan *stride* yang lebih rapat dapat mempertahankan performa klasifikasi pada kedua pendekatan, terutama karena *frame* yang diproses memiliki kontinuitas visual yang lebih tinggi. Namun, kepadatan sampling temporal yang lebih besar tidak selalu berarti informasi temporal yang diperoleh menjadi lebih kaya. Pada konfigurasi ini, *frame* yang terlalu berdekatan dapat meningkatkan redundansi antar-*frame*, sehingga manfaatnya terhadap model spasiotemporal tidak sepenuhnya optimal. Oleh karena itu, pemilihan *stride* perlu mempertimbangkan keseimbangan antara kepadatan informasi antar-*frame* dan cakupan temporal yang ingin direpresentasikan.

4.4.3.3 Eksperimen *Frame* Lebih Sedikit

Eksperimen *frame* lebih sedikit dilakukan untuk mengevaluasi pengaruh pengurangan jumlah *frame* masukan terhadap performa model. Pada konfigurasi ini, jumlah *frame* masukan dikurangi menjadi 8 *frame*. Pengujian ini dilakukan untuk melihat apakah jumlah *frame* yang lebih sedikit masih cukup merepresentasikan informasi visual dalam satu klip, atau justru mengurangi evidensi yang dibutuhkan model dalam membedakan kelas *real* dan *fake*.

Berdasarkan Tabel 4.16, pengurangan jumlah *frame* masukan memberikan

Tabel 4.16 Hasil Eksperimen *Frame* Lebih Sedikit

Kode	Acc	Prec	Rec	F1	AUC
E4-SP	78,4%	75,9%	76,7%	76,3%	85,8%
E4-ST	85,0%	83,5%	86,7%	84,2%	92,4%

dampak yang berbeda pada model spasial dan spasiotemporal. Pada model spasial, performa yang diperoleh menunjukkan bahwa jumlah *frame* yang lebih sedikit masih dapat digunakan untuk melakukan klasifikasi, tetapi kemampuan model menjadi lebih terbatas. Hal ini dapat terjadi karena model spasial melakukan prediksi pada tingkat *frame*, kemudian hasilnya diagregasi pada tingkat klip. Ketika jumlah *frame* berkurang, jumlah evidensi visual yang digunakan dalam proses agregasi juga berkurang, sehingga keputusan akhir model menjadi lebih bergantung pada informasi dari *frame* yang lebih sedikit.

Pada model spasiotemporal, performa yang diperoleh tetap relatif tinggi. Hal ini menunjukkan bahwa *VideoMAE* masih mampu memanfaatkan informasi antar-*frame* meskipun jumlah *frame* masukan dikurangi. Nilai *recall* yang tinggi mengindikasikan bahwa model spasiotemporal tetap cukup baik dalam mengenali klip *fake* pada konfigurasi *frame* yang lebih sedikit. Dengan demikian, representasi spasiotemporal masih dapat bekerja secara efektif meskipun konteks temporal yang diberikan lebih terbatas.

Secara umum, eksperimen ini menunjukkan bahwa pengurangan jumlah *frame* tidak selalu menyebabkan penurunan performa yang besar, terutama pada model spasiotemporal. Namun, pada pendekatan spasial, jumlah *frame* yang lebih sedikit dapat mengurangi jumlah bukti visual yang tersedia untuk membentuk prediksi tingkat klip. Oleh karena itu, konfigurasi *frame* lebih sedikit dapat menjadi alternatif yang lebih efisien, tetapi perlu dipertimbangkan berdasarkan keseimbangan antara kebutuhan komputasi dan stabilitas performa model.

4.4.3.4 Eksperimen *Frame* Lebih Banyak

Eksperimen *frame* lebih banyak dilakukan untuk mengevaluasi pengaruh penambahan jumlah *frame* masukan terhadap performa model. Pada konfigurasi ini, jumlah *frame* masukan ditingkatkan menjadi 24 *frame* dengan *stride* 1. Dengan demikian, model memperoleh representasi temporal yang lebih panjang dan lebih rapat dibandingkan konfigurasi dasar. Pengujian ini dilakukan untuk melihat apakah penambahan jumlah *frame* dapat memberikan informasi visual dan temporal yang lebih kaya, atau justru menghasilkan redundansi karena *frame* yang digunakan memiliki jarak temporal yang sangat dekat.

Tabel 4.17 Hasil Eksperimen *Frame* Lebih Banyak

Kode	<i>Acc</i>	<i>Prec</i>	<i>Rec</i>	<i>F1</i>	<i>AUC</i>
E5-SP	80,2%	78,1%	80,1%	78,8%	88,4%
E5-ST	85,1%	83,3%	86,3%	84,1%	92,7%

Berdasarkan Tabel 4.17, penambahan jumlah *frame* menghasilkan performa yang baik pada kedua pendekatan. Pada model spasial, penggunaan 24 *frame* memberikan lebih banyak evidensi visual *frame-level* sebelum hasil prediksi diagregasi pada tingkat klip. Dengan jumlah *frame* yang lebih banyak, keputusan akhir model tidak hanya bergantung pada sedikit *frame*, tetapi dibentuk dari cakupan informasi visual yang lebih luas. Hal ini dapat membantu model spasial dalam menangkap variasi tampilan wajah pada satu klip.

Pada model spasiotemporal, konfigurasi 24 *frame* dengan *stride* 1 menghasilkan performa yang lebih tinggi dibandingkan model spasial. Hasil ini menunjukkan bahwa *VideoMAE* mampu memanfaatkan tambahan *frame* untuk membangun representasi spasiotemporal yang lebih kuat. Nilai *AUC* yang tinggi juga menunjukkan bahwa model spasiotemporal memiliki kemampuan diskriminatif yang baik dalam membedakan kelas *real* dan *fake* pada konfigurasi ini.

Namun, konfigurasi *frame* lebih banyak juga perlu dilihat secara hati-hati

karena penambahan *frame* dilakukan bersamaan dengan penggunaan *stride* yang rapat. *Frame* yang berdekatan dapat memperkaya kontinuitas temporal, tetapi juga berpotensi meningkatkan redundansi antar-*frame*. Oleh karena itu, peningkatan jumlah *frame* tidak selalu dapat dimaknai hanya sebagai penambahan informasi baru, melainkan sebagai kombinasi antara cakupan temporal yang lebih panjang, kepadatan sampling yang lebih tinggi, dan peningkatan jumlah evidensi visual yang diproses model.

Secara umum, eksperimen ini menunjukkan bahwa penggunaan *frame* lebih banyak dapat memberikan hasil yang kompetitif, terutama pada pendekatan spasiotemporal. *VideoMAE* tetap menunjukkan keunggulan dibandingkan model spasial karena mampu memproses seluruh *frame* sebagai satu klip dan memodelkan hubungan antar-*frame* secara langsung. Dengan demikian, konfigurasi *frame* lebih banyak memperkuat temuan bahwa informasi temporal memberikan kontribusi penting dalam klasifikasi video *deepfake*.

4.4.4 Evaluasi Lintas-Dataset

Evaluasi lintas-*dataset* dilakukan untuk mengukur kemampuan generalisasi model terhadap *dataset* eksternal yang memiliki distribusi berbeda dari *dataset* pelatihan. Pada penelitian ini, model dilatih menggunakan *dataset WildDeepfake*, kemudian dievaluasi pada *dataset Celeb-DF v2*. Evaluasi ini dilakukan secara *zero-shot*, yaitu model tidak dilatih ulang dan tidak dilakukan *fine-tuning* pada *dataset Celeb-DF v2*. Dengan demikian, *dataset Celeb-DF v2* hanya digunakan sebagai data uji eksternal untuk menilai ketahanan model ketika dihadapkan pada karakteristik data yang berbeda dari *dataset* sumber.

Pada evaluasi ini, *checkpoint* model yang digunakan berasal dari hasil *ablation study scheduler*, yaitu M6-SP untuk model spasial dan M6-ST untuk model spasiotemporal. Hasil pengujian pada *Celeb-DF v2* diberi kode E6-SP untuk model spasial dan E6-ST untuk model spasiotemporal.

Berdasarkan Tabel 4.18, hasil evaluasi lintas-*dataset* menunjukkan adanya

Tabel 4.18 Hasil Evaluasi Lintas-Dataset pada Dataset *Celeb-DF v2*

Kode	Acc	Prec	Rec	F1	AUC
E6-SP	72,9%	69,9%	68,1%	68,7%	77,7%
E6-ST	64,2%	65,5%	67,1%	63,7%	72,6%

pembalikan performa. Pada eksperimen internal menggunakan *WildDeepfake*, model spasiotemporal secara umum menunjukkan performa yang lebih tinggi dibandingkan model spasial, khususnya pada eksperimen *baseline* dan eksperimen utama. Namun, ketika model diuji secara *zero-shot* pada *Celeb-DF v2*, pola tersebut berubah. Model spasial E6-SP memperoleh *accuracy* sebesar 72,9% dan *AUC* sebesar 77,7%, sedangkan model spasiotemporal E6-ST memperoleh *accuracy* sebesar 64,2% dan *AUC* sebesar 72,6%. Dengan demikian, model spasial justru lebih unggul dibandingkan model spasiotemporal pada skenario lintas-dataset.

Hal ini menunjukkan bahwa keunggulan model spasiotemporal pada dataset sumber tidak secara otomatis menghasilkan generalisasi yang lebih baik pada dataset eksternal. Pada dataset *WildDeepfake*, *VideoMAE* memperoleh keuntungan karena mampu memodelkan hubungan spasial dan temporal antar-frame melalui pemrosesan klip secara langsung. Akan tetapi, ketika model dipindahkan ke *Celeb-DF v2* tanpa *fine-tuning*, performa model spasiotemporal mengalami degradasi yang lebih besar. Jika dibandingkan dengan performa *baseline* pada *WildDeepfake*, *accuracy* model spasiotemporal menurun dari 85,8% menjadi 64,2%, atau turun sebesar 21,6 poin persentase. Penurunan ini lebih besar dibandingkan model spasial yang turun dari 82,5% pada M6-SP menjadi 72,9% pada E6-SP, atau turun sebesar 9,6 poin persentase.

Salah satu penjelasan teoretis terhadap penurunan yang lebih besar pada model spasiotemporal adalah adanya pergeseran distribusi temporal atau *temporal domain shift*. *WildDeepfake* merupakan dataset *in-the-wild* yang dikumpulkan dari video internet, sehingga memiliki variasi kondisi visual dan

temporal yang tinggi, seperti perbedaan kualitas video, kompresi, *frame rate*, pergerakan kamera, serta artefak temporal yang tidak seragam [9]. Dalam proses *fine-tuning* pada *dataset* tersebut, *VideoMAE* dapat mempelajari pola dinamika temporal yang spesifik terhadap karakteristik *WildDeepfake*. Melalui mekanisme *joint space-time attention*, model tidak hanya mempelajari artefak visual pada *frame*, tetapi juga relasi antar-*frame* dalam satu klip. Ketika pola temporal pada *Celeb-DF v2* berbeda dari *WildDeepfake*, representasi temporal yang dipelajari model pada *dataset* sumber dapat menjadi kurang relevan. Kondisi ini mengindikasikan bahwa model spasiotemporal berpotensi lebih rentan terhadap pergeseran domain temporal.

Sebaliknya, model spasial berbasis *ViT* hanya memproses informasi visual statis pada tingkat *frame*, kemudian melakukan agregasi prediksi pada tingkat klip. Karena tidak memodelkan hubungan temporal secara eksplisit, model spasial tidak terlalu bergantung pada pola gerakan, *frame rate*, atau dinamika antar-*frame* yang spesifik terhadap *dataset* sumber. Representasi yang dipelajari model spasial lebih berfokus pada artefak visual *frame-level*, seperti tekstur lokal, batas pencampuran wajah, ketidakwajaran detail visual, atau pola manipulasi statis lainnya. Fitur-fitur spasial tersebut cenderung lebih invarian terhadap perubahan domain temporal dibandingkan fitur spasiotemporal yang secara langsung melibatkan dimensi waktu. Hal ini dapat menjelaskan mengapa E6-SP memiliki penurunan performa yang lebih kecil dibandingkan E6-ST pada evaluasi *Celeb-DF v2*.

Perbedaan karakteristik *dataset* juga menjadi faktor penting dalam interpretasi hasil ini. *WildDeepfake* merepresentasikan data *in-the-wild* yang berasal dari internet, sedangkan *Celeb-DF v2* dikenal sebagai *dataset deepfake* yang dirancang dengan kualitas visual yang lebih baik dan lebih menantang dibandingkan *dataset* generasi awal [19]. Perbedaan sumber data, proses manipulasi, kualitas visual, dan karakteristik temporal dapat menyebabkan model yang telah beradaptasi dengan *WildDeepfake* tidak sepenuhnya sesuai ketika

diterapkan pada *Celeb-DF v2*. Dengan demikian, penurunan performa pada E6-SP dan E6-ST menunjukkan adanya *domain shift*, sedangkan pembalikan performa antara model spasial dan spasiotemporal menunjukkan bahwa fitur temporal yang efektif pada *dataset* sumber belum tentu memiliki tingkat transferabilitas yang sama pada *dataset* eksternal.

Secara keseluruhan, evaluasi lintas-*dataset* menunjukkan bahwa kemampuan generalisasi model masih menjadi tantangan penting dalam klasifikasi video *deepfake*. Pada eksperimen internal *WildDeepfake*, model spasiotemporal lebih unggul karena mampu memanfaatkan hubungan antar-*frame*. Namun, pada evaluasi *zero-shot* terhadap *Celeb-DF v2*, model spasial menunjukkan ketahanan yang lebih baik terhadap pergeseran domain. Temuan ini menunjukkan bahwa pendekatan spasiotemporal memiliki potensi kuat ketika distribusi data latih dan data uji relatif sejalan, tetapi dapat mengalami degradasi lebih besar ketika pola temporal pada *dataset* uji berbeda. Oleh karena itu, pengembangan model *deepfake* yang *robust* tidak hanya perlu mengejar performa tinggi pada *dataset* sumber, tetapi juga perlu mempertimbangkan kemampuan generalisasi lintas-*dataset*.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berisi kesimpulan dari hasil dan pembahasan terkait penelitian yang dilakukan, dapat juga berupa temuan yang Anda dapatkan setelah melakukan penelitian atau analisis terhadap tugas akhir Anda. Memberikan jawaban dari poin pada subbab Rumusan Masalah dan Tujuan Penelitian.

5.2 Saran

Berisi saran mengenai aspek tugas akhir atau temuan yang dapat dikembangkan dan diperkaya di tugas akhir selanjutnya. Saran dapat berkaitan erat pada subbab ??.

DAFTAR PUSTAKA

- [1] World Economic Forum (WEF). “The Global Risks Report 2026”. 21st Edition (2026). URL: https://reports.weforum.org/docs/WEF_Global_Risks_Report_2026.pdf.
- [2] Ruben Tolosana et al. “DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection” (June 2020).
- [3] Yisroel Mirsky and Wenke Lee. “The Creation and Detection of Deepfakes: A Survey”. *ACM Computing Surveys* 54.1 (2021), pp. 1–41. 1557-7341. URL: <http://dx.doi.org/10.1145/3425780>.
- [4] Bhaskardeep Khaund. “AI and Identity Security: The Threat of Deepfakes and the Future of Authentication”. *Journal of Information Systems Engineering and Management* 10.60s (Sept. 2025), pp. 1015–1030. 2468-4376.
- [5] Junyi Cao et al. “End-to-End Reconstruction-Classification Learning for Face Forgery Detection”. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, pp. 4103–4112.
- [6] Baoping Liu et al. “TI2Net: Temporal Identity Inconsistency Network for Deepfake Detection”. *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. 2023, pp. 4680–4689.
- [7] Zhihao Gu et al. “Spatiotemporal Inconsistency Learning for DeepFake Video Detection” (Oct. 2021).
- [8] Alexandros Haliassos et al. “Lips Don’t Lie: A Generalisable and Robust Approach to Face Forgery Detection” (Aug. 2021).
- [9] Bojia Zi et al. “WildDeepfake: A Challenging Real-World Dataset for Deepfake Detection” (July 2024).

- [10] Jongwook Choi et al. *Exploiting Style Latent Flows for Generalizing Deepfake Video Detection*. 2024. arXiv: [2403.06592 \[cs.CV\]](#). URL: <https://arxiv.org/abs/2403.06592>.
- [11] Alexey Dosovitskiy et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. 2021. arXiv: [2010.11929 \[cs.CV\]](#). URL: <https://arxiv.org/abs/2010.11929>.
- [12] Zhan Tong et al. *VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training*. 2022. arXiv: [2203.12602 \[cs.CV\]](#). URL: <https://arxiv.org/abs/2203.12602>.
- [13] Aminollah Khormali and Jiann-Shiun Yuan. “DFDT: An End-to-End DeepFake Detection Framework Using Vision Transformer”. *Applied Sciences* 12.6 (2022). 2076-3417. URL: <https://www.mdpi.com/2076-3417/12/6/2953>.
- [14] Wanyi Zhuang et al. *UIA-ViT: Unsupervised Inconsistency-Aware Method based on Vision Transformer for Face Forgery Detection*. 2022. arXiv: [2210.12752 \[cs.CV\]](#). URL: <https://arxiv.org/abs/2210.12752>.
- [15] Staffy Kingra, Naveen Aggarwal, and Nirmal Kaur. “SFormer: An end-to-end spatio-temporal transformer architecture for deepfake detection”. *Forensic Science International: Digital Investigation* 51 (2024), p. 301817. 2666-2817. URL: <https://www.sciencedirect.com/science/article/pii/S2666281724001410>.
- [16] Juan Hu et al. *Delocate: Detection and Localization for Deepfake Videos with Randomly-Located Tampered Traces*. 2024. arXiv: [2401.13516 \[cs.CV\]](#). URL: <https://arxiv.org/abs/2401.13516>.
- [17] Tero Karras, Samuli Laine, and Timo Aila. *A Style-Based Generator Architecture for Generative Adversarial Networks*. 2019. arXiv: [1812.04948 \[cs.NE\]](#). URL: <https://arxiv.org/abs/1812.04948>.
- [18] Ian J. Goodfellow et al. “Generative Adversarial Nets”. *Advances in Neural Information Processing Systems*. Ed. by Z. Ghahramani

- et al. Vol. 27. Curran Associates, Inc., 2014. URL: https://proceedings.neurips.cc/paper_files/paper/2014/file/f033ed80deb0234979a61f95710dbe25-Paper.pdf.
- [19] Yuezun Li et al. *Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics*. 2020. arXiv: [1909.12962](https://arxiv.org/abs/1909.12962) [cs.CR]. URL: <https://arxiv.org/abs/1909.12962>.
- [20] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep learning”. *Nature* 521.7553 (May 2015), pp. 436–444. 1476-4687. URL: <https://doi.org/10.1038/nature14539>.
- [21] Athanasios Voulodimos et al. “Deep Learning for Computer Vision: A Brief Review”. *Computational Intelligence and Neuroscience* 2018 (Feb. 2018). PMID: 29487619, p. 7068349. 1687-5273. URL: <https://doi.org/10.1155/2018/7068349>.
- [22] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: [1706.03762](https://arxiv.org/abs/1706.03762) [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- [23] Zhikan Wang et al. *A Timely Survey on Vision Transformer for Deepfake Detection*. 2024. arXiv: [2405.08463](https://arxiv.org/abs/2405.08463) [cs.CV]. URL: <https://arxiv.org/abs/2405.08463>.
- [24] Sayantan Das et al. *Unmasking Deepfakes: Masked Autoencoding Spatiotemporal Transformers for Enhanced Video Forgery Detection*. 2024. arXiv: [2306.06881](https://arxiv.org/abs/2306.06881) [cs.CV]. URL: <https://arxiv.org/abs/2306.06881>.
- [25] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. *Is Space-Time Attention All You Need for Video Understanding?* 2021. arXiv: [2102.05095](https://arxiv.org/abs/2102.05095) [cs.CV]. URL: <https://arxiv.org/abs/2102.05095>.
- [26] Anurag Arnab et al. *ViViT: A Video Vision Transformer*. 2021. arXiv: [2103.15691](https://arxiv.org/abs/2103.15691) [cs.CV]. URL: <https://arxiv.org/abs/2103.15691>.
- [27] Marina Sokolova and Guy Lapalme. “A systematic analysis of performance measures for classification tasks”. *Information Processing*

- & *Management* 45.4 (2009), pp. 427–437. 0306-4573. URL: <https://www.sciencedirect.com/science/article/pii/S0306457309000259>.
- [28] David M. W. Powers. *Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation*. 2020. arXiv: [2010.16061](https://arxiv.org/abs/2010.16061) [cs.LG]. URL: <https://arxiv.org/abs/2010.16061>.
- [29] Tom Fawcett. “An introduction to ROC analysis”. *Pattern Recognition Letters* 27.8 (2006). ROC Analysis in Pattern Recognition, pp. 861–874. 0167-8655. URL: <https://www.sciencedirect.com/science/article/pii/S016786550500303X>.
- [30] Kaiqing Lin et al. “Guard Me If You Know Me: Protecting Specific Face-Identity from Deepfakes” (Dec. 2025).
- [31] Chih-Chung Hsu, Yi-Xiu Zhuang, and Chia-Yen Lee. “Deep Fake Image Detection Based on Pairwise Learning”. *Applied Sciences* 10.1 (2020). 2076-3417. URL: <https://www.mdpi.com/2076-3417/10/1/370>.
- [32] V. Roshan Joseph. “Optimal ratio for data splitting”. *Statistical Analysis and Data Mining: The ASA Data Science Journal* 15.4 (2022), pp. 531–538. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/sam.11583>.
- [33] Houda Bichri, Adil Chergui, and Mustapha Hain. “Investigating the Impact of Train / Test Split Ratio on the Performance of Pre-Trained Models with Custom Datasets”. *International Journal of Advanced Computer Science and Applications (IJACSA)* 15.2 (2024).
- [34] Beilin Chu et al. *Reduced Spatial Dependency for More General Video-level Deepfake Detection*. 2025. arXiv: [2503.03270](https://arxiv.org/abs/2503.03270) [cs.CV]. URL: <https://arxiv.org/abs/2503.03270>.
- [35] Yuhang Lu, Ruizhi Luo, and Touradj Ebrahimi. *A Novel Framework for Assessment of Learning-based Detectors in Realistic Conditions with Application to Deepfake Detection*. 2022. arXiv: [2203.11797](https://arxiv.org/abs/2203.11797) [cs.CV]. URL: <https://arxiv.org/abs/2203.11797>.