

**ANALISIS KOMPARATIF PENDEKATAN SPASIAL DAN
SPASIOTEMPORAL UNTUK KLASIFIKASI VIDEO
DEEPPAKE MENGGUNAKAN VISION TRANSFORMER DAN
ENCODER VIDEO MAE**

TUGAS AKHIR

Rustian Afencius Marbun

122140155



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	iii
DAFTAR GAMBAR	iv
DAFTAR RUMUS	v
DAFTAR KODE	vi
BAB I PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.2 Dasar Teori	10
2.2.1 Teori 1	10
2.2.1.1 Subsubbab	11
2.2.2 Teori 2	11
BAB III METODE PENELITIAN	13
3.1 Alur Penelitian	13
3.2 Penjabaran Langkah Penelitian	13
3.2.1 Identifikasi Masalah	13
3.2.2 Studi Literatur	14

3.2.3	Pengumpulan Data	15
3.2.4	Preprocessing Data	16
3.2.4.1	Ekstraksi Dataset	17
3.2.4.2	Data Splitting	19
3.2.4.3	Strided Temporal Sampling	20
3.2.4.4	Augmentasi Data	21
3.2.4.5	Normalisasi Frame Hasil Sampling	22
3.2.5	Rancangan Model	23
3.2.5.1	Rancangan Model Spasial Berbasis Vision Transformer (ViT)	23
3.2.5.2	Rancangan Model Spasiotemporal Berbasis Encoder VideoMAE	26
3.2.6	Evaluasi Model	29
3.2.7	Hasil dan Pembahasan	30
3.3	Alat dan Bahan Tugas Akhir	31
3.3.1	Alat	31
3.3.2	Bahan	31
3.4	Ilustrasi Perhitungan Metode	31
DAFTAR PUSTAKA		32
LAMPIRAN		34
A	Dataset	34
B	Hasil Wawancara	34
C	Rincian Kasus Uji	34

DAFTAR TABEL

Tabel 2.1	Literasi Penelitian Terdahulu.....	9
Tabel 2.2	Contoh Tabel.....	10

DAFTAR GAMBAR

Gambar 2.1	Contoh gambar dan caption.....	11
Gambar 3.1	Alur Penelitian.....	13
Gambar 3.2	Contoh sampel data pada dataset WildDeepfake	15
Gambar 3.3	Struktur folder dataset WildDeepfake sebelum ekstraksi. .	18
Gambar 3.4	Struktur folder dataset WildDeepfake setelah ekstraksi ..	19
Gambar 3.5	Ilustrasi penerapan <i>strided temporal sampling</i> dengan T $= 16$ dan $\tau = 4$	21
Gambar 3.6	Arsitektur model spasial berbasis Vision Transformer (ViT) untuk klasifikasi <i>deepfake</i>	25
Gambar 3.7	Arsitektur model spatiotemporal berbasis encoder VideoMAE untuk klasifikasi <i>deepfake</i> , diadaptasi dari Tong <i>et al.</i> (2022).	28

DAFTAR RUMUS

Rumus 2.1	Rumus sederhana	11
Rumus 2.2	Mean Absolute Error (MAE)	11
Rumus 2.3	Distribusi Normal	12
Rumus 2.4	Sistem persamaan linier	12

DAFTAR KODE

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Kemajuan teknologi informasi dan komunikasi telah mengubah cara masyarakat memproduksi, mendistribusikan, dan mengonsumsi informasi digital. Dalam konteks tersebut, media visual seperti citra dan video menempati posisi penting karena sering dipersepsikan sebagai representasi langsung dari realitas. Namun, perkembangan kecerdasan buatan generatif juga meningkatkan risiko manipulasi informasi visual dalam skala besar. *Global Risks Report 2026* yang diterbitkan *World Economic Forum* menempatkan *misinformation and disinformation* pada peringkat kedua risiko global dalam horizon dua tahun, menunjukkan bahwa gangguan terhadap integritas informasi merupakan isu strategis yang semakin mendesak [1]. Salah satu bentuk manipulasi visual yang paling menonjol adalah *deepfake*, yaitu media sintesis berbasis *deep learning* yang mampu menghasilkan konten wajah dan video yang sangat realistis, sehingga berpotensi digunakan untuk penipuan, manipulasi opini, dan penyalahgunaan identitas digital [2], [3].

Ancaman *deepfake* tidak lagi terbatas pada ranah hiburan atau eksperimen teknis, tetapi telah berkembang menjadi persoalan keamanan informasi dan kepercayaan digital. Tolosana dkk. menjelaskan bahwa kemajuan teknik manipulasi wajah, khususnya yang ditopang *deep learning* dan GAN, telah menghasilkan konten palsu yang sangat meyakinkan serta menimbulkan tantangan serius bagi sistem deteksi [2]. Sejalan dengan itu, Khaund menunjukkan bahwa media sintesis modern dapat melemahkan keandalan mekanisme autentikasi yang bergantung pada biometrik dan verifikasi dokumen, sehingga *deepfake* menjadi ancaman yang relevan bagi ekosistem identitas digital [3]. Kondisi ini menegaskan perlunya pengembangan sistem deteksi otomatis

yang tidak hanya akurat pada lingkungan terkontrol, tetapi juga tangguh ketika dihadapkan pada variasi kualitas media di dunia nyata [3].

Dalam perkembangannya, pendekatan deteksi *deepfake* dapat dibedakan menjadi pendekatan spasial dan pendekatan spasiotemporal. Pendekatan spasial, yang secara operasional bekerja pada tingkat *frame* tunggal, berfokus pada ekstraksi artefak visual statis seperti ketidakwajaran tekstur, batas wajah, dan inkonsistensi detail lokal [2], [4]. Pendekatan ini relatif efisien dan telah menunjukkan performa yang baik pada banyak dataset terkontrol. Akan tetapi, semakin realistiknya generator *deepfake* membuat artefak visual statis menjadi semakin halus, sehingga detektor yang hanya bergantung pada bukti spasial berisiko mengalami penurunan kemampuan generalisasi [2], [4]. Dengan kata lain, peningkatan kualitas generasi media sintesis menuntut strategi deteksi yang tidak hanya mengandalkan petunjuk visual pada satu bingkai secara terpisah.

Sebagai alternatif, pendekatan spasiotemporal memanfaatkan hubungan antarbingkai untuk mendeteksi inkonsistensi gerakan atau koherensi temporal yang tidak alami pada video *deepfake*. Gu dkk. menunjukkan bahwa deteksi video *deepfake* pada praktiknya berkembang dalam dua jalur besar, yaitu solusi berbasis *frame* dan solusi berbasis video, serta menekankan pentingnya pemodelan *spatial-temporal inconsistency* dalam video hasil manipulasi [5]. Demikian pula, Haliassos dkk. menunjukkan bahwa representasi gerakan mulut yang bersifat spasiotemporal dapat meningkatkan kemampuan generalisasi dan ketahanan terhadap berbagai distorsi umum [6]. Meskipun demikian, keunggulan pendekatan spasiotemporal tidak selalu bersifat mutlak, karena isyarat temporal juga dapat terdegradasi oleh kompresi, *post-processing*, dan kualitas video yang rendah, yang lazim dijumpai pada distribusi konten daring [6].

Tantangan tersebut menjadi semakin penting ketika sistem deteksi diuji pada skenario *in-the-wild*. Zi dkk. memperkenalkan WildDeepfake sebagai dataset dunia nyata yang terdiri atas 7.314 sekuens wajah yang diekstraksi dari 707 video *deepfake* yang dikumpulkan sepenuhnya dari internet [7]. Mereka juga

menunjukkan bahwa WildDeepfake merupakan dataset yang lebih menantang dibandingkan dataset yang lebih terkontrol, karena performa sejumlah detektor dasar dapat menurun secara drastis pada dataset ini [7]. Temuan tersebut menunjukkan bahwa evaluasi pada data yang terkontrol belum cukup untuk merepresentasikan kondisi operasional sebenarnya. Oleh karena itu, pertanyaan mengenai pendekatan mana yang lebih tangguh, apakah pendekatan spasial atau pendekatan spasiotemporal, masih relevan untuk diuji secara empiris pada data *deepfake* dunia nyata [5], [6], [7].

Berdasarkan uraian tersebut, penelitian ini berfokus pada analisis komparatif klasifikasi video *deepfake* dengan pendekatan spasial dan spasiotemporal menggunakan dua model dari keluarga Transformer, yaitu Vision Transformer (ViT) dan encoder VideoMAE. ViT merepresentasikan pendekatan Transformer untuk citra dengan memproses urutan *image patches* secara langsung [8], sedangkan VideoMAE merupakan *video transformer* yang dirancang untuk mempelajari representasi video secara efisien [9]. Dengan membandingkan kedua pendekatan tersebut pada dataset WildDeepfake, penelitian ini bertujuan untuk mengevaluasi secara objektif kontribusi relatif informasi spasial dan temporal terhadap ketahanan klasifikasi video *deepfake* pada kondisi dunia nyata. Hasil penelitian diharapkan dapat memberikan dasar empiris yang lebih kuat mengenai pendekatan yang lebih sesuai untuk pengembangan sistem deteksi *deepfake* yang *robust* dan relevan secara praktis.

1.2 Rumusan Masalah

1. Bagaimana merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis encoder VideoMAE pada dataset WildDeepfake?
2. Bagaimana mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal

berbasis encoder VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*?

3. Pendekatan manakah di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis encoder VideoMAE yang paling efektif untuk klasifikasi video *deepfake* pada skenario *in-the-wild*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan penelitian ini adalah sebagai berikut.

1. Merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis encoder VideoMAE pada dataset WildDeepfake.
2. Mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis encoder VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*.
3. Menentukan pendekatan yang paling efektif di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis encoder VideoMAE untuk klasifikasi video *deepfake* pada skenario *in-the-wild*.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut.

1. Dataset yang digunakan dalam penelitian ini hanya dataset WildDeepfake sebagai sumber data pelatihan, validasi, dan pengujian.
2. Penelitian ini dibatasi pada klasifikasi biner untuk membedakan video ke dalam kelas *real* dan *fake*.
3. Data yang digunakan berupa *face sequence* yang telah melalui proses

preprocessing awal pada dataset sumber, sehingga penelitian ini tidak mencakup tahap deteksi wajah, ekstraksi fitur wajah, maupun *face alignment* dari video mentah.

4. Model yang digunakan dibatasi pada arsitektur Vision Transformer (ViT) untuk pendekatan spasial dan encoder VideoMAE untuk pendekatan spasiotemporal, dengan memanfaatkan bobot pralatih (*pretrained weights*) untuk proses *fine-tuning*.
5. Evaluasi kinerja model dibatasi pada metrik *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*.
6. Penelitian ini tidak membahas implementasi sistem dalam skenario *real-time*, integrasi dengan data audio atau teks, serta tidak melakukan pengujian pada dataset eksternal selain WildDeepfake.

1.5 Manfaat Penelitian

Manfaat penelitian ini adalah sebagai berikut.

1. Menghasilkan implementasi dan evaluasi komparatif model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis encoder VideoMAE pada dataset WildDeepfake.
2. Memberikan kontribusi ilmiah berupa analisis efektivitas relatif informasi spasial dan temporal dalam klasifikasi video *deepfake* pada kondisi dunia nyata (*in-the-wild*).
3. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan sistem klasifikasi atau deteksi *deepfake* yang lebih *robust*, khususnya pada data video dengan kualitas visual yang beragam dan terkompresi.

1.6 Sistematika Penulisan

Sistematika penulisan berisi pembahasan apa yang akan ditulis disetiap Bab. Sistematika pada umumnya berupa paragraf yang setiap paragraf mencerminkan

bahasan setiap Bab.

Bab I

Bab ini berisikan penjelasan latar belakang dari topik penelitian yang berlangsung, rumusan masalah dari masalah yang dihadapi pada penjelasan di latar belakang, tujuan dari penelitian, batasan dari penelitian, manfaat dari hasil penelitian, dan sistematika penulisan tugas akhir.

Bab II

Bab ini membahas mengenai tinjauan pustaka dari penelitian terdahulu dan dasar teori yang berkaitan dengan penelitian ini.

Bab III

Bab ini berisikan penjelasan alur kerja sistem, alat dan data yang digunakan, metode yang digunakan, dan rancangan pengujian.

Bab IV

Bab ini membahas hasil implementasi dan pengujian dari penelitian yang dilakukan, serta analisis dan evaluasi yang dapat dipetik dari hasil.

Bab V

Bab ini membahas kesimpulan dari hasil penelitian dan juga saran untuk penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Berisi penelitian terdahulu yang menjadi konsep / pendukung penelitian yang dilakukan. Lakukan pembahasan secara sistematis dengan menjelaskan masalah apa yang diangkat di penelitian terdahulu, metode yang digunakan, kontribusi yang diberikan, serta analisis penulis terkait dengan keunggulan atau keterbatasannya. Tuangkan perbandingan penelitian terdahulu dengan penelitian yang akan dikerjakan, minimal 5 jurnal pembanding (4-5 tahun terakhir). Kemudian penulis sebaiknya melakukan rangkuman terutama terkait dengan peluang pengembangan atau tugas akhir yang akan dilakukan

Perujukan literatur dapat dilakukan dengan menambahkan entri baru dalam file `references.bib`. Cara merujuk sitasi menggunakan `\cite{nama label sitasi}`. Hasil sitasi seperti ini: **knuth2001art**, **Vogels2006Am**, atau **Suryanto2019MAE Ivanny2014Banding**. Daftar Pustaka hanya akan memunculkan sitasi yang direferensikan menggunakan command `\cite{}`.

Tuliskan **judul jurnal, penulis jurnal, tahun jurnal terbit, penjelasan isi jurnal, metode penelitian, hasil penelitian & pengujian**.

1. Sistem Informasi Pendaftaran Haji dan Umroh Di PT Multazam Sriwijaya Barakah Palembang Menggunakan Metode Rapid Application Development. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur

adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2. Sistem Informasi Umroh Di PT XYZ Lampung Menggunakan Metode Rapid Application Development. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Tabel ringkasan tinjauan pustaka ditulis setelah penjelasan masing-masing jurnal.

Tabel 2.1 Literasi Penelitian Terdahulu

No.	Judul	Masalah	Metode	Hasil
1.	Sistem Informasi Pendaftaran Haji dan Umroh Di PT Multazam Sriwijaya Barakah Palembang Menggunakan Metode Rapid Application Development	Belum adanya sistem untuk pendaftaran haji & umrah	Rapid Application Development	Sistem Informasi Pendaftaran Haji dan Umroh di PT Multazam Sriwijaya Barakah Palembang
2.	Sistem Informasi Umroh Di PT XYZ Lampung Menggunakan Metode Rapid Application Development	Belum adanya sistem untuk pendaftaran haji & umrah	Rapid Application Development	Sistem Informasi Pendaftaran Umroh di PT XYZ Lampung

No.	Judul	Masalah	Metode	Hasil
3.	Sistem Informasi Umroh Di PT XYZ Lampung Menggunakan Metode Rapid Application Development	Belum adanya sistem untuk pendaftaran haji & umrah	Rapid Application Development	Sistem Informasi Pendaftaran Umroh di PT XYZ Lampung

2.2 Dasar Teori

Berisi teori/konsep yang berkaitan/digunakan dalam tugas akhir yang dikerjakan. Gunakanlah data melalui buku/jurnal referensi, publikasi tugas akhir, penelitian, buku, dan informasi web yang dapat dipertanggungjawabkan, hindari penggunaan dasar teori melalui tautan Wikipedia, surat kabar, atau portal berita, yang dapat memiliki isi yang tidak bersifat fakta.

2.2.1 Teori 1

Berikut adalah contoh penyisipan tabel menggunakan `\begin{longtable}{}:`


Tabel 2.2 Contoh Tabel

Col1	Col2	Col2	Col3
1	6	87837	787
2	7	78	5415
3	545	778	7507
4	545	18744	7560
5	88	788	6344

2.2.1.1 Subsubbab

Berikut adalah contoh subsubbab. Ini adalah level subbab maksimal dalam laporan Tugas Akhir, dan tidak boleh lebih dalam.

Gambar 2.1 adalah contoh Gambar yang diambil dari internet yang harus dicantumkan sumbernya dan memiliki lisensi Creative Common. Jika gambar adalah milik peneliti lain atau tidak dibuat atau diambil sendiri maka peneliti wajib meminta izin kepada peneliti lain tersebut untuk mencantumkan gambar. Gunakan `\begin{figure}` untuk memasukkan gambar. Gunakan `\caption{[nama caption]}` untuk memberikan caption gambar. Nomor caption akan diurutkan secara otomatis. Jangan lupa untuk melabeli setiap gambar dengan `\label{[nama label]}`, agar bisa direferensi menggunakan `\ref{[nama label]}`



Gambar 2.1 Contoh gambar dan caption
Sumber: Contoh

2.2.2 Teori 2

Untuk membuat sebuah rumus persamaan, gunakan kode `\begin{equationcaptioned}` seperti dibawah:

$$x + 1 = 2$$

(Rumus 2.1)

Teks caption rumus tidak akan muncul di teks, tetapi akan muncul di Daftar Rumus.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

(Rumus 2.2)

Berikut adalah contoh penulisan persamaan yang lebih kompleks, yaitu persamaan distribusi normal.

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}$$

(Rumus 2.3)

Jika menuliskan banyak persamaan secara berurutan, gunakan `\begin{split}`:

$$\begin{aligned} 2x - 5y &= 8 \\ 3x + 9y &= -12 \end{aligned}$$


(Rumus 2.4)

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Alur penelitian dalam tugas akhir ini divisualisasikan melalui sebuah diagram alir yang menjelaskan setiap tahapan proses penelitian, mulai dari identifikasi masalah hingga tahap akhir penyelesaian. Ilustrasi keseluruhan proses tersebut dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Berdasarkan alur penelitian yang ditampilkan pada Gambar 3.1, subbab berikut akan menjabarkan secara rinci setiap langkah yang dilakukan dalam penelitian ini.

3.2.1 Identifikasi Masalah

Tahap identifikasi masalah dalam penelitian ini berfokus pada kerentanan sistem deteksi deepfake pada skenario dunia nyata (*in-the-wild*). Sistem deteksi konvensional yang berbasis analisis spasial statis (*frame-level*) diketahui mengalami penurunan akurasi yang signifikan seiring meningkatnya realisme

manipulasi *deepfake* modern [4], [10]. Sebagai alternatif, pendekatan berbasis spasiotemporal (*video-level*) secara teoretis memiliki kemampuan untuk mengatasi keterbatasan tersebut melalui pendeteksian anomali gerakan antarframe [5]. Namun, pendekatan ini juga memiliki kelemahan, karena jejak artefak temporal sering kali mengalami degradasi akibat kompresi tinggi dan distorsi resolusi pada video dunia nyata [7], [11]. Kondisi tersebut memunculkan suatu paradoks empiris, yaitu bahwa penambahan dimensi temporal belum tentu menghasilkan sistem deteksi yang lebih tangguh dibandingkan pendekatan spasial murni [6]. Berdasarkan permasalahan tersebut, penelitian ini merumuskan eksperimen komparatif secara objektif antara arsitektur Vision Transformer (ViT) dan Video Masked Autoencoder (VideoMAE) dengan menggunakan dataset WildDeepfake.

3.2.2 Studi Literatur

Tahap kedua dalam penelitian ini adalah studi literatur, yaitu kajian mendalam terhadap berbagai sumber ilmiah yang relevan dengan topik penelitian. Studi literatur ini bertujuan untuk memahami konsep, metode, dan temuan terkini yang berkaitan dengan taksonomi manipulasi wajah, kemampuan model deteksi berbasis spasial maupun spasiotemporal, serta karakteristik gangguan pada video *deepfake* dalam skenario dunia nyata.


Pada tahap ini, dilakukan penelaahan terhadap penelitian-penelitian yang membahas efektivitas ekstraksi artefak visual statis pada tingkat bingkai tunggal (*frame-level*) [2], [4], pentingnya analisis inkonsistensi gerakan antarbingkai pada tingkat video (*video-level*) [5], serta tantangan yang ditimbulkan oleh kompresi media sosial yang ekstrem pada dataset WildDeepfake [7]. Hasil studi literatur tersebut menjadi landasan teoretis untuk mengidentifikasi celah penelitian dalam domain deteksi *deepfake* serta menyusun rancangan eksperimen komparatif antara arsitektur Vision Transformer (ViT) dan Video Masked Autoencoder (VideoMAE) yang dikembangkan dalam penelitian ini.

3.2.3 Pengumpulan Data

Tahap pengumpulan data dalam penelitian ini dilakukan dengan menggunakan dataset publik WildDeepfake¹. Dataset ini diperkenalkan oleh Zi *et al.* [7] sebagai dataset *deepfake* yang merepresentasikan kondisi dunia nyata (*in-the-wild*), sehingga dinilai lebih sesuai untuk mengevaluasi ketahanan model klasifikasi dibandingkan dataset yang dikembangkan dalam lingkungan yang lebih terkontrol. Menurut Zi *et al.* [7], WildDeepfake memiliki keragaman yang tinggi, meliputi variasi jumlah subjek dalam satu adegan, latar belakang, pose wajah, ekspresi, pencahayaan, serta variasi kompresi, resolusi, dan format video.

Secara keseluruhan, WildDeepfake terdiri atas 707 video yang diproses menjadi 7.314 sekuens wajah dengan total 1.180.099 citra wajah. Dari jumlah tersebut, terdapat 3.805 sekuens wajah kelas *real* dan 3.509 sekuens wajah kelas *fake*. Selain itu, dataset ini dibagi menjadi 6.508 sekuens data latih dan 806 sekuens data uji. Pembagian tersebut dilakukan berdasarkan kemiripan antarsekuens agar data latih dan data uji memiliki perbedaan yang memadai, sehingga evaluasi model dapat dilakukan secara lebih objektif [7].

Sebagai ilustrasi, contoh sampel citra wajah dari kelas *real* dan *fake* pada dataset WildDeepfake ditunjukkan pada Gambar 3.2.



Gambar 3.2 Contoh sampel data pada dataset WildDeepfake

Sebelum dataset dipublikasikan, Zi *et al.* [7] telah melakukan serangkaian *preprocessing* awal terhadap data. Proses tersebut diawali dengan pengumpulan

¹ Dataset WildDeepfake: <https://huggingface.co/datasets/xingjunm/WildDeepfake>

lebih dari 1.200 video *deepfake* dari berbagai situs berbagi video. Selanjutnya, video yang menggunakan manipulasi wajah tradisional serta video *deepfake* yang tidak memiliki pasangan video asli dieliminasi, sehingga diperoleh 707 video *deepfake* yang dinilai layak digunakan. Setelah itu, area wajah pada setiap *frame* dideteksi menggunakan MTCNN, kemudian fitur wajah diekstraksi menggunakan MobileNetV2. Untuk mengurangi pengaruh variasi orientasi wajah, setiap wajah dalam sekuens kemudian disejajarkan menggunakan *facial landmark* yang diperoleh dari dlib [7].

Pada tahap anotasi, Zi *et al.* [7] melibatkan tiga annotator untuk memberikan label *real*, *fake*, atau *unknown* pada setiap sekuens wajah. Sekuens yang masuk ke kategori *unknown* serta sekuens yang memperoleh label tidak konsisten antarannotator kemudian dibuang dari dataset akhir. Dengan demikian, dataset WildDeepfake yang digunakan dalam penelitian ini merupakan hasil pengolahan dan anotasi yang telah dilakukan secara sistematis.

3.2.4 Preprocessing Data

Tahap preprocessing data dilakukan untuk menyiapkan dataset WildDeepfake agar sesuai dengan kebutuhan eksperimen pada penelitian ini. Pada tahap ini, data tidak lagi melalui proses deteksi wajah, ekstraksi fitur wajah, maupun *face alignment*, karena tahapan tersebut telah dilakukan sebelumnya pada saat penyusunan dataset WildDeepfake oleh Zi *et al.* [7]. Selain itu, citra wajah pada sumber dataset yang digunakan telah tersedia dalam ukuran 224 x 224 piksel, sehingga penelitian ini tidak melakukan proses *resize* tambahan. Dengan demikian, preprocessing dalam penelitian ini difokuskan pada ekstraksi data, penyusunan struktur sekuens, pemisahan data, *strided temporal sampling*, augmentasi data, serta normalisasi dan pembentukan tensor masukan. Rancangan ini disusun agar pendekatan spasial dan pendekatan spatiotemporal menggunakan evidensi visual dasar yang sama, sehingga perbandingan kinerja keduanya dapat dilakukan secara lebih adil.

3.2.4.1 Ekstraksi Dataset

Tahap awal preprocessing dilakukan melalui proses ekstraksi data dan penyusunan struktur sekuens dari dataset WildDeepfake. Dataset yang digunakan tersimpan dalam direktori utama *deepfake_in_the_wild* yang terbagi ke dalam empat subset, yaitu *real train*, *real test*, *fake train*, dan *fake test*. Pada masing-masing subset tersebut terdapat sejumlah berkas terkompresi dengan format *.tar.gz*, seperti *0.tar.gz*, *1.tar.gz*, *2.tar.gz*, dan seterusnya.

Sebelum proses ekstraksi dilakukan, setiap berkas *.tar.gz* telah memuat struktur data internal yang terdiri atas folder kelas, kemudian di dalamnya terdapat beberapa folder sekuens wajah. Sebagai contoh, pada subset *real train*, berkas *0.tar.gz* memuat folder *real*, yang selanjutnya berisi folder-folder seperti *0*, *1*, *2*, dan seterusnya. Setiap folder tersebut merepresentasikan satu *face sequence*, sedangkan citra-citra di dalamnya, seperti *0.png*, *1.png*, *2.png*, dan seterusnya, merupakan kumpulan *frame* wajah hasil ekstraksi dari video. Nama berkas citra menunjukkan urutan *frame* pada video asli, sehingga informasi temporal tetap dapat dipertahankan untuk kebutuhan pemrosesan lebih lanjut. Struktur folder dataset WildDeepfake sebelum proses ekstraksi ditunjukkan pada Gambar 3.3.


```

deepfake_in_the_wild/
|-- real_train/
|   |-- 0.tar.gz
|   |   |-- real/
|   |   |   |-- 0/
|   |   |   |   |-- 0.png
|   |   |   |   |-- 1.png
|   |   |   |   |-- 2.png
|   |   |   |   |-- ...
|   |   |   |-- 1/
|   |   |   |-- 2/
|   |   |   |-- ...
|   |-- 1.tar.gz
|   |-- 2.tar.gz
|   |-- ...
|-- real_test/
|   |-- 0.tar.gz
|   |-- ...
|-- fake_train/
|   |-- 0.tar.gz
|   |-- ...
|-- fake_test/
|   |-- 0.tar.gz
|   |-- ...

```

Gambar 3.3 Struktur folder dataset WildDeepfake sebelum ekstraksi

Pada penelitian ini, seluruh berkas *.tar.gz* terlebih dahulu diekstraksi sesuai subset asalnya. Setelah proses ekstraksi selesai, struktur data kemudian disusun ulang agar lebih sistematis dan mudah digunakan pada tahap berikutnya. Folder hasil ekstraksi dari setiap arsip, misalnya *0*, *1*, *2*, dan seterusnya, ditempatkan langsung di bawah subset masing-masing, seperti *real train*, *real test*, *fake train*, dan *fake test*. Di dalam setiap folder hasil ekstraksi tersebut tersimpan kembali folder-folder sekuens wajah yang berisi kumpulan citra *frame*. Dengan demikian, satu folder hasil ekstraksi merepresentasikan satu kelompok data dari satu arsip, sedangkan folder-folder di dalamnya merepresentasikan unit sekuens yang akan diproses lebih lanjut. Struktur folder dataset WildDeepfake setelah proses ekstraksi ditunjukkan pada Gambar 3.4.

```

deepfake_in_the_wild/
|-- real train/
|   |-- 0/
|   |   |-- 0/
|   |   |   |-- 0.png
|   |   |   |-- 1.png
|   |   |   |-- 2.png
|   |   |   |-- ...
|   |   |-- 1/
|   |   |-- 2/
|   |   |-- ...
|   |-- 1/
|   |-- 2/
|   |-- ...
|-- real test/
|   |-- 0/
|   |-- ...
|-- fake train/
|   |-- 0/
|   |-- ...
|-- fake test/
|   |-- 0/
|   |-- ...

```

Gambar 3.4 Struktur folder dataset WildDeepfake setelah ekstraksi

Penyusunan struktur data ini dilakukan untuk memudahkan proses pembacaan data pada tahap berikutnya. Dengan struktur yang telah disusun ulang tersebut, proses *data loading*, pembentukan klip, dan pelacakan identitas sekuens dapat dilakukan secara lebih teratur dan konsisten. Melalui tahapan ini, dataset berada dalam bentuk yang lebih siap untuk digunakan pada proses data splitting, *strided temporal sampling*, dan pembentukan masukan model pada tahap berikutnya.

3.2.4.2 Data Splitting

Penelitian ini mengikuti pemisahan data yang telah tersedia pada sumber dataset, yaitu subset *train* dan *test*. Dengan demikian, seluruh data pada direktori *real test* dan *fake test* digunakan sebagai data pengujian akhir, sedangkan direktori *real train* dan *fake train* digunakan sebagai sumber data untuk proses pelatihan dan validasi. Strategi ini sejalan dengan pembagian resmi WildDeepfake yang dilaporkan oleh Zi *et al.*, yaitu 6.508 *face sequence* untuk pelatihan dan 806 *face sequence* untuk pengujian [7].

Selanjutnya, subset *train* pada sumber dataset dipisahkan kembali menjadi data *train* dan data *validation* dengan perbandingan 80:20. Pemisahan ini


dilakukan pada tingkat sekuens, bukan pada tingkat citra, agar *frame* yang berasal dari sekuens yang sama tidak terdistribusi ke subset yang berbeda. Pendekatan ini digunakan untuk mencegah *data leakage* serta menjaga validitas evaluasi model selama proses pelatihan dan pengujian.

3.2.4.3 Strided Temporal Sampling

Pada penelitian ini, pembentukan sampel dilakukan menggunakan teknik *strided temporal sampling* pada sekuens video. Teknik ini digunakan untuk memilih sejumlah *frame* dari setiap sekuens secara berkala sehingga diperoleh representasi temporal yang lebih ringkas, tetapi tetap mampu merepresentasikan dinamika gerakan dalam video.

Setiap sekuens diproses untuk membentuk sebuah klip yang terdiri atas 16 *frame* dengan *stride* 4. Dalam konfigurasi ini, setelah satu *frame* dipilih, *frame* berikutnya diambil dengan selang empat indeks dari *frame* sebelumnya hingga diperoleh 16 *frame* dalam satu klip. Konfigurasi tersebut sejalan dengan rancangan VideoMAE, yang menerapkan *strided temporal sampling* untuk melakukan *temporal downsampling* secara efisien tanpa harus memproses seluruh *frame* dalam satu sekuens secara langsung [9].

Sebagai ilustrasi, perbedaan antara *sequential frame sampling* dan *strided temporal sampling* ditunjukkan pada Gambar 3.5. Pada *sequential frame sampling*, *frame* diambil secara berurutan sesuai urutan kemunculannya dalam sekuens, misalnya *frame* ke-1, ke-2, dan seterusnya hingga *frame* terakhir. Sebaliknya, pada *strided temporal sampling*, *frame* dipilih dengan interval tertentu. Dalam penelitian ini, interval yang digunakan adalah empat *frame*, sehingga dari satu sekuens diperoleh klip berisi 16 *frame* yang tetap merepresentasikan informasi temporal secara lebih efisien.



Gambar 3.5 Ilustrasi penerapan *strided temporal sampling* dengan $T = 16$ dan $\tau = 4$

Hasil *strided temporal sampling* pada penelitian ini dijadikan sebagai sampel dasar bersama untuk kedua jalur eksperimen, yaitu pendekatan spasial dan pendekatan spasiotemporal. Dengan demikian, kedua pendekatan tidak dibangun dari kumpulan citra yang berbeda, melainkan dari *frame-frame* hasil sampling yang sama. Perbedaannya terletak pada bentuk representasi yang diberikan kepada model. Pada pendekatan spasial, setiap *frame* hasil sampling diperlakukan sebagai sampel individual. Sementara itu, pada pendekatan spasiotemporal, *frame-frame* yang sama dipertahankan sebagai satu klip terurut. Rancangan ini bertujuan untuk menjaga keadilan eksperimen, sehingga perbedaan kinerja yang muncul lebih merefleksikan perbedaan cara model memanfaatkan informasi spasial dan temporal, bukan disebabkan oleh perbedaan data yang digunakan.

3.2.4.4 Augmentasi Data

Untuk meningkatkan keragaman data pelatihan dan mengurangi risiko *overfitting*, augmentasi hanya diterapkan pada data *train*, sedangkan data *validation* dan data *test* tidak diberikan augmentasi agar evaluasi model tetap objektif. Dalam penelitian ini, augmentasi diterapkan setelah tahap *strided temporal sampling*, sehingga transformasi dilakukan pada klip hasil sampling yang sama yang akan digunakan oleh kedua jalur eksperimen. Pendekatan ini

dipilih untuk memastikan bahwa *frame-frame* yang masuk ke model spasial dan model spatiotemporal tetap berasal dari sumber visual yang identik.

Transformasi yang digunakan bersifat ringan dan realistis, yaitu *horizontal flip* secara acak, penyesuaian kecerahan dan kontras, serta penambahan *Gaussian noise*. Pemilihan transformasi tersebut bertujuan untuk mensimulasikan berbagai gangguan visual yang umum muncul pada video dunia nyata, seperti perubahan pencahayaan, derau akibat proses perekaman, dan penurunan kualitas akibat kompresi. Dengan demikian, model diharapkan menjadi lebih tangguh terhadap variasi kualitas data yang tidak ideal.

Agar kesetaraan data masukan tetap terjaga, seluruh transformasi pada satu klip diterapkan dengan parameter yang sama untuk semua *frame* di dalam klip tersebut. Pendekatan ini dilakukan untuk mempertahankan koherensi temporal antar-*frame* [12]. Dengan demikian, apabila suatu klip menerima *horizontal flip*, penyesuaian kecerahan atau kontras, *Gaussian noise*, maka transformasi yang sama diterapkan secara konsisten pada seluruh *frame* dalam klip tersebut. Setelah itu, *frame-frame* hasil augmentasi yang sama digunakan sebagai masukan bagi pendekatan spasial, sedangkan klip hasil augmentasi digunakan sebagai masukan bagi pendekatan spatiotemporal.

3.2.4.5 Normalisasi Frame Hasil Sampling

Setelah data melalui tahap ekstraksi, pemisahan, *strided temporal sampling*, dan augmentasi, langkah berikutnya adalah melakukan normalisasi terhadap *frame-frame* hasil sampling. Normalisasi dilakukan agar distribusi nilai piksel menjadi lebih terstandarisasi dan sesuai dengan karakteristik model *pretrained* yang digunakan. Tahap ini penting untuk menjaga stabilitas proses pelatihan serta membantu model dalam mempelajari pola visual secara lebih efektif.

Pada pendekatan spasial, setiap *frame* hasil *strided temporal sampling* diperlakukan sebagai citra tunggal yang akan diberikan ke model Vision Transformer (ViT). Sebelum digunakan, nilai piksel pada setiap

frame terlebih dahulu diubah ke rentang $[0, 1]$, kemudian dinormalisasi menggunakan parameter $mean = [0.485, 0.456, 0.406]$ dan $standard deviation = [0.229, 0.224, 0.225]$. Parameter ini mengikuti preprocessing resmi pada model ViT-B/16 di Torchvision.

Sementara itu, pada pendekatan spasiotemporal, kumpulan *frame* hasil *strided temporal sampling* dipertahankan sebagai satu klip yang akan digunakan oleh model VideoMAE. Setiap *frame* dalam klip juga dinormalisasi dengan prosedur yang sama, yaitu dengan mengubah nilai piksel ke rentang $[0, 1]$, kemudian menerapkan $mean = [0.485, 0.456, 0.406]$ dan $standard deviation = [0.229, 0.224, 0.225]$. Nilai tersebut mengikuti konfigurasi normalisasi pada repositori resmi VideoMAE.

3.2.5 Rancangan Model


Pada tahap ini, rancangan model disusun untuk membandingkan dua pendekatan klasifikasi *deepfake*, yaitu pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE. Kedua model dibangun dari *frame-frame* hasil *strided temporal sampling* yang sama, sehingga perbandingan dilakukan secara lebih adil dan terarah. Perbedaan utama antara keduanya terletak pada cara representasi visual diproses. Pada pendekatan spasial, setiap *frame* dianalisis secara individual untuk menangkap karakteristik visual statis. Sementara itu, pada pendekatan spasiotemporal, *frame-frame* yang sama dipertahankan sebagai satu klip video untuk memanfaatkan informasi spasial sekaligus hubungan temporal antar-*frame*. Dengan rancangan tersebut, penelitian ini dapat mengevaluasi secara langsung efektivitas pendekatan *frame-level* dan *video-level* dalam klasifikasi *deepfake* pada kondisi dunia nyata.

3.2.5.1 Rancangan Model Spasial Berbasis Vision Transformer (ViT)

Model spasial pada penelitian ini dirancang menggunakan arsitektur Vision Transformer (ViT) dengan varian ViT-Base/16. Pemilihan ViT-Base/16

didasarkan pada kemampuan arsitektur Transformer dalam memodelkan hubungan global antarbagian citra melalui mekanisme *self-attention*, sehingga model tidak hanya bergantung pada kedekatan lokal antarpiksel, tetapi juga mampu menangkap keterkaitan visual yang tersebar pada berbagai area wajah [8]. Dalam konteks klasifikasi *deepfake*, pendekatan spasial digunakan untuk mengekstraksi artefak visual statis pada tingkat *frame*, seperti ketidakwajaran tekstur, batas wajah yang kurang alami, serta inkonsistensi detail lokal yang masih menjadi petunjuk penting dalam deteksi manipulasi wajah [2], [4]. Pemilihan ViT juga selaras dengan tujuan penelitian ini untuk membandingkan pendekatan *frame-level* dan *video-level* secara lebih adil, karena ViT dan VideoMAE sama-sama berlandaskan keluarga arsitektur Transformer.

Masukan model berupa *frame* hasil *strided temporal sampling* berukuran 224×224 piksel. Setiap *frame* diproses sebagai citra tunggal pada jalur spasial. Sesuai dengan rancangan ViT, citra masukan terlebih dahulu dibagi menjadi *patch* berukuran 16×16 piksel. Dengan konfigurasi tersebut, satu citra 224×224 menghasilkan $14 \times 14 = 196$ *patch*. Setiap *patch* kemudian diratakan dan diproyeksikan secara linear untuk membentuk representasi vektor yang disebut *patch embedding* [8]. Setelah proses tersebut, sebuah *class token* ditambahkan pada awal urutan token, sedangkan *position embedding* disisipkan untuk mempertahankan informasi posisi spasial setiap *patch* dalam citra [8]. Dengan demikian, jumlah token yang diproses oleh encoder untuk setiap *frame* adalah 197 token, yaitu 196 token *patch* ditambah 1 *class token*. Ilustrasi arsitektur model spasial berbasis ViT yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.6.



Gambar 3.6 Arsitektur model spasial berbasis Vision Transformer (ViT) untuk klasifikasi *deepfake*

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. Pada konfigurasi ViT-Base, encoder terdiri atas 12 blok Transformer, dengan dimensi embedding sebesar 768 dan 12 *attention head* pada mekanisme *multi-head self-attention* [8]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection* [8]. Melalui susunan ini, model dapat mempelajari hubungan antar-*patch* secara menyeluruh, sehingga representasi visual yang dihasilkan tidak hanya menangkap detail lokal, tetapi juga struktur global wajah yang berpotensi mengalami manipulasi.

Dalam rancangan penelitian ini, setiap *frame* hasil *strided temporal sampling* diberikan ke *backbone* ViT untuk mengekstraksi fitur spasial. Representasi keluaran yang terkait dengan *class token* pada akhir encoder kemudian diteruskan ke lapisan klasifikasi biner untuk membedakan kelas *real* dan *fake*. Dengan rancangan tersebut, unit prediksi dasar pada pendekatan spasial berada pada tingkat *frame*. Namun, karena tujuan penelitian ini adalah melakukan klasifikasi pada tingkat sekuens/video, keluaran dari seluruh *frame* dalam satu sekuens tidak dihentikan pada prediksi individual semata. Untuk setiap sekuens yang terdiri atas 16 *frame* hasil sampling, model terlebih dahulu

menghasilkan probabilitas prediksi pada masing-masing *frame*, kemudian seluruh probabilitas tersebut diagregasi menggunakan rata-rata probabilitas untuk memperoleh keputusan akhir pada tingkat sekuens. Strategi ini dipilih agar pendekatan spasial tetap merepresentasikan analisis visual statis pada tingkat *frame*, tetapi hasil akhirnya tetap dapat dibandingkan secara langsung dengan pendekatan spasiotemporal pada tingkat video.

Rancangan tersebut juga konsisten dengan tujuan eksperimen komparatif yang menggunakan evidensi visual dasar yang sama pada kedua jalur model. Pada pendekatan spasial, *frame-frame* hasil sampling diperlakukan sebagai masukan individual untuk menilai seberapa jauh informasi visual statis masih efektif dalam membedakan wajah asli dan wajah hasil manipulasi pada video *deepfake* dunia nyata [7], [13]. Meskipun demikian, pendekatan ini memiliki keterbatasan mendasar karena tidak memodelkan hubungan temporal antar-*frame* secara eksplisit. Akibatnya, model spasial diperkirakan lebih sensitif terhadap artefak visual statis, tetapi berpotensi kurang optimal dalam menangkap anomali manipulasi yang hanya tampak melalui dinamika gerakan atau inkonsistensi temporal antar-*frame*. Keterbatasan inilah yang kemudian menjadi dasar pembandingan terhadap pendekatan spasiotemporal berbasis VideoMAE pada subbab berikutnya.

3.2.5.2 Rancangan Model Spasiotemporal Berbasis Encoder VideoMAE


Model spasiotemporal pada penelitian ini dirancang menggunakan arsitektur VideoMAE dengan *backbone* Transformer encoder berbasis ViT-Base. Pemilihan model ini didasarkan pada kemampuan VideoMAE dalam memodelkan representasi video secara terpadu pada dimensi spasial dan temporal melalui mekanisme *self-attention* [9]. Berbeda dengan pendekatan spasial yang memproses setiap *frame* secara individual, pendekatan spasiotemporal mempertahankan urutan *frame* sebagai satu kesatuan klip video agar model dapat mempelajari tidak hanya artefak visual statis, tetapi juga hubungan

temporal antar-*frame*. Dalam konteks klasifikasi *deepfake*, pendekatan ini relevan karena manipulasi wajah sering kali menimbulkan inkonsistensi gerakan, seperti *flickering*, perubahan tekstur yang tidak stabil, atau ketidaksinkronan gerak bibir [5], [6]. Namun demikian, pada video dunia nyata (*in-the-wild*), jejak temporal tersebut dapat mengalami degradasi akibat kompresi tinggi, variasi resolusi, perubahan pose, dan kualitas pencahayaan yang tidak konsisten, sehingga efektivitas pendekatan *video-level* tetap perlu diuji secara empiris [7], [12], [13].

Pada penelitian ini, masukan model berupa satu klip video hasil *strided temporal sampling* yang terdiri atas 16 *frame* RGB berukuran 224×224 piksel dengan *stride* 4. Konfigurasi ini dipilih agar konsisten dengan tahap *preprocessing* yang telah dijelaskan sebelumnya, sekaligus menjaga kesetaraan evidensi visual dengan pendekatan spasial. Dengan demikian, kedua jalur eksperimen dibangun dari *frame-frame* hasil sampling yang sama, sehingga perbedaan performa yang diperoleh lebih merefleksikan perbedaan kemampuan model dalam memanfaatkan informasi spasial dan temporal, bukan disebabkan oleh perbedaan data masukan. Selain itu, model pada penelitian ini diinisialisasi menggunakan bobot pralatih berbasis Kinetics-400, sehingga proses *fine-tuning* dimulai dari representasi video umum yang telah dipelajari sebelumnya pada dataset video berskala besar [9].

Berbeda dari Vision Transformer untuk citra tunggal yang membagi input menjadi *patch* dua dimensi, VideoMAE membagi klip video menjadi kubus spasiotemporal melalui mekanisme *joint space-time cube embedding* [9]. Pada rancangan ini, setiap kubus memiliki ukuran $2 \times 16 \times 16$, yaitu mencakup dua *frame* pada dimensi waktu dan area 16×16 piksel pada dimensi spasial [9]. Dengan masukan berukuran $16 \times 224 \times 224$, proses tersebut menghasilkan token video sebanyak $(16/2) \times (224/16) \times (224/16) = 8 \times 14 \times 14 = 1568$ token. Setiap kubus kemudian diratakan dan diproyeksikan secara linear ke ruang embedding untuk membentuk representasi token video. Setelah itu, *positional*

embedding ditambahkan untuk mempertahankan informasi posisi spasial dan urutan temporal token sebelum diproses lebih lanjut oleh encoder. Ilustrasi arsitektur model spasiotemporal berbasis VideoMAE yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.7.



Gambar 3.7 Arsitektur model spasiotemporal berbasis encoder VideoMAE untuk klasifikasi *deepfake*, diadaptasi dari Tong *et al.* (2022).

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. Pada konfigurasi ViT-Base, encoder terdiri atas 12 blok Transformer [9]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection*. Karakteristik utama rancangan ini terletak pada penggunaan *joint space-time attention*, yaitu mekanisme *self-attention* yang memungkinkan seluruh token video saling berinteraksi secara langsung lintas posisi spasial dan lintas waktu secara simultan [9]. Melalui mekanisme tersebut, model tidak hanya menangkap detail visual pada setiap *frame*, tetapi juga mampu mempelajari keterkaitan perubahan visual antar-*frame* dalam satu klip secara menyeluruh.

Perlu dicatat bahwa pada rancangan asli VideoMAE, komponen seperti *tube masking* dengan rasio tinggi dan *decoder* digunakan pada tahap *self-supervised*

pre-training untuk merekonstruksi bagian video yang dimask [9]. Namun, pada penelitian ini fokus utama bukan pada tahap *pre-training*, melainkan pada pemanfaatan encoder prelatih untuk tugas klasifikasi biner *downstream*. Oleh karena itu, alur model dalam penelitian ini difokuskan pada pembentukan token spasiotemporal, ekstraksi representasi video melalui Transformer encoder, dan klasifikasi akhir pada tingkat klip. Pendekatan ini sejalan dengan tujuan penelitian untuk mengevaluasi apakah representasi spasiotemporal yang dipelajari encoder VideoMAE mampu memberikan keunggulan dibandingkan pendekatan spasial murni pada skenario *deepfake in-the-wild* [7], [13].

Pada tahap akhir, representasi keluaran dari lapisan terakhir encoder diringkas melalui *mean pooling* untuk memperoleh satu vektor fitur pada tingkat klip. Vektor tersebut kemudian diteruskan ke *classification head* untuk menghasilkan prediksi akhir secara langsung pada tingkat video, yaitu kelas *real* atau *fake*. Dengan rancangan tersebut, pendekatan spasiotemporal pada penelitian ini beroperasi sepenuhnya pada level klip, sehingga model diharapkan mampu menangkap bukti manipulasi yang tersebar baik pada dimensi spasial maupun temporal secara lebih komprehensif [5], [9]. Hasil dari model ini selanjutnya dibandingkan secara langsung dengan pendekatan spasial berbasis ViT untuk menilai kontribusi relatif informasi temporal terhadap ketahanan klasifikasi *deepfake* pada kondisi dunia nyata.

3.2.6 Evaluasi Model

Evaluasi model pada penelitian ini dilakukan untuk menilai kinerja dan kemampuan generalisasi dua pendekatan yang digunakan, yaitu model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE. Proses evaluasi dilaksanakan menggunakan data *validation* selama pelatihan untuk memantau perkembangan pembelajaran model dan menentukan model terbaik, serta data *test* pada tahap akhir untuk mengukur performa akhir secara objektif terhadap data yang tidak terlibat dalam proses pelatihan [12].

Agar perbandingan kedua pendekatan dilakukan secara setara, evaluasi pada penelitian ini ditetapkan pada tingkat sekuens atau video. Pada pendekatan spasial, model menghasilkan prediksi untuk setiap *frame* dalam satu sekuens, kemudian seluruh prediksi tersebut diagregasi menjadi satu keputusan akhir. Sementara itu, pada pendekatan spasiotemporal, model memproses klip video secara langsung dan menghasilkan satu prediksi pada tingkat video. Kinerja model diukur menggunakan *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC. Penggunaan *precision*, *recall*, dan *F1-score* bertujuan untuk memberikan penilaian yang lebih komprehensif terhadap performa klasifikasi, khususnya dalam melihat keseimbangan antara ketepatan prediksi positif dan kemampuan model mendeteksi seluruh sampel positif [14].

Selain itu, AUC-ROC digunakan untuk menilai kemampuan diskriminatif model dalam membedakan video *real* dan *fake* pada berbagai nilai ambang keputusan. Metrik ini melengkapi evaluasi berbasis *threshold* tunggal karena mampu memberikan gambaran yang lebih menyeluruh mengenai hubungan antara tingkat deteksi positif benar dan tingkat kesalahan positif palsu [15]. Hasil evaluasi selanjutnya disajikan dalam bentuk tabel perbandingan metrik, *confusion matrix*, kurva ROC, serta grafik *training loss* dan *validation loss* untuk mendukung analisis performa dan kestabilan proses pelatihan model [12], [15].

3.2.7 Hasil dan Pembahasan

Tahap hasil dan pembahasan dilakukan untuk menganalisis secara komparatif kinerja model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis encoder VideoMAE dalam klasifikasi video *deepfake* pada tingkat sekuens atau video. Analisis didasarkan pada perbandingan nilai *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC, serta didukung oleh *confusion matrix*, kurva ROC, dan grafik *training loss* serta *validation loss* untuk menilai performa klasifikasi, kemampuan diskriminatif, dan kestabilan pelatihan model [12], [14], [15]. Hasil yang diperoleh kemudian diinterpretasikan untuk

menjelaskan efektivitas relatif pendekatan spasial dan spatiotemporal, termasuk kecenderungan kesalahan prediksi pada data WildDeepfake yang memiliki karakteristik kompresi tinggi, variasi pose, pencahayaan, dan kualitas visual yang tidak seragam [6], [7], [13].

3.3 Alat dan Bahan Tugas Akhir

Adapun alat dan bahan yang digunakan dalam penelitian ini dijelaskan sebagai berikut.

3.3.1 Alat

Alat yang digunakan dalam penelitian ini meliputi perangkat keras (*hardware*) dan perangkat lunak (*software*) yang mendukung proses pemodelan, pelatihan, serta evaluasi model. Berikut adalah alat yang digunakan.

1. Visual Studio Code
2. Kaggle Notebook
3. Library PyTorch
4. GPU NVIDIA Tesla T4 (*cloud-based service*)

3.3.2 Bahan

Bahan yang digunakan dalam penelitian ini berupa dataset dan sumber pendukung untuk proses pelatihan serta evaluasi model. Dataset utama yang digunakan adalah WildDeepfake sebagai sumber data pelatihan, validasi, dan pengujian. Selain itu, penelitian ini juga menggunakan *pretrained weights* pada model Vision Transformer (ViT) dan encoder VideoMAE untuk mendukung proses *fine-tuning* pada tugas klasifikasi video *deepfake*.

3.4 Ilustrasi Perhitungan Metode

Penjelasan contoh perhitungan bagi penelitian tugas akhir yang menggunakan algoritma perhitungan tertentu. Rumus perhitungan berdasarkan rumus yang sudah dijelaskan sebelumnya di Bab 2.2.

DAFTAR PUSTAKA

- [1] World Economic Forum (WEF). “The Global Risks Report 2026”. 21st Edition (2026). URL: https://reports.weforum.org/docs/WEF_Global_Risks_Report_2026.pdf.
- [2] Ruben Tolosana et al. “DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection” (June 2020).
- [3] Bhaskardeep Khaund. “AI and Identity Security: The Threat of Deepfakes and the Future of Authentication”. *Journal of Information Systems Engineering and Management* 10.60s (Sept. 2025), pp. 1015–1030. 2468-4376.
- [4] Junyi Cao et al. “End-to-End Reconstruction-Classification Learning for Face Forgery Detection”. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, pp. 4103–4112.
- [5] Zhihao Gu et al. “Spatiotemporal Inconsistency Learning for DeepFake Video Detection” (Oct. 2021).
- [6] Alexandros Haliassos et al. “Lips Don’t Lie: A Generalisable and Robust Approach to Face Forgery Detection” (Aug. 2021).
- [7] Bojia Zi et al. “WildDeepfake: A Challenging Real-World Dataset for Deepfake Detection” (July 2024).
- [8] Alexey Dosovitskiy et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. 2021. arXiv: [2010.11929](https://arxiv.org/abs/2010.11929) [cs.CV]. URL: <https://arxiv.org/abs/2010.11929>.
- [9] Zhan Tong et al. *VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training*. 2022. arXiv: [2203.12602](https://arxiv.org/abs/2203.12602) [cs.CV]. URL: <https://arxiv.org/abs/2203.12602>.
- [10] Kaiqing Lin et al. “Guard Me If You Know Me: Protecting Specific Face-Identity from Deepfakes” (Dec. 2025).

- [11] Chih-Chung Hsu, Yi-Xiu Zhuang, and Chia-Yen Lee. “Deep Fake Image Detection Based on Pairwise Learning”. *Applied Sciences* 10.1 (2020). 2076-3417. URL: <https://www.mdpi.com/2076-3417/10/1/370>.
- [12] Yuhang Lu, Ruizhi Luo, and Touradj Ebrahimi. *A Novel Framework for Assessment of Learning-based Detectors in Realistic Conditions with Application to Deepfake Detection*. 2022. arXiv: [2203.11797](https://arxiv.org/abs/2203.11797) [cs.CV]. URL: <https://arxiv.org/abs/2203.11797>.
- [13] Beilin Chu et al. *Reduced Spatial Dependency for More General Video-level Deepfake Detection*. 2025. arXiv: [2503.03270](https://arxiv.org/abs/2503.03270) [cs.CV]. URL: <https://arxiv.org/abs/2503.03270>.
- [14] Marina Sokolova and Guy Lapalme. “A systematic analysis of performance measures for classification tasks”. *Information Processing & Management* 45.4 (2009), pp. 427–437. 0306-4573. URL: <https://www.sciencedirect.com/science/article/pii/S0306457309000259>.
- [15] Tom Fawcett. “An introduction to ROC analysis”. *Pattern Recognition Letters* 27.8 (2006). ROC Analysis in Pattern Recognition, pp. 861–874. 0167-8655. URL: <https://www.sciencedirect.com/science/article/pii/S016786550500303X>.

LAMPIRAN

A Dataset

B Hasil Wawancara

C Rincian Kasus Uji