

**ANALISIS KOMPARATIF PENDEKATAN SPASIAL DAN
SPASIOTEMPORAL UNTUK KLASIFIKASI VIDEO DEEPPAKE
MENGUNAKAN VISION TRANSFORMER DAN VIDEOMAE**

TUGAS AKHIR

Rustian Afencius Marbun

122140155



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
DAFTAR RUMUS	vi
DAFTAR KODE	vii
BABI PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	6
1.6.1 Bab I Pendahuluan	6
1.6.2 Bab II Tinjauan Pustaka	6
1.6.3 Bab III Metode Penelitian	6
1.6.4 Bab IV Hasil dan Pembahasan	6
1.6.5 Bab V Kesimpulan dan Saran	6
BAB II TINJAUAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.2 Dasar Teori	12
2.2.1 Deepfake dan Manipulasi Media Visual	12
2.2.1.1 Deepfake	13
2.2.1.2 Konsep dan Generasi Deepfake	13
2.2.1.3 Karakteristik Dataset In-the-Wild	14

2.2.2	Deep Learning	15
2.2.3	Computer Vision	15
2.2.4	Transformer	16
2.2.5	Vision Transformer (ViT)	18
2.2.6	VideoMAE	19
2.2.7	Strided Temporal Sampling	22
2.2.8	Evaluasi Model	23
2.2.8.1	Confusion Matrix	23
2.2.8.2	Accuracy	24
2.2.8.3	Precision, Recall, dan F1-Score	24
2.2.8.4	Area Under Curve – Receiver Operating Characteristic (AUC-ROC)	25
BAB III METODE PENELITIAN		27
3.1	Alur Penelitian	27
3.2	Penjabaran Langkah Penelitian	27
3.2.1	Identifikasi Masalah	27
3.2.2	Studi Literatur	28
3.2.3	Pengumpulan Data	29
3.2.4	Preprocessing Data	30
3.2.4.1	Ekstraksi Dataset	30
3.2.4.2	Data Splitting	32
3.2.4.3	Strided Temporal Sampling	34
3.2.4.4	Augmentasi Data	35
3.2.4.5	Normalisasi Frame Hasil Sampling	36
3.2.5	Rancangan Model	37
3.2.5.1	Rancangan Model Spasial Berbasis Vision Transformer (ViT)	37

- 3.2.5.2 Rancangan Model Spasiotemporal Berbasis
VideoMAE 40
- 3.2.6 Evaluasi Model 42
- 3.2.7 Hasil dan Pembahasan 44
- 3.3 Alat dan Bahan Tugas Akhir..... 44
 - 3.3.1 Alat..... 44
 - 3.3.2 Bahan..... 44
- 3.4 Ilustrasi Perhitungan Metode 45
- DAFTAR PUSTAKA..... 46**

DAFTAR TABEL

Tabel 2.1	Literasi Penelitian Terdahulu.....	10
Tabel 2.2	<i>Confusion Matrix</i>	24

DAFTAR GAMBAR

Gambar 2.1	Arsitektur Transformer	17
Gambar 2.2	Arsitektur Vision Transformer (ViT)	19
Gambar 2.3	Arsitektur VideoMAE dengan asymmetric encoder-decoder dan tube masking	20
Gambar 3.1	Alur Penelitian	27
Gambar 3.2	Contoh sampel citra wajah kelas <i>real</i> dan <i>fake</i> pada dataset WildDeepfake	29
Gambar 3.3	Struktur folder dataset WildDeepfake sebelum ekstraksi .	31
Gambar 3.4	Struktur folder dataset WildDeepfake setelah ekstraksi . .	32
Gambar 3.5	Ilustrasi perbedaan <i>sequential frame sampling</i> dan <i>strided temporal sampling</i> ($T = 16, \tau = 4$)	35
Gambar 3.6	Arsitektur model spasial berbasis Vision Transformer (ViT)	38
Gambar 3.7	Arsitektur model spasiotemporal berbasis VideoMAE untuk klasifikasi <i>deepfake</i>	41

DAFTAR RUMUS

Rumus 2.1	Mekanisme <i>self-attention</i> pada Transformer	17
Rumus 2.2	Rumus <i>accuracy</i> pada klasifikasi biner	24
Rumus 2.3	Rumus <i>precision</i> pada klasifikasi biner	25
Rumus 2.4	Rumus <i>recall</i> pada klasifikasi biner	25
Rumus 2.5	Rumus <i>F1-score</i> pada klasifikasi biner	25
Rumus 2.6	Rumus <i>true positive rate</i> (TPR)	26
Rumus 2.7	Rumus <i>false positive rate</i> (FPR)	26

DAFTAR KODE

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Kemajuan teknologi informasi dan komunikasi telah mengubah cara masyarakat memproduksi, mendistribusikan, dan mengonsumsi informasi digital. Dalam konteks tersebut, media visual seperti citra dan video menempati posisi penting karena kerap dipersepsikan sebagai representasi yang dekat dengan realitas. Namun, perkembangan kecerdasan buatan generatif juga meningkatkan risiko manipulasi informasi visual dalam skala besar. *Global Risks Report 2026* yang diterbitkan oleh *World Economic Forum* menunjukkan bahwa misinformasi dan disinformasi merupakan ancaman yang konsisten lintas periode proyeksi, yaitu menempati peringkat kelima pada tahun 2026, peringkat kedua dalam proyeksi dua tahun hingga 2028, dan peringkat keempat dalam proyeksi sepuluh tahun hingga 2036 [1]. Temuan tersebut menunjukkan bahwa gangguan terhadap integritas informasi bukan hanya menjadi persoalan saat ini, tetapi juga diperkirakan tetap signifikan dalam jangka menengah dan panjang. Salah satu bentuk manipulasi visual yang paling menonjol dalam konteks ini adalah *deepfake*, yaitu media sintetis berbasis *deep learning* yang mampu menghasilkan konten wajah dan video yang sangat realistis, sehingga berpotensi digunakan untuk penipuan, manipulasi opini, dan penyalahgunaan identitas digital [2], [3].

Ancaman *deepfake* tidak lagi terbatas pada ranah hiburan atau eksperimen teknis, tetapi telah berkembang menjadi persoalan keamanan informasi dan kepercayaan digital. Tolosana dkk. menjelaskan bahwa kemajuan teknik manipulasi wajah, khususnya yang ditopang *deep learning* dan GAN, telah menghasilkan konten palsu yang sangat meyakinkan serta menimbulkan tantangan serius bagi sistem deteksi [2]. Sejalan dengan itu, Khaund menunjukkan bahwa media sintetis modern dapat melemahkan keandalan

mekanisme autentikasi yang bergantung pada biometrik dan verifikasi dokumen, sehingga *deepfake* menjadi ancaman yang relevan bagi ekosistem identitas digital [4]. Kondisi ini menegaskan perlunya pengembangan sistem deteksi otomatis yang tidak hanya akurat pada lingkungan terkontrol, tetapi juga tangguh ketika dihadapkan pada variasi kualitas media di dunia nyata [4].

Dalam perkembangannya, pendekatan deteksi *deepfake* dapat dibedakan menjadi pendekatan spasial dan pendekatan spasiotemporal. Pendekatan spasial, yang secara operasional bekerja pada tingkat *frame* tunggal, berfokus pada ekstraksi artefak visual statis seperti ketidakwajaran tekstur, batas wajah, dan inkonsistensi detail lokal [2], [5]. Pendekatan ini relatif efisien dan telah menunjukkan performa yang baik pada banyak dataset terkontrol. Akan tetapi, semakin realistiknya generator *deepfake* membuat artefak visual statis menjadi semakin halus, sehingga detektor yang hanya bergantung pada bukti spasial berisiko mengalami penurunan kemampuan generalisasi [2], [5]. Dengan kata lain, peningkatan kualitas generasi media sintetis menuntut strategi deteksi yang tidak hanya mengandalkan petunjuk visual pada satu bingkai secara terpisah.

Sebagai alternatif, pendekatan spasiotemporal memanfaatkan hubungan antarbingkai untuk mendeteksi inkonsistensi gerakan atau koherensi temporal yang tidak alami pada video *deepfake*. Gu dkk. menunjukkan bahwa deteksi video *deepfake* pada praktiknya berkembang dalam dua jalur besar, yaitu solusi berbasis *frame* dan solusi berbasis video, serta menekankan pentingnya pemodelan *spatial-temporal inconsistency* dalam video hasil manipulasi [6]. Demikian pula, Haliassos dkk. menunjukkan bahwa representasi gerakan mulut yang bersifat spasiotemporal dapat meningkatkan kemampuan generalisasi dan ketahanan terhadap berbagai distorsi umum [7]. Meskipun demikian, keunggulan pendekatan spasiotemporal tidak selalu bersifat mutlak, karena isyarat temporal juga dapat terdegradasi oleh kompresi, *post-processing*, dan kualitas video yang rendah, yang lazim dijumpai pada distribusi konten daring [7].

Tantangan tersebut menjadi semakin penting ketika sistem deteksi diuji

pada skenario dunia nyata (*in-the-wild*). Zi dkk. memperkenalkan WildDeepfake sebagai dataset dunia nyata yang terdiri atas 7.314 sekuens wajah yang diekstraksi dari 707 video *deepfake* yang dikumpulkan sepenuhnya dari internet [8]. Mereka juga menunjukkan bahwa WildDeepfake merupakan dataset yang lebih menantang dibandingkan dataset yang lebih terkontrol, karena performa sejumlah detektor dasar dapat menurun secara drastis pada dataset ini [8]. Temuan tersebut menunjukkan bahwa evaluasi pada data yang terkontrol belum cukup untuk merepresentasikan kondisi operasional sebenarnya. Oleh karena itu, pertanyaan mengenai pendekatan mana yang lebih tangguh, apakah pendekatan spasial atau pendekatan spasiotemporal, masih relevan untuk diuji secara empiris pada data *deepfake* dunia nyata [6], [7], [8].

Berdasarkan uraian tersebut, penelitian ini berfokus pada analisis komparatif klasifikasi video *deepfake* dengan pendekatan spasial dan spasiotemporal menggunakan dua model dari keluarga Transformer, yaitu Vision Transformer (ViT) dan VideoMAE. ViT merepresentasikan pendekatan Transformer untuk citra dengan memproses urutan *image patches* secara langsung [9], sedangkan VideoMAE merupakan *video transformer* yang dirancang untuk mempelajari representasi video secara efisien [10]. Dengan membandingkan kedua pendekatan tersebut pada dataset WildDeepfake, penelitian ini bertujuan untuk mengevaluasi secara objektif kontribusi relatif informasi spasial dan temporal terhadap ketahanan klasifikasi video *deepfake* pada kondisi dunia nyata. Hasil penelitian diharapkan dapat memberikan dasar empiris yang lebih kuat mengenai pendekatan yang lebih sesuai untuk pengembangan sistem deteksi *deepfake* yang *robust* dan relevan secara praktis.

1.2 Rumusan Masalah

1. Bagaimana merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset

WildDeepfake?

2. Bagaimana mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, *AUC-ROC*, dan *confusion matrix*?
3. Pendekatan manakah di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE yang paling efektif untuk klasifikasi video *deepfake* pada skenario *in-the-wild*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan penelitian ini adalah sebagai berikut.

1. Merancang dan mengimplementasikan model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake.
2. Mengukur serta membandingkan performa pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE berdasarkan *accuracy*, *precision*, *recall*, *F1-score*, *AUC-ROC*, dan *confusion matrix*.
3. Menentukan pendekatan yang paling efektif di antara model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE untuk klasifikasi video *deepfake* pada skenario *in-the-wild*.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut.

1. Dataset yang digunakan dalam penelitian ini hanya dataset WildDeepfake sebagai sumber data pelatihan, validasi, dan pengujian.
2. Penelitian ini dibatasi pada klasifikasi biner untuk membedakan video ke

dalam kelas *real* dan *fake*.

3. Data yang digunakan berupa *face sequence* yang telah melalui proses *preprocessing* awal pada dataset sumber, sehingga penelitian ini tidak mencakup tahap deteksi wajah, ekstraksi fitur wajah, maupun *face alignment* dari video mentah.
4. Model yang digunakan dibatasi pada arsitektur Vision Transformer (ViT) untuk pendekatan spasial dan VideoMAE untuk pendekatan spasiotemporal, dengan memanfaatkan (*pretrained weights*) untuk proses *fine-tuning*.
5. Evaluasi kinerja model dibatasi pada metrik *accuracy*, *precision*, *recall*, *F1-score*, AUC-ROC, dan *confusion matrix*.
6. Penelitian ini tidak membahas implementasi sistem dalam skenario *real-time*, integrasi dengan data audio atau teks, serta tidak melakukan pengujian pada dataset eksternal selain WildDeepfake.

1.5 Manfaat Penelitian

Manfaat penelitian ini adalah sebagai berikut.

1. Menghasilkan implementasi dan evaluasi komparatif model klasifikasi video *deepfake* menggunakan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake.
2. Memberikan kontribusi ilmiah berupa analisis efektivitas relatif informasi spasial dan temporal dalam klasifikasi video *deepfake* pada kondisi dunia nyata (*in-the-wild*).
3. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan sistem klasifikasi atau deteksi *deepfake* yang lebih *robust*, khususnya pada data video dengan kualitas visual yang beragam dan terkompresi.

1.6 Sistematika Penulisan

Sistematika penulisan yang diterapkan dalam menyusun penelitian ini adalah sebagai berikut.

1.6.1 Bab I Pendahuluan

Pada Bab I, penulis menjelaskan latar belakang permasalahan, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, dan sistematika penulisan.

1.6.2 Bab II Tinjauan Pustaka

Pada Bab II, penulis memberikan penjabaran tentang penelitian sebelumnya yang terkait dengan penelitian ini. Penulis juga memaparkan dasar teori yang berkaitan dengan penelitian yang dilakukan.

1.6.3 Bab III Metode Penelitian

Pada Bab III, penulis menjelaskan mengenai metodologi yang akan digunakan pada penelitian ini. Metodologi yang digunakan dapat dijelaskan dengan diagram alir yang dilanjutkan dengan penjelasan setiap tahapnya dan juga menjelaskan tentang perangkat apa yang digunakan oleh penulis untuk penelitian.

1.6.4 Bab IV Hasil dan Pembahasan

Pada Bab IV, penulis menjelaskan hasil dari penelitian yang didapatkan, dimulai dengan pengumpulan data, pengolahan data, hasil penelitian, dan pembahasan penelitian.

1.6.5 Bab V Kesimpulan dan Saran

Pada Bab V, penulis memberikan kesimpulan dari hasil penelitian yang didapatkan pada Bab IV, serta saran yang dapat dilakukan untuk penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Tinjauan pustaka ini memaparkan penelitian terdahulu yang memiliki relevansi topik dan menjadi landasan utama penyusunan tugas akhir. Adapun penelitian yang dijadikan acuan diuraikan sebagai berikut.

Zi dkk. pada tahun 2021 mempermasalahkan keterbatasan dataset *deepfake* yang umumnya disusun dalam kondisi terkontrol, sehingga kurang merepresentasikan variasi konten dunia nyata yang beredar di internet [8]. Untuk mengatasi hal tersebut, mereka memperkenalkan dataset WildDeepfake yang terdiri atas 7.314 *face sequence* yang diekstraksi dari 707 video *deepfake* yang dikumpulkan sepenuhnya dari internet [8]. Kontribusi utama penelitian ini terletak pada penyediaan dataset *in-the-wild* yang lebih menantang dibandingkan dataset terkontrol, serta evaluasi sejumlah detektor dasar yang menunjukkan penurunan performa yang cukup besar pada dataset tersebut [8]. Bagi penelitian ini, paper tersebut menjadi landasan utama dalam pemilihan WildDeepfake sebagai sumber data, karena menunjukkan bahwa evaluasi model pada data terkontrol saja belum cukup untuk menggambarkan ketahanan model pada kondisi operasional yang sesungguhnya.

Khormali dan Yuan pada tahun 2022 mengangkat masalah bahwa sebagian besar metode deteksi *deepfake* masih bergantung pada arsitektur CNN, yang dinilai kurang optimal dalam menangkap hubungan global antarbagi citra [11]. Mereka mengusulkan DFDT, yaitu kerangka *end-to-end* berbasis Vision Transformer yang terdiri atas komponen *patch extraction and embedding*, *multi-stream transformer block*, *attention-based patch selection*, dan *multi-scale classifier* [11]. Hasil pengujian menunjukkan bahwa DFDT mencapai akurasi 99,41% pada FaceForensics++, 99,31% pada Celeb-DF (V2), dan 81,35% pada

WildDeepfake [11]. Penelitian ini relevan karena secara langsung mendukung penggunaan ViT pada pendekatan spasial untuk klasifikasi *deepfake*. Selain itu, keberhasilan DFDT pada WildDeepfake menunjukkan bahwa Transformer berbasis citra tetap memiliki potensi yang baik pada data dunia nyata, sehingga layak dijadikan pembanding konseptual bagi pendekatan spasial yang digunakan dalam penelitian ini.

Zhuang dkk. pada tahun 2022 membahas permasalahan bahwa pembelajaran inkonsistensi pemalsuan wajah umumnya memerlukan anotasi lokasi manipulasi tingkat piksel, padahal anotasi itu sulit diperoleh dan mahal dibuat [12]. Untuk menjawab masalah tersebut, mereka mengusulkan UIA-ViT, yaitu metode berbasis ViT yang memanfaatkan *self-attention* untuk mempelajari inkonsistensi intra-*frame* hanya dengan label tingkat video, melalui dua komponen utama berupa *Unsupervised Patch Consistency Learning* (UPCL) dan *Progressive Consistency Weighted Assemble* (PCWA) [12]. Kontribusi penelitian ini menunjukkan bahwa ViT tidak hanya efektif sebagai pengganti CNN, tetapi juga memiliki keunggulan metodologis dalam memodelkan relasi antarpetak citra yang relevan untuk mendeteksi inkonsistensi manipulasi [12]. Bagi penelitian ini, UIA-ViT memperkuat justifikasi bahwa pendekatan spasial berbasis ViT masuk akal untuk diterapkan pada klasifikasi video *deepfake*, karena informasi visual statis pada tingkat *frame* masih dapat dieksploitasi secara efektif melalui mekanisme perhatian global.

Kingra dkk. tahun 2024 menyoroti bahwa banyak metode sebelumnya belum mampu memanfaatkan informasi spasial dan temporal secara terpadu dalam satu kerangka Transformer *end-to-end* [13]. Untuk itu, mereka mengusulkan SFormer yang menggunakan Swin Transformer untuk analisis spasial, diikuti *transformer block* untuk analisis temporal, dan *MLP block* untuk prediksi akhir [13]. Hasil eksperimen menunjukkan bahwa SFormer memperoleh akurasi 100% pada FF++, 97,81% pada DFD, 99,1% pada Celeb-DF, dan 93,67% pada DFDC, serta menunjukkan kemampuan generalisasi yang baik

pada eksperimen lintas-dataset [13]. Penelitian ini relevan karena mendukung argumen bahwa pendekatan spasiotemporal berbasis Transformer merupakan arah yang kuat untuk deteksi *deepfake* video. Dalam konteks penelitian ini, SFormer menjadi pembanding penting pada jalur spasiotemporal karena menunjukkan bahwa pemodelan hubungan antar-*frame* dapat meningkatkan kemampuan model dalam menangkap jejak manipulasi yang tidak selalu tampak pada *frame* tunggal.

Hu dkk. pada tahun 2024 membahas tantangan bahwa video *deepfake* modern sering memiliki jejak manipulasi yang tersebar secara acak dan berubah antar-*frame*, sehingga sulit dideteksi hanya dengan fitur lokal yang tetap [14]. Mereka mengusulkan metode Delocate untuk deteksi dan lokalisasi *deepfake*, serta melakukan studi *ablation* yang secara langsung membandingkan MAE dan VideoMAE pada tugas deteksi *deepfake* [14]. Dalam *ablation study* tersebut, baseline VideoMAE memperoleh skor AUC 77,4 pada CDF, 89,3 pada DFO, dan 71,8 pada DFDC, sementara Delocate menunjukkan peningkatan lebih lanjut setelah dilakukan modifikasi terhadap strategi pemodelan [14]. Walaupun VideoMAE pada penelitian ini tidak digunakan sebagai metode utama oleh Hu dkk., keberadaan VideoMAE sebagai baseline yang dievaluasi secara langsung pada domain *deepfake* tetap penting, karena menunjukkan bahwa representasi video berbasis Transformer sudah mulai digunakan dan relevan untuk tugas deteksi *deepfake* video. Dengan demikian, paper ini dapat dijadikan justifikasi tambahan bagi pemilihan VideoMAE sebagai model pada pendekatan spasiotemporal dalam penelitian ini.

Berdasarkan lima penelitian tersebut, dapat disimpulkan bahwa terdapat tiga landasan utama yang mendukung penelitian ini. Pertama, WildDeepfake terbukti merupakan dataset yang lebih menantang dan lebih representatif untuk evaluasi pada kondisi dunia nyata [8]. Kedua, pendekatan spasial berbasis ViT telah menunjukkan potensi yang baik dalam mendeteksi artefak visual statis pada *deepfake* [11], [12]. Ketiga, pendekatan spasiotemporal berbasis

Transformer, termasuk model video seperti VideoMAE, menunjukkan potensi untuk menangkap bukti manipulasi yang tersebar pada dimensi spasial dan temporal [13], [14]. Meskipun demikian, masih terdapat celah penelitian berupa belum banyaknya studi yang secara langsung membandingkan pendekatan spasial berbasis ViT dan pendekatan spasiotemporal berbasis VideoMAE pada dataset WildDeepfake dalam satu rancangan eksperimen yang setara. Oleh karena itu, penelitian ini diarahkan untuk mengisi celah tersebut melalui analisis komparatif kedua pendekatan pada skenario *deepfake in-the-wild*.

Tabel 2.1 Literasi Penelitian Terdahulu

No.	Judul	Masalah	Metode	Hasil
1.	WildDeepfake: A Challenging Real-World Dataset for Deepfake Detection (Zi dkk., 2024)	Dataset <i>deepfake</i> terkontrol kurang mewakili kondisi dunia nyata.	Memperkenalkan dataset WildDeepfake dan menguji beberapa baseline deteksi.	WildDeepfake lebih menantang daripada dataset terkontrol dan layak digunakan untuk evaluasi <i>in-the-wild</i> .
2.	DFDT: An End-to-End DeepFake Detection Framework Using Vision Transformer (Khormali dkk., 2022)	CNN kurang optimal menangkap relasi global citra.	Mengusulkan deteksi <i>deepfake</i> berbasis Vision Transformer.	Mencapai akurasi tinggi pada beberapa dataset, termasuk WildDeepfake, dan mendukung penggunaan ViT.

No.	Judul	Masalah	Metode	Hasil
3.	UIA-ViT: Unsupervised Inconsistency- Aware Method based on Vision Transformer for Face Forgery Detection (Zhuang dkk., 2022)	Deteksi inkonsistensi manipulasi biasanya memerlukan anotasi piksel.	Menggunakan ViT untuk mempelajari inkonsistensi <i>intra-frame</i> tanpa anotasi piksel.	Menunjukkan generalisasi yang baik dan memperkuat efektivitas ViT untuk deteksi manipulasi wajah.
4.	SFormer: An End-to- End Spatio- Temporal Transformer Architecture for Deepfake Detection (Kingra dkk., 2024)	Diperlukan model yang memanfaatkan informasi spasial dan temporal secara terpadu.	Menggunakan Swin Transformer dan <i>transformer</i> <i>temporal</i> untuk deteksi video <i>deepfake</i> .	Memberikan akurasi tinggi pada beberapa dataset dan mendukung pendekatan spasiotemporal berbasis Transformer.

No.	Judul	Masalah	Metode	Hasil
5.	Delocate: Detection and Localization for Deepfake Videos with Randomly-Located Tampered Traces (Huddk., 2024)	Jejak manipulasi video <i>deepfake</i> tersebar acak dan berubah antar-frame.	Mengusulkan model deteksi-lokalisasi dan membandingkan baseline MAE dan VideoMAE.	Menunjukkan peningkatan deteksi lintas-domain dan mendukung relevansi VideoMAE pada deteksi <i>deepfake</i> video.

2.2 Dasar Teori

2.2.1 Deepfake dan Manipulasi Media Visual

Perkembangan manipulasi media visual mengalami perubahan yang sangat signifikan seiring kemajuan *deep learning*, khususnya pada model generatif yang mampu mensintesis wajah dan video dengan tingkat realisme yang tinggi. Dalam konteks ini, *deepfake* dipahami sebagai salah satu bentuk media sintetis yang dihasilkan atau dimanipulasi menggunakan model berbasis jaringan saraf dalam, sehingga konten visual yang dihasilkan tampak autentik meskipun tidak sepenuhnya merepresentasikan kondisi yang sebenarnya [3]. Realisme *deepfake* semakin meningkat setelah berkembangnya arsitektur generator modern yang mampu menghasilkan wajah sintetis beresolusi tinggi dengan detail tekstur, pencahayaan, dan struktur wajah yang semakin alami [15]. Kondisi tersebut menyebabkan manipulasi media visual tidak lagi terbatas pada penyuntingan konvensional, tetapi telah berkembang menjadi rekayasa identitas, ekspresi, dan gerak wajah yang sulit dibedakan dari media asli [3], [15].

2.2.1.1 Deepfake

Deepfake adalah media sintetis atau media yang dimanipulasi menggunakan teknik *deep learning* untuk menghasilkan konten visual atau audiovisual yang menyerupai data asli secara sangat meyakinkan [3]. Dalam praktiknya, *deepfake* tidak hanya mencakup pertukaran wajah (*face swapping*), tetapi juga sintesis wajah penuh, manipulasi ekspresi wajah, rekayasa gerak bibir, dan perubahan identitas visual pada video [3]. Karakteristik utama *deepfake* terletak pada kemampuannya mempertahankan kesan visual yang realistis bagi pengamat manusia, sehingga media hasil manipulasi tampak sah secara visual walaupun tidak autentik secara semantik [3]. Oleh karena itu, *deepfake* menjadi salah satu bentuk manipulasi media visual yang paling menantang dalam bidang forensik digital, karena kualitas hasil generasinya terus meningkat seiring perkembangan model generatif modern [3], [15].

2.2.1.2 Konsep dan Generasi Deepfake

Konsep generasi *deepfake* sangat erat kaitannya dengan perkembangan model generatif, terutama *Generative Adversarial Networks* (GAN). GAN merupakan kerangka pembelajaran generatif yang melibatkan dua jaringan, yaitu *generator* yang bertugas menghasilkan sampel sintetis dan *discriminator* yang bertugas membedakan sampel sintetis dari data asli [16]. Melalui proses pelatihan yang bersifat *adversarial*, *generator* secara bertahap belajar menghasilkan data yang semakin menyerupai distribusi data nyata [16]. Kerangka ini menjadi fondasi penting bagi generasi awal *deepfake* karena memungkinkan pembentukan wajah sintetis dan manipulasi visual berbasis data dengan kualitas yang terus meningkat. Perkembangan berikutnya menghasilkan arsitektur yang lebih kuat, salah satunya *style-based generator architecture* pada StyleGAN, yang memungkinkan kontrol yang lebih baik terhadap atribut visual tingkat tinggi seperti identitas, pose, dan struktur wajah, sekaligus mempertahankan detail lokal yang halus [15]. Dengan demikian, realisme

deepfake modern tidak hanya ditentukan oleh kemampuan menghasilkan wajah yang tampak alami, tetapi juga oleh kemampuan model dalam menjaga konsistensi detail visual sehingga artefak manipulasi menjadi semakin sulit dikenali [15], [16].

2.2.1.3 Karakteristik Dataset In-the-Wild

Karakteristik dataset *in-the-wild* berbeda secara mendasar dari dataset yang dibangun dalam kondisi terkontrol. Pada data terkontrol, video umumnya memiliki kualitas yang lebih seragam, resolusi yang relatif stabil, pencahayaan yang lebih terkendali, dan tingkat kompresi yang tidak terlalu beragam. Sebaliknya, dataset *in-the-wild* merepresentasikan kondisi distribusi dunia nyata yang jauh lebih kompleks, karena memuat variasi kompresi, resolusi, pencahayaan, pose, ekspresi, latar belakang, sudut pengambilan gambar, serta kualitas video yang tidak seragam [8], [17]. Perbedaan tersebut menyebabkan jejak manipulasi pada video *deepfake* menjadi lebih sulit dikenali dibandingkan pada dataset terkontrol. Pergeseran menuju dataset yang lebih realistis juga terlihat pada Celeb-DF, yang dirancang sebagai dataset *DeepFake* yang lebih menantang dengan kualitas visual yang lebih tinggi daripada dataset generasi awal [17]. Pada konteks yang lebih luas, WildDeepfake merepresentasikan karakteristik *in-the-wild* secara lebih kuat karena disusun dari video yang benar-benar dikumpulkan dari internet dan menunjukkan bahwa performa detektor dasar dapat menurun cukup drastis ketika diuji pada kondisi dunia nyata [8]. Oleh karena itu, karakteristik utama dataset *in-the-wild* dalam penelitian ini dipahami sebagai keberagaman kondisi visual dan degradasi nyata yang membuat proses klasifikasi *deepfake* menjadi lebih menantang daripada pada data yang dibangun dalam lingkungan terkontrol [8], [17].

2.2.2 Deep Learning

Deep learning adalah cabang dari *machine learning* yang menggunakan jaringan saraf tiruan berlapis banyak untuk mempelajari representasi data secara bertingkat, mulai dari pola berlevel rendah hingga representasi berlevel tinggi yang lebih abstrak [18]. Pendekatan ini memungkinkan proses ekstraksi fitur dilakukan secara otomatis dari data, sehingga mengurangi ketergantungan pada perancangan fitur manual yang umum digunakan pada metode pembelajaran tradisional [18]. Dalam perkembangannya, *deep learning* telah menunjukkan peningkatan kinerja yang signifikan pada berbagai tugas, seperti pengenalan ucapan, pengenalan objek visual, deteksi objek, dan analisis data berskala besar [18]. Pada konteks penelitian ini, *deep learning* menjadi landasan utama dalam pembangunan model klasifikasi video *deepfake*, karena pendekatan ini memungkinkan model mempelajari pola visual yang kompleks dari citra wajah dan klip video secara langsung dari data [18], [19].

2.2.3 Computer Vision

Computer vision adalah bidang dalam kecerdasan buatan yang berfokus pada bagaimana sistem komputer memperoleh, merepresentasikan, dan memahami informasi dari citra maupun video [19]. Perkembangan *deep learning* telah mendorong kemajuan pesat pada bidang ini, terutama pada tugas klasifikasi citra, deteksi objek, segmentasi, dan analisis visual lainnya, karena model dapat mempelajari fitur visual secara lebih efektif dibandingkan pendekatan konvensional [19]. Dalam penelitian ini, *computer vision* menjadi kerangka aplikasi yang mendasari proses analisis *face sequence* dan klip video untuk membedakan konten *real* dan *fake* berdasarkan karakteristik visual yang dipelajari model [19]. Dengan demikian, *computer vision* tidak hanya berperan sebagai domain penerapan, tetapi juga sebagai dasar konseptual dalam memahami bagaimana informasi visual pada video *deepfake* dapat diolah menjadi keputusan klasifikasi [19].

2.2.4 Transformer

Transformer merupakan arsitektur jaringan saraf yang diperkenalkan untuk memodelkan hubungan antar elemen masukan melalui mekanisme *attention* tanpa bergantung pada proses rekuren maupun konvolusi [20]. Berbeda dengan *Recurrent Neural Network* (RNN) dan *Long Short-Term Memory* (LSTM) yang memproses data secara berurutan, Transformer memungkinkan setiap elemen masukan berinteraksi secara langsung dengan elemen lainnya dalam satu urutan, sehingga konteks global dapat dipelajari secara lebih efektif [20]. Karakteristik ini membuat Transformer menjadi salah satu fondasi utama dalam perkembangan *deep learning* modern dan kemudian diadaptasi ke berbagai domain, tidak hanya pada *Natural Language Processing* (NLP), tetapi juga pada *computer vision* [20].


Secara umum, arsitektur Transformer terdiri atas blok *encoder* dan *decoder* yang dibangun dari komponen utama berupa *multi-head attention*, *feed-forward network*, *residual connection*, dan *layer normalization* [20]. Pada penelitian ini, konsep Transformer menjadi dasar penting karena baik *Vision Transformer* (ViT) maupun VideoMAE sama-sama memanfaatkan mekanisme perhatian untuk membangun representasi visual dari citra dan video [9], [10], [20]. Dengan demikian, pemahaman terhadap Transformer diperlukan untuk menjelaskan bagaimana hubungan global antarbagian masukan visual dapat dipelajari secara langsung tanpa ketergantungan pada struktur rekuren maupun operasi konvolusi tradisional.

Mekanisme inti pada Transformer adalah *self-attention*, yaitu proses yang memungkinkan setiap elemen masukan memberikan perhatian terhadap elemen lainnya dalam urutan yang sama [20]. Pada mekanisme ini, setiap elemen masukan diproyeksikan ke dalam tiga representasi, yaitu *Query* (Q), *Key* (K), dan *Value* (V). Hubungan antar elemen dihitung melalui perkalian antara Q dan K untuk memperoleh skor kesamaan, kemudian dinormalisasi dengan fungsi

softmax agar diperoleh bobot perhatian yang proporsional [20]. Bobot tersebut selanjutnya digunakan untuk menggabungkan V dan menghasilkan representasi baru yang telah memuat informasi konteks secara menyeluruh. Secara matematis, mekanisme ini dinyatakan sebagai berikut [20].

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (\text{Rumus 2.1})$$

Pada persamaan tersebut, Q , K , dan V merupakan matriks hasil transformasi linier dari masukan, sedangkan d_k menyatakan dimensi vektor *key* [20]. Pembagian dengan $\sqrt{d_k}$ dilakukan untuk menstabilkan hasil perkalian *dot product* agar nilainya tidak terlalu besar sebelum dinormalisasi oleh *softmax* [20]. Dengan mekanisme tersebut, Transformer mampu mempelajari hubungan kontekstual antar seluruh elemen masukan, bukan hanya elemen yang berdekatan. Arsitektur umum Transformer ditunjukkan pada Gambar 2.1.



Gambar 2.1 Arsitektur Transformer


2.2.5 Vision Transformer (ViT)

Vision Transformer (ViT) merupakan adaptasi arsitektur Transformer untuk tugas klasifikasi citra dengan memproses citra sebagai urutan *image patch* [9]. Berbeda dengan *Convolutional Neural Network* (CNN) yang menekankan ekstraksi fitur lokal melalui operasi konvolusi, ViT membagi citra menjadi sejumlah *patch* dua dimensi, kemudian memperlakukan setiap *patch* sebagai token masukan yang serupa dengan token pada pemrosesan bahasa alami [9]. Pendekatan ini memungkinkan model memanfaatkan *self-attention* untuk mempelajari hubungan global antarbagian citra secara langsung [9]. Dalam konteks penelitian ini, ViT menjadi dasar pada pendekatan spasial karena setiap *frame* video *deepfake* diproses sebagai citra tunggal untuk mengekstraksi artefak visual statis.

Pada tahap awal pemrosesan, citra masukan berukuran $H \times W \times C$ dibagi menjadi sejumlah *patch* berukuran $P \times P$ [9]. Banyaknya *patch* yang dihasilkan dinyatakan sebagai $N = \frac{HW}{P^2}$, sehingga citra tidak lagi diproses sebagai matriks piksel utuh, melainkan sebagai urutan token visual [9]. Setiap *patch* kemudian diratakan menjadi vektor satu dimensi dan diproyeksikan secara linier ke dalam ruang *embedding* untuk membentuk *patch embedding* [9]. Setelah itu, sebuah *class token* ditambahkan pada awal urutan token sebagai representasi global untuk keperluan klasifikasi, sedangkan *positional embedding* ditambahkan untuk mempertahankan informasi posisi spasial tiap *patch* [9]. Dengan rancangan tersebut, citra dapat diproses oleh rangkaian Transformer *encoder* dengan prinsip yang serupa dengan pengolahan token pada NLP.

Urutan token hasil *embedding* selanjutnya diproses oleh Transformer *encoder* yang tersusun atas blok *multi-head self-attention* dan *multi-layer perceptron* (MLP), disertai *layer normalization* dan *residual connection* [9]. Melalui mekanisme ini, ViT mampu membangun representasi visual yang tidak hanya menangkap detail lokal, tetapi juga keterkaitan global antararea citra

[9]. Karakteristik tersebut menjadikan ViT relevan untuk klasifikasi *deepfake*, karena manipulasi wajah pada *deepfake* sering menghasilkan artefak visual yang tersebar pada berbagai bagian wajah dan tidak selalu terbatas pada pola lokal tertentu. Oleh karena itu, ViT memiliki dasar teoritis yang kuat untuk digunakan sebagai model pada pendekatan spasial dalam penelitian ini. Arsitektur *Vision Transformer* ditunjukkan pada Gambar 2.2.




Gambar 2.2 Arsitektur Vision Transformer (ViT)

2.2.6 VideoMAE

VideoMAE merupakan model *video transformer* berbasis *masked autoencoder* yang dirancang untuk mempelajari representasi video secara efisien melalui *self-supervised pre-training* [10]. Secara konseptual, VideoMAE mengadaptasi prinsip Transformer ke domain video dengan memproses masukan sebagai urutan token visual spasiotemporal, bukan sebagai urutan kata seperti pada *Natural Language Processing* [20]. Rancangan ini juga berkaitan erat dengan perkembangan *Vision Transformer* (ViT), karena *backbone* yang digunakan pada VideoMAE dibangun di atas prinsip *Transformer encoder* yang memproses token visual melalui mekanisme *self-attention* [9], [10]. Dengan demikian, VideoMAE dapat dipahami sebagai perluasan Transformer berbasis citra ke domain video untuk mempelajari hubungan spasial dan temporal secara

bersamaan [9], [10], [20].

Pada arsitektur aslinya, VideoMAE menggunakan rancangan *asymmetric encoder-decoder* [10]. Klip video terlebih dahulu diubah menjadi token spasiotemporal melalui pembagian masukan ke dalam kubus video kecil, kemudian hanya token yang tidak dimask diproses oleh *encoder*, sedangkan *decoder* yang lebih ringan digunakan untuk merekonstruksi token yang disembunyikan [10]. Rancangan ini membuat proses *pre-training* menjadi lebih efisien karena beban komputasi utama difokuskan pada *encoder* yang hanya menerima sebagian token masukan [10]. Selain itu, pendekatan tersebut juga sejalan dengan karakteristik data video yang memiliki redundansi temporal tinggi, sehingga informasi penting masih dapat dipelajari meskipun sebagian besar token masukan disembunyikan [10].



Gambar 2.3 Arsitektur VideoMAE dengan asymmetric encoder-decoder dan tube masking
Sumber: diadaptasi dari Tong dkk. (2022)

Salah satu karakteristik utama VideoMAE adalah penggunaan *tube masking* dengan rasio *masking* yang sangat tinggi, yaitu sekitar 90% hingga 95% [10]. Strategi ini digunakan karena video memiliki korelasi temporal antarbingkai yang kuat, sehingga *masking* biasa berisiko membuat tugas rekonstruksi menjadi terlalu mudah akibat adanya informasi yang berulang pada bingkai tetangga [10]. Dengan *tube masking*, pola *masking* dipertahankan sepanjang dimensi waktu sehingga model terdorong untuk mempelajari representasi spasiotemporal tingkat tinggi, bukan hanya mencocokkan korespondensi lokal antar-*frame* [10]. Pada tahap pembentukan token, VideoMAE tidak membagi masukan sebagai *patch* dua dimensi seperti pada ViT

untuk citra, tetapi sebagai kubus spasiotemporal melalui mekanisme *joint space-time cube embedding*, lalu memodelkan hubungan antar token menggunakan *joint space-time attention* [10]. Rancangan tersebut memungkinkan model menangkap informasi visual statis sekaligus dinamika temporal dalam satu kerangka representasi [10].

Pemodelan ini relevan untuk analisis video *deepfake*, karena bukti manipulasi tidak selalu muncul sebagai artefak spasial pada satu *frame*, tetapi juga dapat muncul sebagai inkonsistensi gerakan atau ketidakwajaran temporal antar-*frame* [6], [13]. Penelitian pada deteksi *deepfake* video juga menunjukkan bahwa pendekatan spasiotemporal berbasis Transformer memiliki potensi yang baik dalam memanfaatkan informasi temporal secara lebih komprehensif [13]. Selain itu, keberadaan VideoMAE sebagai salah satu *baseline* dalam penelitian *deepfake* video menunjukkan bahwa model ini sudah dianggap relevan untuk tugas deteksi dan klasifikasi video manipulasi [14]. Dengan demikian, penggunaan VideoMAE dalam penelitian ini memiliki dasar teoritis yang kuat, baik dari sisi arsitektur model video maupun dari sisi relevansinya pada domain *deepfake* [10], [14].

Pada rancangan asli VideoMAE, *encoder* dan *decoder* digunakan bersama pada tahap *self-supervised pre-training* untuk merekonstruksi token video yang dimask [10]. Namun, pada penelitian ini tidak seluruh mekanisme tersebut digunakan kembali secara utuh. Penelitian ini hanya memanfaatkan *encoder* VideoMAE sebagai *backbone* representasi video, kemudian bagian tersebut di-*fine-tuning* untuk tugas klasifikasi biner *real* dan *fake*. Dengan kata lain, *decoder* rekonstruksi bukan bagian yang digunakan pada tahap klasifikasi dalam penelitian ini, melainkan hanya merupakan komponen pada rancangan asli VideoMAE saat proses *pre-training* [10]. Pendekatan ini sesuai dengan praktik pemanfaatan model hasil *pre-training* pada tugas *downstream*, yaitu menggunakan representasi yang telah dipelajari oleh *encoder* untuk membangun model klasifikasi yang lebih spesifik terhadap domain target [10], [14].

2.2.7 Strided Temporal Sampling

Strided temporal sampling merupakan teknik pemilihan *frame* video secara berkala dengan interval tertentu pada dimensi waktu, sehingga hanya sebagian *frame* yang digunakan sebagai representasi dari satu klip video. Tujuan utama teknik ini adalah mengurangi redundansi temporal pada video, karena *frame-frame* yang berdekatan umumnya memiliki kemiripan visual yang tinggi, sementara informasi gerakan yang relevan masih dapat dipertahankan melalui pemilihan *frame* yang tersebar secara teratur. Dalam konteks pemodelan video, pendekatan ini membantu menekan panjang sekuens masukan dan biaya komputasi, tanpa menghilangkan informasi temporal secara keseluruhan [10], [21], [22].

Pada rancangan VideoMAE, *strided temporal sampling* digunakan sebagai strategi *temporal downsampling* untuk mengatasi redundansi antar-*frame* berurutan [10]. Melalui strategi ini, satu klip video terlebih dahulu diambil dari video asli, kemudian dikompresi menjadi jumlah *frame* yang lebih sedikit melalui proses *temporal sampling* dengan *stride* tertentu [10]. Pendekatan ini membuat model tidak perlu memproses seluruh *frame* dalam satu sekuens secara langsung, tetapi tetap dapat mempelajari pola perubahan visual yang penting pada dimensi waktu [10]. Dengan demikian, *strided temporal sampling* berperan sebagai langkah awal yang penting untuk membentuk representasi video yang lebih ringkas dan efisien sebelum diproses oleh model spasiotemporal [10].

Kebutuhan untuk mengendalikan panjang sekuens masukan juga muncul pada berbagai model *video transformer* lain. TimeSformer menunjukkan bahwa video dapat dimodelkan melalui perhatian ruang-waktu secara langsung, tetapi representasi semacam ini secara alami menghasilkan urutan token yang panjang [21]. Demikian pula, ViViT menegaskan bahwa video menghasilkan token spasiotemporal dalam jumlah besar, sehingga diperlukan rancangan yang efisien untuk mengelola masukan pada domain video [22]. Dalam konteks tersebut,

strided temporal sampling dapat dipahami sebagai salah satu strategi praktis untuk mereduksi jumlah *frame* yang diproses, sehingga efisiensi komputasi dapat ditingkatkan tanpa menghilangkan cakupan dinamika temporal yang representatif [10], [21], [22].

2.2.8 Evaluasi Model

Evaluasi model merupakan tahap yang bertujuan untuk menilai sejauh mana model mampu melakukan klasifikasi video *deepfake* secara tepat pada data uji. Pada penelitian ini, evaluasi dilakukan untuk mengukur kemampuan model dalam membedakan video ke dalam dua kelas, yaitu *real* dan *fake*, sesuai dengan rumusan masalah dan batasan penelitian yang telah ditetapkan. Oleh karena itu, evaluasi tidak hanya dilakukan dengan satu metrik, tetapi menggunakan beberapa ukuran yang saling melengkapi, yaitu *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan *Area Under Curve – Receiver Operating Characteristic* (AUC-ROC).

2.2.8.1 Confusion Matrix

Confusion matrix merupakan representasi tabel yang digunakan untuk membandingkan label sebenarnya (*ground truth*) dengan hasil prediksi model [23]. Pada klasifikasi biner, *confusion matrix* terdiri atas empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Dalam konteks penelitian ini, kelas positif didefinisikan sebagai kelas *fake*. Dengan demikian, *True Positive* merepresentasikan jumlah video *deepfake* yang berhasil diprediksi benar sebagai *fake*, *True Negative* merepresentasikan jumlah video *real* yang diprediksi benar sebagai *real*, *False Positive* merepresentasikan jumlah video *real* yang salah diprediksi sebagai *fake*, sedangkan *False Negative* merepresentasikan jumlah video *deepfake* yang salah diprediksi sebagai *real* [23], [24]. Informasi ini penting karena tidak hanya menunjukkan jumlah prediksi yang benar, tetapi juga memperlihatkan

pola kesalahan model pada masing-masing kelas. Struktur *confusion matrix* ditunjukkan pada Tabel 2.2.

Tabel 2.2 *Confusion Matrix*

Actual \ Predicted	Positive	Negative
<i>Positive</i>	TP	FN
<i>Negative</i>	FP	TN

Keterangan:

- TP (*True Positive*): jumlah prediksi positif yang benar.
- TN (*True Negative*): jumlah prediksi negatif yang benar.
- FP (*False Positive*): jumlah prediksi positif yang salah.
- FN (*False Negative*): jumlah prediksi negatif yang salah.

2.2.8.2 Accuracy

Accuracy merupakan metrik evaluasi yang mengukur proporsi prediksi benar terhadap seluruh sampel yang diuji [23]. Metrik ini memberikan gambaran umum tentang seberapa baik model melakukan klasifikasi secara keseluruhan. Namun, *accuracy* saja tidak selalu cukup untuk menggambarkan performa model secara lengkap, terutama ketika kesalahan pada salah satu kelas memiliki konsekuensi yang lebih penting untuk dianalisis [23], [24]. Secara matematis, *accuracy* dirumuskan sebagai berikut.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (\text{Rumus 2.2})$$

2.2.8.3 Precision, Recall, dan F1-Score

Precision merupakan metrik yang mengukur tingkat ketepatan prediksi pada kelas positif, yaitu seberapa banyak sampel yang diprediksi sebagai kelas positif benar-benar termasuk ke dalam kelas tersebut [23], [24]. Pada penelitian ini, *precision* menunjukkan seberapa tepat model ketika memprediksi sebuah video sebagai *fake*. Secara matematis, *precision* dapat dirumuskan sebagai

berikut.

$$Precision = \frac{TP}{TP + FP} \quad (\text{Rumus 2.3})$$

Recall merupakan metrik yang mengukur kemampuan model dalam menangkap seluruh sampel positif yang sebenarnya ada [23], [24]. Dalam penelitian ini, *recall* menunjukkan seberapa banyak video *deepfake* yang berhasil dideteksi dengan benar oleh model. Secara matematis, *recall* dirumuskan sebagai berikut.

$$Recall = \frac{TP}{TP + FN} \quad (\text{Rumus 2.4})$$

Sementara itu, *F1-score* merupakan rata-rata harmonik dari *precision* dan *recall*, sehingga digunakan untuk memberikan ukuran yang lebih seimbang antara ketepatan prediksi positif dan sensitivitas model terhadap kelas positif [23], [24]. Metrik ini penting ketika evaluasi tidak cukup hanya melihat satu sisi performa saja, melainkan memerlukan keseimbangan antara kemampuan mendeteksi video *deepfake* dan kemampuan menghindari prediksi positif yang salah. Secara matematis, *F1-score* dirumuskan sebagai berikut.

$$F1\text{-score} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (\text{Rumus 2.5})$$

2.2.8.4 Area Under Curve – Receiver Operating Characteristic (AUC-ROC)

Receiver Operating Characteristic (ROC) merupakan kurva yang digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas positif dan kelas negatif pada berbagai nilai ambang keputusan (*threshold*) [24], [25]. Kurva ROC dibentuk dari hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate* (FPR). *True Positive Rate* menunjukkan proporsi sampel positif yang berhasil dideteksi dengan benar, sedangkan *False Positive Rate*

menunjukkan proporsi sampel negatif yang salah diprediksi sebagai positif [25].

Secara matematis, *True Positive Rate* dirumuskan sebagai berikut.

$$TPR = \frac{TP}{TP + FN} \quad (\text{Rumus 2.6})$$

Adapun *False Positive Rate* dirumuskan sebagai berikut.

$$FPR = \frac{FP}{FP + TN} \quad (\text{Rumus 2.7})$$


Sementara itu, *Area Under Curve* (AUC) merupakan luas area di bawah kurva ROC yang digunakan untuk merepresentasikan kemampuan diskriminatif model secara keseluruhan [25]. Nilai AUC berada pada rentang 0 sampai 1, di mana nilai yang semakin mendekati 1 menunjukkan bahwa model memiliki kemampuan yang semakin baik dalam membedakan video *real* dan *fake* [25]. Dalam penelitian ini, AUC-ROC digunakan untuk melengkapi metrik berbasis *confusion matrix*, sehingga evaluasi model tidak hanya bergantung pada satu nilai ambang keputusan, tetapi juga mempertimbangkan performa model pada berbagai kemungkinan *threshold* [24], [25].

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Alur penelitian dalam tugas akhir ini divisualisasikan melalui sebuah diagram alir yang menjelaskan setiap tahapan proses penelitian, mulai dari identifikasi masalah hingga tahap akhir penyelesaian. Ilustrasi keseluruhan proses tersebut dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Berdasarkan alur penelitian yang ditampilkan pada Gambar 3.1, subbab berikut akan menjabarkan secara rinci setiap langkah yang dilakukan dalam penelitian ini.

3.2.1 Identifikasi Masalah

Tahap identifikasi masalah dalam penelitian ini berfokus pada kerentanan sistem deteksi *deepfake* pada skenario dunia nyata (*in-the-wild*). Pendekatan deteksi konvensional yang berbasis analisis spasial pada tingkat *frame* diketahui dapat mengalami penurunan kinerja seiring meningkatnya kualitas visual

manipulasi *deepfake* [5], [26]. Sebagai alternatif, pendekatan spatiotemporal pada tingkat video secara teoretis mampu mengatasi keterbatasan tersebut melalui pemodelan hubungan antar-*frame* dan pendeteksian anomali gerakan [6]. Namun, pendekatan ini juga menghadapi tantangan, karena jejak artefak temporal sering kali mengalami degradasi akibat kompresi tinggi, distorsi resolusi, dan kualitas video yang tidak konsisten pada data dunia nyata [8], [27]. Kondisi tersebut menunjukkan bahwa penambahan informasi temporal belum tentu menghasilkan sistem deteksi yang lebih tangguh dibandingkan pendekatan spasial murni [7]. Berdasarkan permasalahan tersebut, penelitian ini merancang eksperimen komparatif secara objektif antara model spasial berbasis Vision Transformer (ViT) dan model spatiotemporal berbasis VideoMAE menggunakan dataset WildDeepfake.

3.2.2 Studi Literatur


Tahap kedua dalam penelitian ini adalah studi literatur, yaitu kajian terhadap berbagai sumber ilmiah yang relevan dengan topik penelitian. Studi literatur ini bertujuan untuk memahami konsep dasar, pendekatan, dan temuan penelitian terdahulu yang berkaitan dengan deteksi *deepfake*, khususnya pada pendekatan spasial dan spatiotemporal, serta tantangan klasifikasi video pada kondisi dunia nyata.

Pada tahap ini, dilakukan penelaahan terhadap penelitian-penelitian yang membahas efektivitas ekstraksi artefak visual statis pada tingkat *frame* [2], [5], pentingnya analisis inkonsistensi temporal antar-*frame* pada tingkat video [6], serta pengaruh kompresi dan variasi kualitas visual pada dataset WildDeepfake [8]. Hasil studi literatur tersebut digunakan sebagai landasan konseptual untuk mengidentifikasi celah penelitian dan menyusun rancangan eksperimen komparatif antara model spasial berbasis Vision Transformer (ViT) dan model spatiotemporal berbasis VideoMAE.

3.2.3 Pengumpulan Data

Tahap pengumpulan data dalam penelitian ini dilakukan menggunakan dataset publik WildDeepfake. Dataset ini diperkenalkan oleh Zi dkk. [8] sebagai dataset *deepfake* yang merepresentasikan kondisi dunia nyata (*in-the-wild*), sehingga dinilai lebih sesuai untuk mengevaluasi ketahanan model klasifikasi dibandingkan dataset yang disusun dalam lingkungan yang lebih terkontrol. WildDeepfake memiliki keragaman yang tinggi, mencakup variasi jumlah subjek dalam satu adegan, latar belakang, pose wajah, ekspresi, pencahayaan, serta variasi kompresi, resolusi, dan format video.

Secara keseluruhan, WildDeepfake terdiri atas 707 video yang diproses menjadi 7.314 sekuens wajah dengan total 1.180.099 citra wajah. Dari jumlah tersebut, terdapat 3.805 sekuens wajah kelas *real* dan 3.509 sekuens wajah kelas *fake*. Selain itu, dataset ini dibagi menjadi 6.508 sekuens data latih dan 806 sekuens data uji. Pembagian tersebut dilakukan berdasarkan kemiripan antarsekuens agar data latih dan data uji memiliki perbedaan yang memadai, sehingga evaluasi model dapat dilakukan secara lebih objektif [8]. Sebagai ilustrasi, contoh sampel citra wajah dari kelas *real* dan *fake* pada dataset WildDeepfake ditunjukkan pada Gambar 3.2.



Gambar 3.2 Contoh sampel citra wajah kelas *real* dan *fake* pada dataset WildDeepfake

Sumber: WildDeepfake (Zi dkk., 2024)

Sebelum dipublikasikan, WildDeepfake telah melalui serangkaian *preprocessing* awal oleh Zi dkk. [8]. Proses tersebut meliputi pengumpulan video *deepfake* dari berbagai situs video, penyaringan video yang tidak memenuhi

kriteria, deteksi area wajah menggunakan MTCNN, ekstraksi fitur wajah menggunakan MobileNetV2, serta *face alignment* menggunakan *facial landmark* dari dlib. Pada tahap anotasi, setiap sekuens wajah diberi label *real*, *fake*, atau *unknown* oleh tiga anotator, kemudian sekuens dengan label tidak konsisten atau masuk kategori *unknown* dibuang dari dataset akhir. Dengan demikian, dataset WildDeepfake yang digunakan dalam penelitian ini merupakan hasil pengolahan dan anotasi yang telah dilakukan secara sistematis, sehingga siap digunakan sebagai sumber data pada tahap *preprocessing* berikutnya.

3.2.4 Preprocessing Data

Tahap *preprocessing* data dilakukan untuk menyiapkan dataset WildDeepfake agar sesuai dengan kebutuhan eksperimen pada penelitian ini. Pada tahap ini, data tidak lagi melalui proses deteksi wajah, ekstraksi fitur wajah, maupun *face alignment*, karena seluruh tahapan tersebut telah dilakukan sebelumnya pada saat penyusunan dataset WildDeepfake. Selain itu, citra wajah pada dataset sumber telah tersedia dalam ukuran 224×224 piksel, sehingga penelitian ini tidak melakukan proses *resize* tambahan.

Dengan demikian, *preprocessing* dalam penelitian ini difokuskan pada ekstraksi data, penyusunan struktur sekuens, pemisahan data, *strided temporal sampling*, augmentasi data, normalisasi, dan pembentukan tensor masukan. Rancangan ini disusun agar pendekatan spasial dan pendekatan spatiotemporal menggunakan evidensi visual dasar yang sama, sehingga perbandingan kinerja keduanya dapat dilakukan secara lebih adil dan terarah.

3.2.4.1 Ekstraksi Dataset

Tahap awal *preprocessing* dilakukan melalui proses ekstraksi dataset dan penyusunan struktur sekuens dari WildDeepfake. Dataset yang digunakan tersimpan dalam direktori utama *deepfake_in_the_wild* yang terbagi ke dalam empat subset, yaitu *real train*, *real test*, *fake train*, dan *fake test*. Pada masing-

masing subset tersebut terdapat sejumlah berkas terkompresi dengan format *.tar.gz*, seperti *0.tar.gz*, *1.tar.gz*, *2.tar.gz*, dan seterusnya.

Sebelum proses ekstraksi dilakukan, setiap berkas *.tar.gz* telah memuat struktur data internal yang terdiri atas folder kelas dan sejumlah folder sekuens wajah. Sebagai contoh, pada subset *real train*, berkas *0.tar.gz* memuat folder *real* yang berisi folder-folder seperti *0*, *1*, *2*, dan seterusnya. Setiap folder tersebut merepresentasikan satu *face sequence*, sedangkan citra-citra di dalamnya, seperti *0.png*, *1.png*, *2.png*, dan seterusnya, merupakan kumpulan *frame* wajah hasil ekstraksi dari video. Nama berkas citra menunjukkan urutan *frame* pada video asli, sehingga informasi temporal tetap dapat dipertahankan untuk kebutuhan pemrosesan lebih lanjut. Struktur folder dataset WildDeepfake sebelum proses ekstraksi ditunjukkan pada Gambar 3.3.

```

deepfake_in_the_wild/
|-- real train/
|   |-- 0.tar.gz
|   |   |-- real/
|   |   |   |-- 0/
|   |   |   |   |-- 0.png
|   |   |   |   |-- 1.png
|   |   |   |   |-- 2.png
|   |   |   |   |-- ...
|   |   |   |-- 1/
|   |   |   |-- 2/
|   |   |   |-- ...
|   |-- 1.tar.gz
|   |-- 2.tar.gz
|   |-- ...
|-- real test/
|   |-- 0.tar.gz
|   |-- ...
|-- fake train/
|   |-- 0.tar.gz
|   |-- ...
|-- fake test/
|   |-- 0.tar.gz
|   |-- ...

```

Gambar 3.3 Struktur folder dataset WildDeepfake sebelum ekstraksi

Pada penelitian ini, seluruh berkas *.tar.gz* diekstraksi terlebih dahulu sesuai subset asalnya. Setelah proses ekstraksi selesai, struktur data disusun ulang agar lebih sistematis dan mudah digunakan pada tahap berikutnya. Folder hasil ekstraksi dari setiap arsip, misalnya *0*, *1*, *2*, dan seterusnya, ditempatkan langsung di bawah subset masing-masing, seperti *real train*, *real test*, *fake*

train, dan *fake test*. Di dalam setiap folder hasil ekstraksi tersebut tersimpan kembali folder-folder sekuens wajah yang berisi kumpulan citra *frame*. Dengan demikian, satu folder hasil ekstraksi merepresentasikan satu kelompok data dari satu arsip, sedangkan folder-folder di dalamnya merepresentasikan unit sekuens yang akan diproses lebih lanjut. Struktur folder dataset WildDeepfake setelah proses ekstraksi ditunjukkan pada Gambar 3.4.

```

deepfake_in_the_wild/
|-- real train/
|   |-- 0/
|   |   |-- 0/
|   |   |   |-- 0.png
|   |   |   |-- 1.png
|   |   |   |-- 2.png
|   |   |   |-- ...
|   |   |-- 1/
|   |   |-- 2/
|   |   |-- ...
|   |-- 1/
|   |-- 2/
|   |-- ...
|-- real test/
|   |-- 0/
|   |-- ...
|-- fake train/
|   |-- 0/
|   |-- ...
|-- fake test/
|   |-- 0/
|   |-- ...

```

Gambar 3.4 Struktur folder dataset WildDeepfake setelah ekstraksi

Penyusunan ulang struktur data ini dilakukan untuk memudahkan proses pembacaan data pada tahap berikutnya. Dengan struktur yang telah disusun ulang tersebut, proses *data loading*, pembentukan klip, dan pelacakan identitas sekuens dapat dilakukan secara lebih teratur dan konsisten. Melalui tahapan ini, dataset berada dalam bentuk yang lebih siap untuk digunakan pada proses *data splitting*, *strided temporal sampling*, dan pembentukan masukan model pada tahap berikutnya.

3.2.4.2 Data Splitting

Penelitian ini mengikuti pemisahan data yang telah tersedia pada dataset sumber, yaitu subset *train* dan *test*. Dengan demikian, seluruh data pada direktori

real test dan *fake test* digunakan sebagai data pengujian akhir, sedangkan direktori *real train* dan *fake train* digunakan sebagai sumber data untuk proses pelatihan dan validasi. Strategi ini mempertahankan pembagian resmi dari dataset WildDeepfake, sehingga evaluasi akhir tetap dilakukan pada data yang tidak terlibat dalam proses pelatihan [8].

Fokus pemisahan data pada penelitian ini terletak pada subset *train*, yang kemudian dipecah kembali menjadi data *train* dan data *validation* dengan perbandingan 80:20. Pemilihan rasio ini didasarkan pada pertimbangan teoritis dan empiris. Secara teoritis, Joseph menunjukkan bahwa tidak terdapat satu rasio pembagian data yang selalu optimal untuk semua kasus, tetapi rasio pembagian perlu mempertimbangkan keseimbangan antara kecukupan data pelatihan dan keandalan evaluasi. Dalam praktik pemodelan prediktif, rasio 80:20 menjadi salah satu pilihan yang paling umum digunakan karena memberikan proporsi data latih yang cukup besar, sekaligus tetap menyediakan sebagian data untuk validasi performa model [28].

Dari sisi empiris, Bichri dkk. mengevaluasi pengaruh rasio pembagian data 60:40, 70:30, 80:20, dan 90:10 pada beberapa model *pre-trained* untuk tugas klasifikasi citra. Hasil penelitian tersebut menunjukkan bahwa performa model dipengaruhi oleh rasio pembagian data, dan penggunaan proporsi data latih yang lebih besar dari 70% cenderung memberikan hasil yang lebih baik pada skenario yang diuji. Temuan ini mendukung bahwa rasio 80:20 merupakan pilihan yang wajar dan seimbang untuk proses pengembangan model, karena masih menyediakan data validasi yang memadai tanpa terlalu mengurangi jumlah data latih [29].

Pada penelitian ini, pemisahan subset *train* menjadi data *train* dan *validation* dilakukan pada tingkat sekuens, bukan pada tingkat citra. Pendekatan ini diterapkan agar *frame* yang berasal dari sekuens yang sama tidak terdistribusi ke subset yang berbeda. Dengan demikian, potensi *data leakage* dapat dihindari dan validitas evaluasi selama proses pelatihan dapat tetap terjaga.

Melalui rancangan ini, data *validation* benar-benar berfungsi sebagai data yang tidak digunakan dalam pembaruan parameter model, tetapi masih berasal dari distribusi pelatihan yang sama.

3.2.4.3 Strided Temporal Sampling


Pada penelitian ini, pembentukan sampel dilakukan menggunakan teknik *strided temporal sampling* pada sekuens video. Teknik ini digunakan untuk memilih sejumlah *frame* dari setiap sekuens secara berkala sehingga diperoleh representasi temporal yang lebih ringkas, tetapi tetap mampu merepresentasikan dinamika gerakan dalam video.

Penerapan teknik ini mengacu pada rancangan VideoMAE yang diperkenalkan oleh Tong dkk. [10]. Dalam paper tersebut, *strided temporal sampling* digunakan sebagai strategi *temporal downsampling* untuk mengatasi redundansi temporal pada video, sehingga model tidak perlu memproses seluruh *frame* dalam satu sekuens secara langsung. Tong dkk. [10] menjelaskan bahwa satu klip video terlebih dahulu diambil dari video asli, kemudian dikompresi menjadi sejumlah *frame* yang lebih sedikit melalui proses *temporal sampling*.

Mengikuti prinsip tersebut, setiap sekuens pada penelitian ini diproses untuk membentuk satu klip yang terdiri atas 16 *frame* dengan *stride* 4. Dalam konfigurasi ini, setelah satu *frame* dipilih, *frame* berikutnya diambil dengan selang empat indeks dari *frame* sebelumnya hingga diperoleh 16 *frame* dalam satu klip. Pemilihan konfigurasi ini bertujuan untuk menjaga efisiensi pemrosesan sekaligus mempertahankan cakupan informasi temporal yang cukup representatif.

Sebagai ilustrasi, perbedaan antara *sequential frame sampling* dan *strided temporal sampling* ditunjukkan pada Gambar 3.5. Pada *sequential frame sampling*, *frame* diambil secara berurutan sesuai urutan kemunculannya dalam sekuens. Sebaliknya, pada *strided temporal sampling*, *frame* dipilih dengan interval tertentu. Dalam penelitian ini, interval yang digunakan adalah empat

frame, sehingga dari satu sekuens diperoleh klip berisi 16 *frame* yang tetap merepresentasikan informasi temporal secara lebih efisien.



Gambar 3.5 Ilustrasi perbedaan *sequential frame sampling* dan *strided temporal sampling* ($T = 16$, $\tau = 4$)

Hasil *strided temporal sampling* pada penelitian ini dijadikan sebagai sampel dasar bersama untuk kedua jalur eksperimen, yaitu pendekatan spasial dan pendekatan spasiotemporal. Dengan demikian, kedua pendekatan tidak dibangun dari kumpulan citra yang berbeda, melainkan dari *frame-frame* hasil sampling yang sama. Perbedaannya terletak pada bentuk representasi yang diberikan kepada model. Pada pendekatan spasial, setiap *frame* hasil sampling diperlakukan sebagai sampel individual. Sementara itu, pada pendekatan spasiotemporal, *frame-frame* yang sama dipertahankan sebagai satu klip terurut. Rancangan ini bertujuan untuk menjaga keadilan eksperimen, sehingga perbedaan kinerja yang muncul lebih merefleksikan perbedaan cara model memanfaatkan informasi spasial dan temporal, bukan disebabkan oleh perbedaan data yang digunakan.

3.2.4.4 Augmentasi Data

Untuk meningkatkan keragaman data pelatihan dan mengurangi risiko *overfitting*, augmentasi hanya diterapkan pada data *train*, sedangkan data *validation* dan data *test* tidak diberikan augmentasi agar evaluasi model tetap

objektif. Dalam penelitian ini, augmentasi dilakukan setelah tahap *strided temporal sampling*, sehingga transformasi diterapkan pada klip hasil sampling yang sama yang akan digunakan oleh kedua jalur eksperimen. Transformasi yang diterapkan meliputi *horizontal flip* untuk menambah keragaman orientasi wajah, penyesuaian kecerahan dan kontras (*color jitter*) untuk mensimulasikan variasi pencahayaan pada video dunia nyata, penambahan *Gaussian noise* untuk meniru derau akibat proses perekaman dan kompresi, serta *random resized crop* agar model dapat mempelajari pola visual pada area wajah yang sedikit berbeda tanpa menghilangkan konteks utama. Seluruh transformasi diterapkan secara konsisten pada semua *frame* dalam satu klip dengan parameter yang sama, sehingga struktur visual wajah dan koherensi temporal antar-*frame* tetap terjaga. Dengan demikian, augmentasi yang digunakan dapat meningkatkan keragaman data tanpa mengubah karakteristik visual penting yang menjadi dasar klasifikasi video *deepfake*.

3.2.4.5 Normalisasi Frame Hasil Sampling

Setelah data melalui tahap ekstraksi, pemisahan, *strided temporal sampling*, dan augmentasi, langkah berikutnya adalah melakukan normalisasi terhadap *frame-frame* hasil sampling. Normalisasi dilakukan agar distribusi nilai piksel menjadi lebih terstandarisasi dan sesuai dengan karakteristik model *pretrained* yang digunakan. Tahap ini penting untuk menjaga stabilitas proses pelatihan serta membantu model dalam mempelajari pola visual secara lebih efektif.

Pada pendekatan spasial, setiap *frame* hasil *strided temporal sampling* diperlakukan sebagai citra tunggal yang akan diberikan ke model Vision Transformer (ViT). Sebelum digunakan, nilai piksel pada setiap *frame* terlebih dahulu diubah ke rentang $[0, 1]$, kemudian dinormalisasi menggunakan parameter $mean = [0.5, 0.5, 0.5]$ dan $standard deviation = [0.5, 0.5, 0.5]$. Parameter ini mengikuti konfigurasi preprocessing bawaan dari model ViT-

*Base*¹ pada pustaka *timm* yang digunakan dalam penelitian ini.

Sementara itu, pada pendekatan spasiotemporal, kumpulan *frame* hasil *strided temporal sampling* dipertahankan sebagai satu klip yang akan digunakan oleh model VideoMAE. Setiap *frame* dalam klip juga dinormalisasi dengan terlebih dahulu mengubah nilai piksel ke rentang $[0, 1]$, kemudian menerapkan parameter *mean* = $[0.5, 0.5, 0.5]$ dan *standard deviation* = $[0.5, 0.5, 0.5]$. Parameter ini mengikuti konfigurasi VideoMAEImageProcessor² pada implementasi yang digunakan dalam penelitian ini.

3.2.5 Rancangan Model

Pada tahap ini, rancangan model disusun untuk membandingkan pendekatan spasial berbasis Vision Transformer (ViT) dan pendekatan spasiotemporal berbasis VideoMAE pada tugas klasifikasi video *deepfake*. Kedua model menggunakan *frame-frame* hasil *strided temporal sampling* yang sama sebagai evidensi visual dasar, sehingga perbedaan performa yang diperoleh lebih merefleksikan perbedaan kemampuan model dalam memanfaatkan informasi spasial dan temporal. Pada pendekatan spasial, masukan diproses pada tingkat *frame*, sedangkan pada pendekatan spasiotemporal, masukan diproses pada tingkat klip video. Rancangan ini memungkinkan evaluasi komparatif yang lebih objektif terhadap kedua pendekatan pada data *deepfake in-the-wild*.

3.2.5.1 Rancangan Model Spasial Berbasis Vision Transformer (ViT)


Model Vision Transformer (ViT) yang diperkenalkan oleh Dosovitskiy dkk. pada tahun 2021 merupakan arsitektur berbasis Transformer untuk tugas klasifikasi citra yang memproses citra sebagai urutan *image patch* [9]. Berbeda dengan pendekatan konvolusional yang menekankan operasi lokal, ViT memanfaatkan mekanisme *self-attention* untuk memodelkan hubungan

¹https://huggingface.co/timm/vit_base_patch16_224.augreg2_in21k_ft_in1k

²https://github.com/huggingface/transformers/blob/v5.5.0/src/transformers/models/videomae/image_processing_videomae.py

global antarbagian citra, sehingga mampu menangkap keterkaitan visual yang tersebar pada berbagai area masukan [9]. Dalam penelitian ini, ViT-Base/16 digunakan sebagai model pada pendekatan spasial untuk melakukan klasifikasi video *deepfake* berdasarkan informasi visual statis pada tingkat *frame*. Model tersebut diinisialisasi menggunakan bobot hasil pelatihan pada ImageNet-21K, kemudian disesuaikan lebih lanjut untuk tugas klasifikasi biner *real* dan *fake*.

Masukan model berupa *frame* hasil *strided temporal sampling* berukuran 224×224 piksel. Pada jalur spasial, setiap *frame* diproses sebagai citra tunggal. Sesuai dengan rancangan ViT, citra masukan terlebih dahulu dibagi menjadi *patch* berukuran 16×16 piksel. Dengan konfigurasi tersebut, satu citra 224×224 menghasilkan $14 \times 14 = 196$ *patch*. Setiap *patch* kemudian diratakan dan diproyeksikan secara linear untuk membentuk representasi vektor yang disebut *patch embedding* [9]. Setelah proses tersebut, sebuah *class token* ditambahkan pada awal urutan token, sedangkan *position embedding* disisipkan untuk mempertahankan informasi posisi spasial setiap *patch* dalam citra [9]. Dengan demikian, jumlah token yang diproses oleh model untuk setiap *frame* adalah 197 token, yaitu 196 token *patch* dan 1 *class token*. Ilustrasi arsitektur model spasial berbasis ViT yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.6.



Gambar 3.6 Arsitektur model spasial berbasis Vision Transformer (ViT)

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. Pada konfigurasi ViT-Base, encoder terdiri atas 12 blok Transformer dengan dimensi embedding sebesar 768 dan 12 *attention head* pada mekanisme *multi-head self-attention* [9]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection* [9]. Melalui susunan ini, model dapat mempelajari hubungan antar-*patch* secara menyeluruh, sehingga representasi visual yang dihasilkan tidak hanya menangkap detail lokal, tetapi juga struktur global wajah yang berpotensi mengalami manipulasi.

Dalam rancangan penelitian ini, setiap *frame* hasil *strided temporal sampling* diberikan ke *backbone* ViT untuk mengekstraksi fitur spasial. Representasi keluaran yang terkait dengan *class token* pada akhir encoder kemudian diteruskan ke lapisan klasifikasi biner untuk menghasilkan probabilitas kelas *real* dan *fake*. Dengan rancangan tersebut, unit prediksi dasar pada pendekatan spasial berada pada tingkat *frame*. Namun, karena tujuan penelitian ini adalah melakukan klasifikasi pada tingkat sekuens atau video, prediksi tidak dihentikan pada masing-masing *frame* secara individual. Untuk setiap sekuens yang terdiri atas 16 *frame* hasil sampling, model terlebih dahulu menghasilkan probabilitas prediksi pada setiap *frame*, kemudian seluruh probabilitas tersebut diagregasi menggunakan rata-rata probabilitas untuk memperoleh keputusan akhir pada tingkat sekuens. Strategi ini dipilih agar pendekatan spasial tetap merepresentasikan analisis visual statis pada tingkat *frame*, tetapi hasil akhirnya tetap dapat dibandingkan secara langsung dengan pendekatan spasiotemporal pada tingkat klip video.

Rancangan tersebut konsisten dengan tujuan eksperimen komparatif yang menggunakan evidensi visual dasar yang sama pada kedua jalur model. Pada pendekatan spasial, *frame-frame* hasil sampling diperlakukan sebagai masukan individual untuk menilai sejauh mana informasi visual statis masih efektif dalam membedakan wajah asli dan wajah hasil manipulasi pada video *deepfake* dunia

nyata [8], [30]. Meskipun demikian, pendekatan ini memiliki keterbatasan mendasar karena tidak memodelkan hubungan temporal antar-*frame* secara eksplisit. Akibatnya, model spasial diperkirakan lebih sensitif terhadap artefak visual statis, tetapi berpotensi kurang optimal dalam menangkap anomali manipulasi yang hanya tampak melalui dinamika gerakan atau inkonsistensi temporal antar-*frame*. Keterbatasan inilah yang kemudian menjadi dasar pembandingan terhadap pendekatan spasiotemporal berbasis VideoMAE pada subbab berikutnya.


3.2.5.2 Rancangan Model Spasiotemporal Berbasis VideoMAE

Model VideoMAE yang diperkenalkan oleh Tong dkk. pada tahun 2022 merupakan arsitektur berbasis Transformer untuk pemodelan video yang dirancang agar mampu mempelajari representasi spasiotemporal secara efisien [10]. Berbeda dengan Transformer untuk citra tunggal, VideoMAE memproses video sebagai urutan token spasiotemporal yang dibentuk dari klip video, sehingga model dapat menangkap informasi visual statis sekaligus hubungan temporal antar-*frame* [10]. Dalam penelitian ini, VideoMAE digunakan sebagai model pada pendekatan spasiotemporal untuk melakukan klasifikasi video *deepfake* berdasarkan representasi visual pada tingkat klip. Model tersebut diinisialisasi menggunakan bobot hasil pelatihan pada Kinetics-400, kemudian disesuaikan lebih lanjut untuk tugas klasifikasi biner *real* dan *fake*.

Masukan model berupa satu klip video hasil *strided temporal sampling* yang terdiri atas 16 *frame* RGB berukuran 224×224 piksel dengan *stride* 4. Konfigurasi ini dipilih agar konsisten dengan tahap *preprocessing* yang telah dijelaskan sebelumnya, sekaligus menjaga kesetaraan evidensi visual dengan pendekatan spasial. Dengan demikian, kedua jalur eksperimen dibangun dari *frame-frame* hasil *sampling* yang sama, sehingga perbedaan performa yang diperoleh lebih merefleksikan perbedaan kemampuan model dalam memanfaatkan informasi spasial dan temporal, bukan disebabkan oleh perbedaan

data masukan.

Berbeda dari Vision Transformer untuk citra tunggal yang membagi input menjadi *patch* dua dimensi, VideoMAE membagi klip video menjadi kubus spasiotemporal melalui mekanisme *joint space-time cube embedding* [10]. Pada rancangan ini, setiap kubus memiliki ukuran $2 \times 16 \times 16$, yaitu mencakup dua *frame* pada dimensi waktu dan area 16×16 piksel pada dimensi spasial [10]. Dengan masukan berukuran $16 \times 224 \times 224$, proses tersebut menghasilkan token video sebanyak $(16/2) \times (224/16) \times (224/16) = 8 \times 14 \times 14 = 1568$ token. Setiap kubus kemudian diratakan dan diproyeksikan secara linear ke ruang embedding untuk membentuk representasi token video. Setelah itu, *positional embedding* ditambahkan untuk mempertahankan informasi posisi spasial dan urutan temporal token sebelum diproses lebih lanjut oleh model. Ilustrasi arsitektur model spasiotemporal berbasis VideoMAE yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.7.



Gambar 3.7 Arsitektur model spasiotemporal berbasis VideoMAE untuk klasifikasi *deepfake*

Urutan token hasil embedding selanjutnya diproses oleh rangkaian Transformer encoder. Pada konfigurasi ViT-Base, encoder terdiri atas 12 blok Transformer [10]. Setiap blok encoder memuat komponen *layer normalization*, *multi-head self-attention*, dan *multi-layer perceptron* (MLP) yang dihubungkan melalui mekanisme *residual connection* [10]. Karakteristik utama rancangan

ini terletak pada penggunaan *joint space-time attention*, yaitu mekanisme *self-attention* yang memungkinkan seluruh token video saling berinteraksi secara langsung lintas posisi spasial dan lintas waktu secara simultan [10]. Melalui mekanisme tersebut, model tidak hanya menangkap detail visual pada setiap *frame*, tetapi juga mampu mempelajari keterkaitan perubahan visual antar-*frame* dalam satu klip secara menyeluruh.

Perlu dicatat bahwa pada rancangan asli VideoMAE, komponen seperti *tube masking* dengan rasio tinggi dan *decoder* digunakan pada tahap *self-supervised pre-training* untuk merekonstruksi bagian video yang dimask [10]. Namun, pada penelitian ini fokus utama bukan pada tahap tersebut, melainkan pada pemanfaatan representasi VideoMAE untuk tugas klasifikasi biner *downstream*. Oleh karena itu, alur model dalam penelitian ini difokuskan pada pembentukan token spasiotemporal, ekstraksi representasi video melalui Transformer encoder, dan klasifikasi akhir pada tingkat klip.

Pada tahap akhir, representasi keluaran dari lapisan terakhir encoder diringkas melalui *mean pooling* untuk memperoleh satu vektor fitur pada tingkat klip. Vektor tersebut kemudian diteruskan ke *classification head* untuk menghasilkan prediksi akhir secara langsung pada tingkat video, yaitu kelas *real* atau *fake*. Dengan rancangan tersebut, pendekatan spasiotemporal pada penelitian ini beroperasi sepenuhnya pada tingkat klip, sehingga model diharapkan mampu menangkap bukti manipulasi yang tersebar baik pada dimensi spasial maupun temporal secara lebih komprehensif [6], [10]. Hasil dari model ini selanjutnya dibandingkan secara langsung dengan pendekatan spasial berbasis ViT untuk menilai kontribusi relatif informasi temporal terhadap ketahanan klasifikasi *deepfake* pada kondisi dunia nyata.

3.2.6 Evaluasi Model

Evaluasi model pada penelitian ini dilakukan untuk menilai kinerja dua pendekatan yang digunakan, yaitu model spasial berbasis Vision Transformer

(ViT) dan model spasiotemporal berbasis VideoMAE. Proses evaluasi dilaksanakan menggunakan data validasi selama pelatihan untuk memantau perkembangan pembelajaran model dan menentukan model terbaik, serta data uji pada tahap akhir untuk mengukur performa secara objektif terhadap data yang tidak terlibat dalam proses pelatihan [31].

Agar perbandingan kedua pendekatan dilakukan secara setara, evaluasi pada penelitian ini ditetapkan pada tingkat sekuens atau video. Pada pendekatan spasial, model menghasilkan prediksi untuk setiap *frame* dalam satu sekuens, kemudian seluruh prediksi tersebut diagregasi menjadi satu keputusan akhir. Sementara itu, pada pendekatan spasiotemporal, model memproses klip video secara langsung dan menghasilkan satu prediksi pada tingkat video. Dengan demikian, hasil evaluasi dari kedua pendekatan dapat dibandingkan secara langsung pada unit keluaran yang sama.

Kinerja model diukur menggunakan *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC. Penggunaan *precision*, *recall*, dan *F1-score* bertujuan untuk memberikan penilaian yang lebih komprehensif terhadap performa klasifikasi, khususnya dalam melihat keseimbangan antara ketepatan prediksi positif dan kemampuan model mendeteksi seluruh sampel positif [23]. Selain itu, AUC-ROC digunakan untuk menilai kemampuan diskriminatif model dalam membedakan video *real* dan *fake* pada berbagai nilai ambang keputusan [25].

Hasil evaluasi selanjutnya disajikan dalam bentuk tabel perbandingan metrik, *confusion matrix*, kurva ROC, serta grafik *training loss* dan *validation loss* untuk mendukung analisis performa klasifikasi, kemampuan diskriminatif, dan kestabilan proses pelatihan model [25], [31]. Dengan susunan evaluasi tersebut, penelitian ini dapat membandingkan secara objektif efektivitas pendekatan spasial dan spasiotemporal dalam klasifikasi video *deepfake* pada dataset WildDeepfake.

3.2.7 Hasil dan Pembahasan

Tahap hasil dan pembahasan dilakukan untuk menganalisis secara komparatif kinerja model spasial berbasis Vision Transformer (ViT) dan model spasiotemporal berbasis VideoMAE dalam klasifikasi video *deepfake* pada tingkat sekuens atau video. Analisis didasarkan pada perbandingan nilai *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC, serta didukung oleh *confusion matrix*, kurva ROC, dan grafik *training loss* serta *validation loss* untuk menilai performa klasifikasi, kemampuan diskriminatif, dan kestabilan pelatihan model [23], [25], [31]. Hasil yang diperoleh kemudian diinterpretasikan untuk menjelaskan efektivitas relatif pendekatan spasial dan spasiotemporal, termasuk kecenderungan kesalahan prediksi pada data WildDeepfake yang memiliki karakteristik kompresi tinggi, variasi pose, pencahayaan, dan kualitas visual yang tidak seragam [7], [8], [30].

3.3 Alat dan Bahan Tugas Akhir

Adapun alat dan bahan yang digunakan dalam penelitian ini dijelaskan sebagai berikut.

3.3.1 Alat

Alat yang digunakan dalam penelitian ini meliputi perangkat keras (*hardware*) dan perangkat lunak (*software*) yang mendukung proses pemodelan, pelatihan, serta evaluasi model. Berikut adalah alat yang digunakan.

1. Visual Studio Code
2. Kaggle Notebook
3. Library PyTorch
4. GPU NVIDIA Tesla T4 (*cloud-based service*)

3.3.2 Bahan

Bahan yang digunakan dalam penelitian ini berupa dataset dan sumber pendukung untuk proses pelatihan serta evaluasi model. Dataset utama yang

digunakan adalah WildDeepfake sebagai sumber data pelatihan, validasi, dan pengujian. Selain itu, penelitian ini juga menggunakan *pretrained weights* pada model Vision Transformer (ViT) dan VideoMAE untuk mendukung proses *fine-tuning* pada tugas klasifikasi video *deepfake*.

3.4 Ilustrasi Perhitungan Metode

Penjelasan contoh perhitungan bagi penelitian tugas akhir yang menggunakan algoritma perhitungan tertentu. Rumus perhitungan berdasarkan rumus yang sudah dijelaskan sebelumnya di Bab 2.2.

DAFTAR PUSTAKA

- [1] World Economic Forum (WEF). “The Global Risks Report 2026”. 21st Edition (2026). URL: https://reports.weforum.org/docs/WEF_Global_Risks_Report_2026.pdf.
- [2] Ruben Tolosana et al. “DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection” (June 2020).
- [3] Yisroel Mirsky and Wenke Lee. “The Creation and Detection of Deepfakes: A Survey”. *ACM Computing Surveys* 54.1 (2021), pp. 1–41. 1557-7341. URL: <http://dx.doi.org/10.1145/3425780>.
- [4] Bhaskardeep Khaund. “AI and Identity Security: The Threat of Deepfakes and the Future of Authentication”. *Journal of Information Systems Engineering and Management* 10.60s (Sept. 2025), pp. 1015–1030. 2468-4376.
- [5] Junyi Cao et al. “End-to-End Reconstruction-Classification Learning for Face Forgery Detection”. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, pp. 4103–4112.
- [6] Zhihao Gu et al. “Spatiotemporal Inconsistency Learning for DeepFake Video Detection” (Oct. 2021).
- [7] Alexandros Haliassos et al. “Lips Don’t Lie: A Generalisable and Robust Approach to Face Forgery Detection” (Aug. 2021).
- [8] Bojia Zi et al. “WildDeepfake: A Challenging Real-World Dataset for Deepfake Detection” (July 2024).
- [9] Alexey Dosovitskiy et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. 2021. arXiv: [2010.11929](https://arxiv.org/abs/2010.11929) [cs.CV]. URL: <https://arxiv.org/abs/2010.11929>.

- [10] Zhan Tong et al. *VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training*. 2022. arXiv: [2203.12602](https://arxiv.org/abs/2203.12602) [cs.CV]. URL: <https://arxiv.org/abs/2203.12602>.
- [11] Aminollah Khormali and Jiann-Shiun Yuan. “DFDT: An End-to-End DeepFake Detection Framework Using Vision Transformer”. *Applied Sciences* 12.6 (2022). 2076-3417. URL: <https://www.mdpi.com/2076-3417/12/6/2953>.
- [12] Wanyi Zhuang et al. *UIA-ViT: Unsupervised Inconsistency-Aware Method based on Vision Transformer for Face Forgery Detection*. 2022. arXiv: [2210.12752](https://arxiv.org/abs/2210.12752) [cs.CV]. URL: <https://arxiv.org/abs/2210.12752>.
- [13] Staffy Kingra, Naveen Aggarwal, and Nirmal Kaur. “SFormer: An end-to-end spatio-temporal transformer architecture for deepfake detection”. *Forensic Science International: Digital Investigation* 51 (2024), p. 301817. 2666-2817. URL: <https://www.sciencedirect.com/science/article/pii/S2666281724001410>.
- [14] Juan Hu et al. *Delocate: Detection and Localization for Deepfake Videos with Randomly-Located Tampered Traces*. 2024. arXiv: [2401.13516](https://arxiv.org/abs/2401.13516) [cs.CV]. URL: <https://arxiv.org/abs/2401.13516>.
- [15] Tero Karras, Samuli Laine, and Timo Aila. *A Style-Based Generator Architecture for Generative Adversarial Networks*. 2019. arXiv: [1812.04948](https://arxiv.org/abs/1812.04948) [cs.NE]. URL: <https://arxiv.org/abs/1812.04948>.
- [16] Ian J. Goodfellow et al. “Generative Adversarial Nets”. *Advances in Neural Information Processing Systems*. Ed. by Z. Ghahramani et al. Vol. 27. Curran Associates, Inc., 2014. URL: https://proceedings.neurips.cc/paper_files/paper/2014/file/f033ed80deb0234979a61f95710dbe25-Paper.pdf.
- [17] Yuezun Li et al. *Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics*. 2020. arXiv: [1909.12962](https://arxiv.org/abs/1909.12962) [cs.CR]. URL: <https://arxiv.org/abs/1909.12962>.

- [18] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep learning”. *Nature* 521.7553 (May 2015), pp. 436–444. 1476-4687. URL: <https://doi.org/10.1038/nature14539>.
- [19] Athanasios Voulodimos et al. “Deep Learning for Computer Vision: A Brief Review”. *Computational Intelligence and Neuroscience* 2018 (Feb. 2018). PMID: 29487619, p. 7068349. 1687-5273. URL: <https://doi.org/10.1155/2018/7068349>.
- [20] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- [21] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. *Is Space-Time Attention All You Need for Video Understanding?* 2021. arXiv: 2102.05095 [cs.CV]. URL: <https://arxiv.org/abs/2102.05095>.
- [22] Anurag Arnab et al. *ViViT: A Video Vision Transformer*. 2021. arXiv: 2103.15691 [cs.CV]. URL: <https://arxiv.org/abs/2103.15691>.
- [23] Marina Sokolova and Guy Lapalme. “A systematic analysis of performance measures for classification tasks”. *Information Processing & Management* 45.4 (2009), pp. 427–437. 0306-4573. URL: <https://www.sciencedirect.com/science/article/pii/S0306457309000259>.
- [24] David M. W. Powers. *Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation*. 2020. arXiv: 2010.16061 [cs.LG]. URL: <https://arxiv.org/abs/2010.16061>.
- [25] Tom Fawcett. “An introduction to ROC analysis”. *Pattern Recognition Letters* 27.8 (2006). ROC Analysis in Pattern Recognition, pp. 861–874. 0167-8655. URL: <https://www.sciencedirect.com/science/article/pii/S016786550500303X>.
- [26] Kaiqing Lin et al. “Guard Me If You Know Me: Protecting Specific Face-Identity from Deepfakes” (Dec. 2025).

- [27] Chih-Chung Hsu, Yi-Xiu Zhuang, and Chia-Yen Lee. “Deep Fake Image Detection Based on Pairwise Learning”. *Applied Sciences* 10.1 (2020). 2076-3417. URL: <https://www.mdpi.com/2076-3417/10/1/370>.
- [28] V. Roshan Joseph. “Optimal ratio for data splitting”. *Statistical Analysis and Data Mining: The ASA Data Science Journal* 15.4 (2022), pp. 531–538. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/sam.11583>.
- [29] Houda Bichri, Adil Chergui, and Mustapha Hain. “Investigating the Impact of Train / Test Split Ratio on the Performance of Pre-Trained Models with Custom Datasets”. *International Journal of Advanced Computer Science and Applications (IJACSA)* 15.2 (2024).
- [30] Beilin Chu et al. *Reduced Spatial Dependency for More General Video-level Deepfake Detection*. 2025. arXiv: 2503.03270 [cs.CV]. URL: <https://arxiv.org/abs/2503.03270>.
- [31] Yuhang Lu, Ruizhi Luo, and Touradj Ebrahimi. *A Novel Framework for Assessment of Learning-based Detectors in Realistic Conditions with Application to Deepfake Detection*. 2022. arXiv: 2203.11797 [cs.CV]. URL: <https://arxiv.org/abs/2203.11797>.